

Probabilités et statistiques

Paul Viallard
(paul.viallard@inria.fr)

2026

Table des matières

I	Théorie des probabilités	7
1	Mesures et espaces probabilisés	9
1.1	Introduction	9
1.2	Elements de la théorie des probabilités	10
1.3	Théorie de la mesure appliquée à la théorie des probabilités	12
1.4	Tribu borélienne et mesure de Lebesgue	13
2	De l'intégration aux probabilités	15
2.1	Fonction simple	15
2.2	Fonction mesurable	16
2.3	Intégrale de Lebesgue	18
2.4	Espérance et probabilité	20
3	Propriétés de l'espérance	21
3.1	Dérivée de Radon-Nikodym	21
3.2	Variable aléatoire	24
3.3	Indépendance et théorèmes de Fubini	25
3.4	Probabilités conditionnelles	27
3.5	Variance	28
4	Lois	31
4.1	Lois discrètes	31
4.2	Lois continues (à densité)	34
5	Simulation de lois	37
5.1	Le cas "simple" : la loi uniforme	37
5.2	Méthodes d'inversion	37
5.3	Algorithme de Box-Muller : tirer selon $\mathcal{N}(0, 1)$	40
5.4	Astuce de la reparamétrisation	41
5.5	Méthode du rejet	42
6	Convergence des suites de variables aléatoires	45
6.1	Introduction	45
6.2	Convergence presque sûre	45
6.3	Convergence en probabilité	46
6.4	Convergence en loi	46
6.5	Propriétés sur les types de convergence	48
II	Statistiques	51
7	Estimation	53
7.1	Echantillon	53
7.2	Statistique et Estimateur	53
7.3	Qualité d'un estimateur	54
7.4	Estimation de paramètres de distributions : maximum de vraisemblance	56
7.5	Estimation d'un moment : méthode des moments	58
8	Intervalles de confiance et inégalités de concentration	59
8.1	Introduction	59
8.2	Intervalle de confiance	60
8.3	Inégalité de concentration	63
8.4	Autres inégalités (utiles !)	66

9	Apprentissage statistique	69
9.1	Introduction	69
9.2	Apprentissage non supervisé	70
9.3	Apprentissage supervisé	72
9.4	Généralisation et théorie de l'apprentissage	74
10	Généralités sur les tests statistiques	79
10.1	Introduction	79
10.2	Hypothèses	79
10.3	Un premier test	79
10.4	Intervalle de fluctuation	80
10.5	Test Z	82
10.6	Test de Student	83
10.7	Tests pour échantillons indépendants	84
10.8	Test de Kolmogorov-Smirnov	85
11	Tests du χ^2	89
11.1	La loi du χ^2	89
11.2	Test d'adéquation à une loi donnée	90
11.3	Test d'adéquation à une famille de lois	93
11.4	Test d'indépendance	94
III	TDs	97
1	Espaces mesurés/probabilisés, et intégration	99
12.1	Espaces mesurés	99
12.2	Espaces probabilisés	99
12.3	Fonction simple	99
12.4	Intégrale de Lebesgue	100
2	Propriétés de l'espérance	101
13.1	Dérivé de Radon-Nikodym	101
13.2	Modèles d'urnes	101
13.3	Probabilités conditionnelles	102
3	Lois et distributions de probabilités	103
4	Convergence	113
5	TD de Statistiques 2	119
IV	Correction des TDs	121
1	Mesures, espaces probabilisés, et intégration	123
17.1	Fonction simple	125
17.2	Intégrale de Lebesgue	125
2	Propriétés de l'espérance	129
3	Lois et distributions de probabilités	131
4	TD de Statistiques 1	137
5	TD de Statistiques 2	139

Avant-propos

Bibliographie

Ce cours est basé sur celui de [François Schwarzentruber](#), qui est lui-même basé sur différentes références. Des notations inspirées de [mes papiers](#) et de ceux de [Pascal Germain](#), François Laviolette, [Mario Marchand](#), et d'[Emilie Morvant](#).

Références pour la théorie des probabilités

Le cours de François, sur lequel ce cours est basé, s'inspire de deux références pour les probabilités : (GARET et al., [2019](#)) et (BARBE et al., [2021](#)). Cependant, ce cours ajoute des éléments sur la théorie de la mesure qui ne proviennent pas de ces livres. De plus, voici deux livres qui sont intéressants (en tout cas, qui m'intéressent particulièrement...) : (WHITTLE, [2012](#); SHAFER et al., [2019](#)).

Références pour l'apprentissage statistique

Pour une compréhension globale de l'apprentissage statistique, plusieurs références peuvent être intéressantes. Parmi les ouvrages présentant les méthodes d'un point de vue pratique, (BISHOP et al., [2006](#)) et (HASTIE et al., [2009](#)) sont des références incontournables ; il y a également des références plus récentes comme (MURPHY, [2022](#)). D'un point de vue théorique, il y a le livre de (VAPNIK, [2013](#)), qui jette les bases théoriques des principes fondamentaux du domaine. Enfin, des introductions plus récentes de ces bases théoriques se trouvent dans (MOHRI et al., [2012](#)) et (BACH, [2024](#)).

Partie I

Théorie des probabilités

Chapitre 1


Mesures et espaces probabilisés

1.1 Introduction


Expérience aléatoire

La théorie des probabilités sert à étudier une expérience aléatoire.

Définition 1.1. Une *expérience aléatoire* est un processus dont le résultat ne peut pas être déterminé à l'avance, même si les conditions initiales sont connues. Autrement dit, le résultat est incertain et dépend du hasard.



Exemple. Le lancer de dé est une expérience aléatoire :



Caractérisation d'une expérience aléatoire

Afin de caractériser une expérience aléatoire, nous avons besoin de définir

- de tous les résultats pouvant être obtenus,
- les probabilités associées à chaque résultat pour quantifier la “chance” d’observer un résultat donné.

Exemple. Pour un lancer de dé, nous avons

- l'ensemble des résultats défini par $\{\square, \square, \square, \square, \square, \square\}$,
- les probabilités définies par $\mathbb{P}_{\text{dé} \sim \text{lancer}}[\text{dé} = \square] = \frac{1}{6}$, $\mathbb{P}_{\text{dé} \sim \text{lancer}}[\text{dé} = \square] = \frac{1}{6}$, $\mathbb{P}_{\text{dé} \sim \text{lancer}}[\text{dé} = \square] = \frac{1}{6}$, $\mathbb{P}_{\text{dé} \sim \text{lancer}}[\text{dé} = \square] = \frac{1}{6}$, $\mathbb{P}_{\text{dé} \sim \text{lancer}}[\text{dé} = \square] = \frac{1}{6}$, et $\mathbb{P}_{\text{dé} \sim \text{lancer}}[\text{dé} = \square] = \frac{1}{6}$.

Objectif du chapitre

L'objectif de ce chapitre est de définir formellement la notion d'expérience aléatoire. Pour ce faire, nous introduirons les espaces probabilisés (qui formaliseront la notion d'expérience aléatoire) en nous appuyant sur des éléments de théorie de la mesure.


1.2 Elements de la théorie des probabilités

Univers

Afin de caractériser l'ensemble des résultats possibles d'une expérience aléatoire, nous devons définir l'univers.

Définition 1.2. Un *univers* Ω est l'ensemble (non vide) de tous les résultats pouvant être obtenus au cours d'une expérience aléatoire.

Exemple. Voici un exemple d'univers Ω avec 12 résultats possibles :




Événement

Parfois, nous pouvons nous intéresser qu'à un sous-ensemble de Ω . Pour cela, nous devons définir un événement.

Définition 1.3. Un *événement* A est un sous-ensemble de Ω désignant un sous-ensemble des résultats possibles d'une expérience aléatoire.


Exemple. Voici l'événement $A := \text{"le dé affiche un nombre pair"}$



Pour définir des probabilités...

Pour définir des probabilités, nous allons mesurer la "taille" des événements $A \subseteq \Omega$ à l'aide d'un objet mathématique appelé "mesure". Ainsi, nous verrons que définir une mesure revient à définir des probabilités.


Exemple. Voici un exemple de mesure sur l'univers Ω et l'événement $A \subseteq \Omega$ précédent.




Pour définir une mesure, nous devons également identifier les différents ensembles autorisés à être mesurés.

Exemple. Nous voulons autoriser que seuls les événements $A \subseteq \Omega$ puissent être mesurés.

On peut mesurer l'événement $A \subseteq \Omega$



On ne peut pas mesurer l'ensemble $A \not\subseteq \Omega$



Introduction (rapide) à la théorie de la mesure

Afin de bien définir une mesure, nous allons voir différentes notions issues de la théorie de la mesure.

Tribu (ou σ -algèbre)

Pour définir l'ensemble des ensembles que l'on peut mesurer, nous allons définir une tribu.

Définition 1.4. Une *tribu* Σ_X (ou σ -algèbre) est un ensemble de sous-ensembles de X avec :

1. $\emptyset \in \Sigma_X$;
2. $X \in \Sigma_X$;
3. Σ_X est stable par complémentaire : si $A \in \Sigma_X$, alors $\bar{A} \in \Sigma_X$;
4. Σ_X est stable par union dénombrable : si $\forall n \in \mathbb{N}, A_n \in \Sigma_X$, alors $\cup_{n \in \mathbb{N}} A_n \in \Sigma_X$;
5. Σ_X est stable par intersection dénombrable : si $\forall n \in \mathbb{N}, A_n \in \Sigma_X$, alors $\cap_{n \in \mathbb{N}} A_n \in \Sigma_X$.

Définition 1.5. Si un ensemble X est muni d'une tribu Σ_X , alors (X, Σ_X) est appelé *espace mesurable*.

Mesure

Nous sommes maintenant prêts à définir une mesure : c'est une fonction ν (positive), qui mesure la "taille" d'un ensemble A appartenant à la tribu Σ_X .

Définition 1.6. Une *mesure* est une application ν définie sur la tribu Σ_X et à valeur dans $[0, +\infty]$ qui respecte les deux propriétés suivantes :

- $\nu(\emptyset) = 0$
- Pour toute suite de sous-ensembles $(A_i)_{i \in \mathbb{N}}$ de Σ_X deux à deux disjoints, on a

$$\nu\left(\bigsqcup_{i \in \mathbb{N}} A_i\right) = \sum_{i \in \mathbb{N}} \nu(A_i).$$

Définition 1.7. Si un ensemble X est muni d'une tribu Σ_X , alors (X, Σ_X, ν) est appelé *espace mesuré*.

La proposition qui suit présente des propriétés naturelles sur un espace mesuré.

Proposition 1.8. Si (X, Σ_X, ν) est un espace mesuré où $\nu : \Sigma_X \rightarrow \mathbb{R}^+$, nous avons les propriétés suivantes :

1. Pour tout $A, B \in \Sigma_X$, $A \cap B = \emptyset$ implique $\nu(A \sqcup B) = \nu(A) + \nu(B)$;
2. Pour tout $A, B \in \Sigma_X$, $\nu(A \cup B) = \nu(A) + \nu(B) - \nu(A \cap B)$;
3. Pour tout $A, B \in \Sigma_X$, $\nu(A \cup B) \leq \nu(A) + \nu(B)$;
4. Pour tout $A, B \in \Sigma_X$, $\nu(A \cap B) \leq \min(\nu(A), \nu(B))$;
5. Pour tout $A, B \in \Sigma_X$, $\nu(A \cup B) \geq \max(\nu(A), \nu(B))$.

1.3 Théorie de la mesure appliquée à la théorie des probabilités

Tribu sur un univers

Pour définir des probabilités, un univers Ω doit être muni d'une tribu.

Définition 1.9. Si un univers Ω est muni d'une tribu Σ_Ω , alors (Ω, Σ_Ω) est appelé *espace probabilisable*.

Définition 1.10. Un événement est un sous-ensemble A qui est contenu dans Σ_Ω .

Mesure de probabilité

Ensuite, une mesure de probabilité est une fonction μ , qui, à tout événement A , associe un nombre $\mu(A)$ entre 0 et 1, qui mesure de combien l'événement est probable.

Définition 1.11. Une *mesure de probabilité* est une application de $\mu : \Sigma_\Omega \rightarrow [0, 1]$ vérifiant :

- $\mu(\Omega) = 1$;
- $\mu(\emptyset) = 0$;
- Pour toute suite de sous-ensembles $(A_i)_{i \in \mathbb{N}}$ de Σ_Ω deux à deux disjoints, on a

$$\mu\left(\bigsqcup_{i \in \mathbb{N}} A_i\right) = \sum_{i \in \mathbb{N}} \mu(A_i).$$

Plus précisément, $\mu(\emptyset) = 0$ car nous mesurons un événement sans aucun résultat possible. De même, comme Ω est l'ensemble de tous les résultats possibles, nous avons $\mu(\Omega) = 1$. On peut aussi imaginer que Ω est une surface d'aire 1. Alors $\mu(A)$ est l'aire de A .

Nous verrons dans le prochain chapitre que la mesure de probabilité nous permet de définir directement des probabilités. Autrement dit, le nombre $\mu(A)$ est la probabilité que A soit vraie.

Proposition 1.12. Soit $(\Omega, \Sigma_\Omega, \mu)$ un espace probabilisé. Nous avons

$$\mu(A) = \mathbb{P}_{\omega \sim \mu} [\omega \in A].$$

Espace probabilisé

Un espace probabilisé est constitué d'un univers Ω , d'une tribu définie sur cet univers, et d'une mesure de probabilité.

Définition 1.13. Un *espace probabilisé* est $(\Omega, \Sigma_\Omega, \mu)$ est la donnée :

- d'un espace Ω ;
- d'une tribu Σ_Ω sur Ω ;
- d'une mesure de probabilité $\mu : \Sigma_\Omega \rightarrow [0, 1]$.

En plus des propriétés de Proposition 1.8, nous avons la propriété suivante pour un espace probabilisé.

Proposition 1.14. Si $(\Omega, \Sigma_\Omega, \mu)$ est un espace probabilisé, nous avons :

1. Pour tout $A \in \Sigma_\Omega$, $\mu(\overline{A}) = 1 - \mu(A)$.

Voici deux exemples simples d'espaces probabilisés où Ω est un ensemble fini.

Exemple (Lancer d'un dé).

- $\Omega = \{1, 2, 3, 4, 5, 6\}$;
- $\Sigma_\Omega = 2^{\{1, 2, 3, 4, 5, 6\}}$;
- Pour tout $A \subseteq \Omega$, nous avons $\mu(A) = \frac{|A|}{6}$.

Exemple (Météo).

- $\Omega = \{\odot, \bullet\}$;
- $\Sigma_\Omega = 2^{\{\odot, \bullet\}}$;
- $\mu(\emptyset) = 0$, $\mu(\Omega) = 1$, $\mu(\{\odot\}) = 0.2$, $\mu(\{\bullet\}) = 0.8$.

Par contre, lorsque l'on veut définir une mesure de probabilité sur un intervalle, tout se complique ... En effet, nous pouvons prouver le théorème suivant.

Théorème 1.15. Soit $\Omega = [0, 1]$ et $\Sigma_\Omega = 2^\Omega$, alors il n'existe pas d'espace probabilisé $(\Omega, \Sigma_\Omega, \mu)$ tel que $\mu([a, b]) = b - a$ avec $0 \leq a \leq b \leq 1$.

1.4 Tribu borélienne et mesure de Lebesgue

Autrement dit, nous ne pouvons pas définir de mesure de probabilité μ naturelle sur un intervalle (où sa mesure correspond à la longueur de l'intervalle) si la tribu est l'ensemble des parties de Ω .

Tribu engendrée et tribu borélienne

Pour réussir à définir une mesure μ sur $[0, 1]$, il faut utiliser une autre tribu : la tribu borélienne. Pour la construire, il faut supposer que

- $[a, b]$ avec $a, b \in [0, 1]$ est dans $Borel([a, b])$.

Puis, $Borel([a, b])$ est stable par complémentaire, union, et intersection dénombrables. Nous avons, par exemple

- $[0, 1] \setminus [a, b]$ est dans $Borel([0, 1])$;
- $\bigcup_{i \in \mathbb{N}} [a_i, b_i]$ est dans $Borel([0, 1])$ avec $0 \leq a_i \leq b_i \leq 1$;
- $\bigcap_{i \in \mathbb{N}} [a_i, b_i]$ est dans $Borel([0, 1])$ avec $0 \leq a_i \leq b_i \leq 1$;
- $\{a\} = [a, a]$ est dans $Borel([0, 1])$;
- Tout ensemble dénombrable $X = \bigcup_{x \in X} \{x\}$ est dans $Borel([0, 1])$.

Les deux définitions suivantes formalisent exactement cette construction.

Définition 1.16. Soit A un ensemble de sous-ensembles de Ω . La *tribu engendrée* par A est la plus petite tribu contenant A .

Définition 1.17. La *tribu borélienne* $Borel([0, 1])$ est la tribu engendrée par l'ensemble $\{[a, b] \mid a, b \in [0, 1]\}$.

Tribu borélienne sur un ensemble $F \subseteq \mathbb{R}^d$

Nous allons voir que nous pouvons étendre la notions de tribu borélienne à un ensemble $F \subseteq \mathbb{R}^d$, avec $d \in \mathbb{N}^*$. Ceci nous servira plus tard dans le cours.

Définition 1.18. La *tribu borélienne* $Borel(F)$ où $F \subseteq \mathbb{R}^d$, avec $d \in \mathbb{N}^*$, est la tribu engendrée par l'ensemble

$$\left\{ \prod_{i=1}^d [a_i, b_i] \mid \prod_{i=1}^d [a_i, b_i] \subseteq F \right\}$$

Mesure de Lebesgue

Nous pouvons définir la mesure de Lebesgue, qui est une mesure sur un produit cartésien d'intervalles provenant de $Borel(F)$.

Définition 1.19. Soit I_i un intervalle de la forme $[a_i, b_i]$, $]a_i, b_i]$, $[a_i, b_i[$, ou $]a_i, b_i[$. La *mesure de Lebesgue* ν d'un produit cartésien d'intervalles est donnée par

$$\nu(I_1 \times \cdots \times I_d) := \prod_{i=1}^d (b_i - a_i).$$

Espace probabilisé avec une tribu borélienne et une mesure de Lebesgue

Grâce à la tribu borélienne $Borel([0, 1])$ et sa mesure de Lebesgue associée, nous pouvons définir un espace probabilisé sur l'intervalle $[0, 1]$.

Exemple (Loi uniforme sur un intervalle).

- $\Omega = [0, 1]$;
- $\Sigma_\Omega = Borel([0, 1])$;
- $\mu([a, b]) = \mu(]a, b]) = \mu([a, b]) = \mu(]a, b]) = b - a$ avec $0 \leq a \leq b \leq 1$.

Chapitre 2

De l'intégration aux probabilités

Introduction

Dans le chapitre précédent, nous avons vu avec Proposition 1.12 l'égalité suivante.

Soit $(\Omega, \Sigma_\Omega, \mu)$ un espace probabilisé, alors nous avons

$$\mu(A) = \mathbb{P}_{\omega \sim \mu} [\omega \in A].$$

Dans ce chapitre, nous allons démontrer cette proposition.

De plus, nous allons définir des notions essentielles pour caractériser une expérience aléatoire. En effet, étant donné un espace probabilisé $(\Omega, \Sigma_\Omega, \mu)$, nous allons définir une probabilité $\mathbb{P}_{\omega \sim \mu} [\cdot]$, une espérance $\mathbb{E}_{\omega \sim \mu} [\cdot]$, et voir certaines de leurs propriétés.

Afin de formaliser ces notions fondamentales en théorie des probabilités, il est indispensable de définir l'intégrale de Lebesgue. Ainsi, nous verrons : (i) les fonctions simples, qui servent d'éléments de base pour la définition de l'intégrale, et (ii) la notion de fonction mesurable, c'est-à-dire une fonction pour laquelle cette intégrale peut être correctement définie.

2.1 Fonction simple

Fonction simple

Pour définir l'intégrale de Lebesgue, nous avons besoin de définir un type de fonction particulier.

Définition 2.1. Soit (X, Σ_X) un espace mesurable. Soient $a_1, \dots, a_n \in \mathbb{R}$ et $A_1, \dots, A_n \in \Sigma_X$ des ensembles mesurables deux à deux disjoints et $\cup_{i \in \{1, \dots, n\}} A_i = A \subseteq X$. Une *fonction simple* $f : A \rightarrow \mathbb{R}$ est définie par


$$\forall x \in A, \quad f(x) = \sum_{k=1}^n a_k \mathbb{1}[x \in A_k],$$

où $\mathbb{1}[a] = 1$ si la proposition a est vraie et 0 sinon.

En d'autres termes, une fonction simple prend un nombre fini de valeurs réelles. De plus, pour tout élément $x \in A_k$, la fonction simple donne la valeur associée à l'ensemble A_k , c'est-à-dire que nous avons $f(x) = a_k$. Voici un exemple de fonction simple, ainsi que sa représentation graphique.

Exemple.


$$\begin{aligned} f(x) = & 0.75 \cdot \mathbb{1}[x \in [0.0, 0.25[] + 0.25 \cdot \mathbb{1}[x \in [0.25, 0.5[] \\ & + 0.5 \cdot \mathbb{1}[x \in [0.5, 0.75[] + 0.15 \cdot \mathbb{1}[x \in [0.75, 1.0[] \end{aligned}$$



Approximation par fonctions simples

En pratique, une fonction simple permet d'approcher une fonction (plus compliquée).

Exemple.



Cette approximation est justifiée par un théorème que nous allons voir plus tard dans ce chapitre. Ainsi, le théorème suivant n'est que sa version informelle.

Théorème (informel!). Pour un certain type de fonction $f : X \rightarrow \mathbb{R}$, il existe une séquence de fonctions simples $\{f_n\}_{n \in \mathbb{N}}$ telle que

$$\text{pour tout } x \in X, \quad \text{nous avons} \quad \lim_{n \rightarrow \infty} f_n(x) = f(x).$$

En réalité, il permet d'approcher des fonctions mesurables (que nous allons voir ensuite).

2.2 Fonction mesurable

Fonction mesurable

L'intégrale de Lebesgue permet d'intégrer un type de fonction, appelé fonction mesurable, que nous allons voir dans la définition suivante.


Définition 2.2. Soient deux espaces (X, Σ_X) et (Y, Σ_Y) mesurables. Une fonction $f : X \rightarrow Y$ est dite *mesurable* si nous avons

$$\text{pour tout } B \in \Sigma_Y, \quad \text{nous avons} \quad f^{-1}(B) \in \Sigma_X,$$

$$\text{où} \quad f^{-1}(B) = \{x \in X \mid f(x) \in B\}.$$

Voici une illustration pour clarifier cette définition.

Exemple.



Cette définition garantit que la fonction f “transporte” les ensembles mesurables de Y (c’est-à-dire $B \in \Sigma_Y$) vers des ensembles mesurables de X (c’est-à-dire $f^{-1}(B) \in \Sigma_X$). Autrement dit, elle assure que f préserve la structure mesurable des espaces X et Y , ce qui permet d’étudier ses propriétés à travers l’intégration.

Propriétés des fonctions mesurables

Si l’espace Y est restreint à l’ensemble des réels $\mathbb{R}$, nous pouvons trouver une caractérisation (plus naturelle) des fonctions mesurables.

Théorème 2.3. Soient (X, Σ_X) un espace mesurable et une fonction $f : X \rightarrow \mathbb{R}$. Les propositions suivantes sont équivalentes

1. f est une fonction mesurable,
2. pour tout $\alpha \in \mathbb{R}$, nous avons $\{x \in X \mid f(x) \leq \alpha\} \in \Sigma_X$,
3. pour tout $\alpha \in \mathbb{R}$, nous avons $\{x \in X \mid f(x) < \alpha\} \in \Sigma_X$,
4. pour tout $\alpha \in \mathbb{R}$, nous avons $\{x \in X \mid f(x) \geq \alpha\} \in \Sigma_X$,
5. pour tout $\alpha \in \mathbb{R}$, nous avons $\{x \in X \mid f(x) > \alpha\} \in \Sigma_X$.

En effet, pour une fonction $f : X \rightarrow \mathbb{R}$ qui est mesurable, il suffit de vérifier que les ensembles où la fonction est supérieure ou inférieure à un certain seuil α sont mesurable, c’est-à-dire qu’ils appartiennent à la tribu Σ_X . Autrement dit, cette propriété reflète le fait que f “transporte” les ensembles mesurables de $\mathbb{R}$ (comme les intervalles $] -\infty, \alpha]$ ou $[\alpha, +\infty[$) vers des ensembles mesurables de X .

Grâce à cette propriété, nous pouvons prouver que les fonctions simples sont des fonctions mesurables.

Théorème 2.4. Soient un espace mesurable (X, Σ_X) et $f : X \rightarrow \mathbb{R}$ une fonction simple, alors f est une fonction mesurable.

De plus, une caractérisation importante des fonctions mesurables est qu’elles peuvent être approchées par des fonctions simples. En effet, nous avons le théorème suivant.

Théorème 2.5. Soient un espace mesurable (X, Σ_X) et $f : X \rightarrow \mathbb{R}$ une fonction mesurable, alors il existe une séquence de fonctions simples $\{f_n\}_{n \in \mathbb{N}}$ telle que

$$\text{pour tout } x \in X, \quad \text{nous avons} \quad \lim_{n \rightarrow \infty} f_n(x) = f(x).$$

Autrement dit, nous pouvons approcher n’importe quelle fonction mesurable f à l’aide d’une séquence $\{f_n\}_{n \in \mathbb{N}}$ de fonctions simples.

2.3 Intégrale de Lebesgue

Maintenant, nous pouvons définir l'intégrale de Lebesgue pour les fonctions mesurables. Nous allons tout d'abord nous concentrer sur les fonctions simples (qui sont des fonctions mesurables).

Définition 2.6. Soient un espace mesuré (X, Σ_X, ν) et $A \in \Sigma_X$, soit une fonction simple $f : A \rightarrow \mathbb{R}$ où

$$\text{pour tout } x \in A, \text{ nous avons } f(x) = \sum_{k=1}^n a_k \mathbb{1}[x \in A_k].$$

L'intégrale de Lebesgue pour une fonction simple f est définie par

$$\int_A f(x) d\nu(x) := \sum_{k=1}^n a_k \nu(A_k).$$


De façon non formelle, lorsque nous avons une fonction simple $f : X \rightarrow \mathbb{R}$, l'intégrale de Lebesgue revient à sommer les aires des rectangles, avec pour "longueur" a_k et "largeur" $\nu(A_k)$.

Voici un exemple d'intégration avec la fonction simple précédente.

Exemple.

$$\int_A f(x) d\nu(x) = \underbrace{0.75 \cdot \nu([0.0, 0.25])}_{\clubsuit} + \underbrace{0.25 \cdot \nu([0.25, 0.5])}_{\diamond} + \underbrace{0.5 \cdot \nu([0.5, 0.75])}_{\spadesuit} + \underbrace{0.15 \cdot \nu([0.75, 1.0])}_{\heartsuit}$$

(où ν est la mesure de Lebesgue)



Maintenant que nous avons une intégrale pour les fonctions simples, nous pouvons les définir pour des fonctions plus générales qui sont les fonctions mesurables positives.


Définition 2.7. Soient un espace mesuré (X, Σ_X, ν) et $A \in \Sigma_X$, l'intégrale de Lebesgue pour une fonction $f : A \rightarrow \mathbb{R}^+$ mesurable (positive) est définie par

$$\int_A f(x) d\nu(x) := \sup \left\{ \int_A s(x) d\nu(x) \mid s \text{ fonction simple } f : A \rightarrow \mathbb{R} \text{ avec } 0 \leq s(x) \leq f(x) \text{ pour tout } x \in A \right\}.$$

En d'autres termes, l'intégrale de Lebesgue d'une fonction mesurable positive f est obtenue en approximant f par des fonctions simples s telles que $0 \leq s(x) \leq f(x)$ pour tout $x \in X$. L'intégrale de f est alors définie comme la borne supérieure des intégrales de ces fonctions simples s .

Voici une illustration de l'intégration d'une fonction mesurable utilisée dans un exemple précédent.

Exemple.



Malheureusement, l'intégrale est définie pour des fonctions mesurables positives. Ainsi, nous pouvons étendre la définition de l'intégrale de Lebesgue aux fonctions mesurables.


Définition 2.8. Soient un espace mesuré (X, Σ_X, ν) et $A \in \Sigma_X$, l'intégrale de Lebesgue pour une fonction $f : X \rightarrow \mathbb{R}$ mesurable est définie par

$$\int_A f(x) d\nu(x) := \int_A \max(0, f(x)) d\nu(x) - \int_A \max(0, -f(x)) d\nu(x).$$

L'idée est d'utiliser deux intégrales de Lebesgue sur deux fonctions mesurables positives $x \mapsto \max(0, f(x))$ et $x \mapsto \max(0, -f(x))$ et de soustraire la valeur de l'intégrale associée à $x \mapsto \max(0, -f(x))$.

Voici un exemple d'intégration pour une fonction mesurable.

Exemple.



Après avoir défini l'intégrale de Lebesgue pour une fonction mesurable, il est naturel de préciser la condition sous laquelle l'intégration se déroule correctement, c'est-à-dire lorsque l'intégrale prend une valeur finie.

Définition 2.9. Soit un espace mesuré (X, Σ_X, ν) et une fonction $f : X \rightarrow \mathbb{R}$ mesurable. Si

$$\int_X |f(x)| d\nu(x) < +\infty$$

alors la fonction f est dite *intégrable* (au sens de Lebesgue).

Nous pouvons également dériver les propriétés suivantes pour l'intégrale de Lebesgue.

Théorème 2.10. Soient un espace mesuré (X, Σ_X, ν) et $f : X \rightarrow \mathbb{R}$ et $g : X \rightarrow \mathbb{R}$ des fonctions intégrables,

1. pour tout $c \in \mathbb{R}$,

$$\int_X (c \cdot f(x)) d\nu(x) = c \cdot \int_X f(x) d\nu(x),$$

2. nous avons

$$\int_X (f(x) + g(x)) d\nu(x) = \int_X f(x) d\nu(x) + \int_X g(x) d\nu(x),$$

3. pour tout $A \in \Sigma_X$,

$$\int_X \mathbb{1}[x \in A] f(x) d\nu(x) = \int_A f(x) d\nu(x).$$

2.4 Espérance et probabilité

Espérance

Grâce à l'intégrale de Lebesgue, nous pouvons maintenant définir l'espérance.

Définition 2.11. Soit un espace probabilisé $(\Omega, \Sigma_\Omega, \mu)$, l'espérance de $\omega \mapsto f(\omega)$ est définie par

$$\mathbb{E}_{\omega \sim \mu} [f(\omega)] := \int_{\Omega} f(\omega) d\mu(\omega).$$

Grâce à la définition de l'espérance, nous pouvons dériver les propriétés suivantes qui sont directement issues de l'intégrale de Lebesgue.

Corollaire 2.12. Soient un espace probabilisé $(\Omega, \Sigma_\Omega, \mu)$ et $f, g : \Omega \rightarrow \mathbb{R}$ des fonctions intégrables,

1. pour tout $c \in \mathbb{R}$, nous avons

$$\mathbb{E}_{\omega \sim \mu} [c \cdot f(\omega)] = c \cdot \mathbb{E}_{\omega \sim \mu} [f(\omega)]$$

2. pour tout $c \in \mathbb{R}$, nous avons

$$\mathbb{E}_{\omega \sim \mu} [f(\omega) + g(\omega)] = \mathbb{E}_{\omega \sim \mu} [f(\omega)] + \mathbb{E}_{\omega \sim \mu} [g(\omega)]$$

Probabilité

De plus, grâce à l'espérance, nous pouvons également définir formellement une probabilité.

Définition 2.13. Soit un espace probabilisé $(\Omega, \Sigma_\Omega, \mu)$, la probabilité que $\omega \in A$ où $\omega \sim \mu$ est définie par

$$\mathbb{P}_{\omega \sim \mu} [\omega \in A] := \mathbb{E}_{\omega \sim \mu} \mathbb{1} [\omega \in A]$$

Enfin, nous pouvons relier une probabilité à sa mesure (grâce à la définition d'une probabilité et de l'espérance). Autrement dit, nous sommes maintenant prêts à prouver Proposition 1.12.

Soit $(\Omega, \Sigma_\Omega, \mu)$ un espace probabilisé. Nous avons

$$\mu(A) = \mathbb{P}_{\omega \sim \mu} [\omega \in A].$$

Démonstration. Grâce aux Définitions 2.13 et 2.11, nous avons

$$\begin{aligned} \mathbb{P}_{\omega \sim \mu} [\omega \in A] &= \mathbb{E}_{\omega \sim \mu} \mathbb{1} [\omega \in A] \\ &= \int_{\Omega} \mathbb{1} [\omega \in A] d\mu(\omega). \end{aligned}$$

De plus grâce à Théorème 2.10 (propriété 3) et Définition 2.6, nous avons

$$\begin{aligned} \mathbb{P}_{\omega \sim \mu} [\omega \in A] &= \int_{\Omega} \mathbb{1} [\omega \in A] d\mu(\omega) \\ &= \int_A 1 d\mu(\omega) \\ &= \mu(A). \end{aligned}$$

□

Chapitre 3

Propriétés de l'espérance

Introduction

Nous avons vu dans le chapitre précédent la définition de l'espérance et d'une probabilité. Nous allons donc voir différentes propriétés. Plus précisément, nous allons aller un peu plus loin que les propriétés naturelles du Théorème 2.10. En effet, nous allons voir des propriétés que l'on rencontre souvent en probabilités et statistiques.

Nous allons voir

- La dérivée de Radon-Nikodym
- Les variables aléatoires
- Indépendance
- Probabilités conditionnelles
- Variance et covariance

3.1 Dérivée de Radon-Nikodym

Mesure σ -finie

Lorsque l'on travaille avec des mesures de probabilité, il est fréquent de vouloir exprimer une mesure en termes d'une autre à l'aide d'une densité. La dérivée de Radon-Nikodym permet justement de formuler cette idée de manière rigoureuse. Pour introduire la notion de dérivée de Radon-Nikodym, nous avons besoin de rappeler certaines propriétés fondamentales des mesures. L'une d'elles est la notion de mesure σ -finie.

Définition 3.1. Soit un espace mesuré (X, Σ_X, ν) , la mesure ν est dite σ -finie s'il existe des ensembles $A_1, A_2, \dots \in \Sigma_X$ tels que $\bigcup_{n \in \mathbb{N}} A_n = X$ où nous avons

$$\forall n \in \mathbb{N}, \quad \nu(A_n) < +\infty.$$

Exemple 3.2. Voici trois exemples de mesure σ -finie :

- Une mesure de probabilité μ
- La mesure de Lebesgue sur $\mathbb{R}^d$
- La mesure de comptage (que l'on verra dans quelques instants)

Mesure absolument continue

Une autre notion importante pour définir la dérivée de Radon-Nikodym est l'absolue continuité d'une mesure par rapport à une autre qui est définie dans la définition suivante.

Définition 3.3. Soit un espace mesurable (X, Σ_X) où nous avons deux mesures $\nu_1 : \Sigma_X \rightarrow [0, +\infty]$ et $\nu_2 : \Sigma_X \rightarrow [0, +\infty]$. On dit que la mesure ν_1 est *absolument continue par rapport à* ν_2 (que l'on note $\nu_1 \ll \nu_2$) si

$$\forall A \in \Sigma_X, \quad \nu_2(A) = 0 \implies \nu_1(A) = 0.$$

Cela signifie intuitivement que si une mesure attribue une masse nulle à un ensemble, alors l'autre mesure en fait de même.

Densité

Nous sommes maintenant prêt à introduire la dérivée de Radon-Nikodym, *i.e.*, la densité d'une mesure de probabilité μ par rapport à une autre ν .

Définition 3.4. Soit un espace mesurable (Ω, Σ_Ω) où nous avons une mesure de probabilité $\mu : \Sigma_\Omega \rightarrow [0, 1]$ et une mesure σ -finie $\nu : \Sigma_\Omega \rightarrow [0, +\infty]$ tels que $\mu \ll \nu$. La mesure de probabilité μ possède une *densité* lorsque nous avons une fonction mesurable positive notée $d\mu/d\nu$ telle que

$$\forall A \in \Sigma_\Omega, \quad \mathbb{P}_{\omega \sim \mu} [\omega \in A] = \mathbb{E}_{\omega \sim \mu} [\mathbb{1}[\omega \in A]] = \int_{\Omega} \left(\mathbb{1}[\omega \in A] \frac{d\mu}{d\nu}(\omega) \right) d\nu(\omega),$$

où $\frac{d\mu}{d\nu}$ est appelé densité de μ par rapport à ν ou encore dérivée de Radon-Nikodym de μ par rapport à ν .

L'existence et l'unicité de cette fonction sont garanties par le théorème de Radon-Nikodym (non abordé ici). Ce résultat est fondamental en théorie des probabilités et permet de justifier la notion de densité de probabilité.

Fonction de masse

Nous pouvons maintenant définir des espérances sur des espaces finis ou dénombrable. Pour cela il faut définir la dérivée de Radon-Nikodym d'une mesure de probabilité μ en fonction de la mesure de comptage ν définie dans la définition suivante.

Définition 3.5 (Mesure de comptage). Soit l'espace probabilisable $(X, 2^X)$ où Ω est fini ou dénombrable. La mesure de comptage $\nu : 2^X \rightarrow [0, +\infty]$ est définie telle que

$$\forall A \in \Sigma_X, \quad \nu(A) = \begin{cases} |A| & \text{si } A \text{ est fini,} \\ +\infty & \text{si } A \text{ est infini.} \end{cases}$$

En d'autres mots, la mesure de comptage est un cas particulier de mesure qui attribue à chaque ensemble son nombre d'éléments.

Dans le cas où Ω est fini ou dénombrable, la dérivée de Radon-Nikodym devient ce que l'on appelle la fonction de masse.

Définition 3.6 (Fonction de masse). Soit (Ω, Σ_Ω) un espace mesurable avec un univers Ω fini ou dénombrable, où ν est la mesure de comptage et μ une mesure de probabilité tel que $\mu \ll \nu$. Alors $\frac{d\mu}{d\nu}(\omega)$ est appelée fonction de masse.

De plus, nous pouvons prouver la proposition suivante.

Proposition 3.7. Soit (Ω, Σ_Ω) un espace mesurable avec un univers Ω fini ou dénombrable, où ν est la mesure de comptage et μ une mesure de probabilité tel que $\mu \ll \nu$. Alors nous avons

$$\frac{d\mu}{d\nu}(\omega) = \mu(\{\omega\}).$$

Notation. Plus tard, nous notons $\mu(\omega) = \mu(\{\omega\})$.

Nous avons maintenant une expression plus explicite de l'espérance lorsque Ω est fini ou dénombrable.

Corollaire 3.8 (Espérance sur Ω fini ou dénombrable). Soit (Ω, Σ_Ω) un espace mesurable avec un univers Ω fini ou dénombrable, où ν est la mesure de comptage et μ une mesure de probabilité tel que $\mu \ll \nu$. Nous avons

$$\mathbb{E}_{\omega \sim \mu} [f(\omega)] = \sum_{\omega \in X} \mu(\omega) f(\omega).$$

En effet, comme nous pouvons le voir, l'espérance peut s'écrire comme une somme de $\omega \in \Omega$ pondérée par la valeur de la fonction $f(\omega)$ et la valeur de la fonction de masse $\mu(\omega)$. L'avantage de la fonction de masse est que l'on également définir plus intuitivement le passage de la mesure de probabilité μ_1 à μ_2 (que l'on appelle changement de mesure).

Corollaire 3.9 (Changement de mesure). Soit (Ω, Σ_Ω) un espace mesurable où Ω est fini ou dénombrable. Soient ν la mesure de comptage, μ_1 une mesure de probabilité où $\nu \ll \mu_1 \ll \nu$, et μ_2 une mesure de probabilité où $\mu_2 \ll \nu$. Nous avons

$$\mathbb{E}_{\omega \sim \mu_1} \left[\frac{\mu_2(\omega)}{\mu_1(\omega)} f(\omega) \right] = \mathbb{E}_{\omega \sim \mu_2} [f(\omega)].$$

Fonction de densité

Pour une mesure de probabilité définie sur un sous-ensemble de $\mathbb{R}^d$, il est souvent utile d'introduire une fonction de densité qui permet d'exprimer cette mesure en fonction de la mesure de Lebesgue.

Définition 3.10 (Fonction de densité). Soient (Ω, Σ_Ω) un espace mesurable où $\Omega \subseteq \mathbb{R}^d$, où ν est la mesure de Lebesgue et μ une mesure de probabilité. Alors $\frac{d\mu}{d\nu}(\omega)$ est appelée fonction de densité.

En d'autres termes, la fonction de densité permet de représenter la mesure μ en fonction de la mesure de Lebesgue. Cela permet de simplifier les calculs d'intégration, notamment pour l'espérance.

Notation. Plus tard, nous notons $\mu(\omega) = \frac{d\mu}{d\nu}(\omega)$.

Une des conséquences directes de cette définition est que l'espérance mathématique d'une fonction f sous une mesure μ peut être calculée sous forme d'une intégrale par rapport à la mesure de Lebesgue.

Corollaire 3.11 (Espérance sur $\Omega \subseteq \mathbb{R}^d$). Soient (Ω, Σ_Ω) un espace mesurable avec $\Omega \subseteq \mathbb{R}^d$, où ν est la mesure de Lebesgue et μ est une mesure de probabilité telle que $\mu \ll \nu$. Nous avons

$$\begin{aligned} \mathbb{E}_{\omega \sim \mu} [f(\omega)] &= \int_X \mu(\omega) f(\omega) d\nu(\omega) \\ &= \int_X \mu(\omega) f(\omega) d\omega. \end{aligned}$$

Une autre propriété importante des densités de probabilité est qu'elles permettent de changer de mesure de probabilité.

Corollaire 3.12 (Changement de mesure). Soit (Ω, Σ_Ω) un espace mesurable où $\Omega \subseteq \mathbb{R}^d$. Soient ν la mesure de Lebesgue, μ_1 une mesure de probabilité où $\nu \ll \mu_1 \ll \nu$, et μ_2 une mesure de probabilité où $\mu_2 \ll \nu$. Nous avons

$$\mathbb{E}_{\omega \sim \mu_1} \left[\frac{\mu_2(\omega)}{\mu_1(\omega)} f(\omega) \right] = \mathbb{E}_{\omega \sim \mu_2} [f(\omega)].$$

Changement de mesure (le cas général)

Dans le cas général, lorsque nous avons une mesure de référence (comme la mesure de comptage ou la mesure de Lebesgue), nous prenons le raccourci de notation $\frac{d\mu_1}{d\nu}(\omega) = \mu_1(\omega)$ et $\frac{d\mu_2}{d\nu}(\omega) = \mu_2(\omega)$ et nous avons le changement de mesure suivant (généralisant les deux précédents).

Corollaire 3.13. Soit (Ω, Σ_Ω) un espace mesurable. Soient ν une mesure de référence sur Ω , μ_1 une mesure de probabilité où $\nu \ll \mu_1 \ll \nu$, et μ_2 une mesure de probabilité où $\mu_2 \ll \nu$. Nous avons

$$\mathbb{E}_{\omega \sim \mu_1} \left[\frac{\mu_2(\omega)}{\mu_1(\omega)} f(\omega) \right] = \mathbb{E}_{\omega \sim \mu_2} [f(\omega)].$$

Dans le cas où nous n'avons pas de mesure de références, nous avons le résultat suivant.

Corollaire 3.14. Soient (Ω, Σ_Ω) un espace mesuré où μ_1 et μ_2 sont deux mesures de probabilité telles que $\mu_2 \ll \mu_1$. Nous avons

$$\mathbb{E}_{\omega \sim \mu_1} \left[\frac{d\mu_2}{d\mu_1}(\omega) f(\omega) \right] = \mathbb{E}_{\omega \sim \mu_2} [f(\omega)].$$

3.2 Variable aléatoire

Définition

Définition 3.15. Soit $(\Omega, \Sigma_\Omega, \mu)$ un espace probabilisé, et (E, Σ_E) est un espace mesurable. Une *variable aléatoire* est une fonction mesurable $f : \Omega \rightarrow E$.

Exemple. Voici trois exemples de variable aléatoire :

- Si $(E, \Sigma_E) = (\mathbb{R}, \text{Borel}(\mathbb{R}))$ alors f est une variable aléatoire réelle.
- Si E est un ensemble fini ou dénombrable alors f est une variable aléatoire discrète.
- La fonction $f : \omega \mapsto \omega$ (où $E = \Omega$) est une variable aléatoire.

Voici un exemple concret de variable aléatoire réelle.

Exemple. Soit $\Omega = \{\square, \square, \square, \square, \square, \square, \square, \square, \square, \square, \square, \square, \square, \square, \square, \square\}$.
La variable aléatoire $f : \Omega \rightarrow \mathbb{R}$ suivante donne la valeur du dé :

	$\mapsto$	1
	$\mapsto$	2
	$\mapsto$	3
	$\mapsto$	4
	$\mapsto$	5
	$\mapsto$	6
	$\mapsto$	1
	$\mapsto$	2
	$\mapsto$	3
	$\mapsto$	4
	$\mapsto$	5
	$\mapsto$	6

Grâce à cette variable aléatoire, nous avons par exemple :

$$\mathbb{P}_{\omega \sim \mu} [f(\omega) \in \{1, 2\}] = \mathbb{P}_{\omega \sim \mu} [\omega \in \{\square, \square, \square, \square\}].$$

Etant donné que ω peut être vu comme une variable aléatoire, nous allons souvent utiliser la notation suivante pour définir une variable aléatoire.

Définition 3.16. On dit que $\omega \sim \mu$, qui se lit “ ω suit la loi / distribution μ sur Ω ”, si nous avons un espace probabilisé $(\Omega, \Sigma_\Omega, \mu)$.

Cette notation est (je l'espère) intuitive : on peut voir ω comme le fruit d'une réalisation d'une expérience aléatoire. Autrement dit, si on imagine μ comme un “chapeau magique”, alors ω est un résultat sorti de ce “chapeau magique”.

Notation. Lorsque nous écrivons $\omega \sim \mu$, où μ est une distribution sur Ω , nous considérerons que tout se passe bien pour définir la tribu Σ_Ω .

Lorsque nous avons une fonction (mesurable) f , nous pouvons définir une autre mesure de probabilité μ_f qui correspond à la loi de probabilité pour f .

Définition 3.17. Soit une variable aléatoire $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω et $f : \Omega \rightarrow \Omega'$ une variable aléatoire. Nous pouvons définir la mesure de probabilité μ_f sur Ω' associée à f de la façon suivante :

$$\begin{aligned}\mu_f(A) &:= \mathbb{P}_{f(\omega) \sim \mu_f} [f(\omega) \in A] \\ &:= \mathbb{P}_{\omega \sim \mu} [\omega \in f^{-1}(A)].\end{aligned}$$

Ainsi, nous avons le corollaire suivant.

Corollaire 3.18. Si nous avons $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω et $f : \Omega \rightarrow \Omega'$ une variable aléatoire. alors nous avons $f(\omega) \sim \mu_f$.

Théorème de transfert

Le théorème de transfert permet de transférer l'intégration de Ω vers Ω' . En effet, nous avons le résultat suivant.

Proposition 3.19 (théorème de transfert). Soient $\omega \sim \mu$, $f(\omega) \sim \mu_f$ et $g : \Omega' \rightarrow \mathbb{R}$ une fonction mesurable alors nous avons

$$\mathbb{E}_{\omega \sim \mu} [g(f(\omega))] = \mathbb{E}_{f(\omega) \sim \mu_f} [g(f(\omega))].$$

3.3 Indépendance et théorèmes de Fubini

Nous allons maintenant voir la notion d'indépendance qui est fondamentale en théorie des probabilités et statistiques. Pour cela, nous allons (encore) avoir besoin d'une notion venant de la théorie de la mesure : les tribus et les mesures produits.

Tribus et mesures produits

Afin de définir une mesure produit, nous avons besoin de définir la tribu produit.

Définition 3.20. Soient $(\Omega_1, \Sigma_{\Omega_1})$ et $(\Omega_2, \Sigma_{\Omega_2})$ deux espaces probabilisables, la *tribu produit* est définie par

$$\Sigma_{\Omega_1} \otimes \Sigma_{\Omega_2} := \sigma(\{A_1 \times A_2 \mid A_1 \in \Sigma_{\Omega_1}, A_2 \in \Sigma_{\Omega_2}\}),$$

où $\sigma(A)$ est la tribu engendrée par l'ensemble A .

Nous sommes maintenant prêts à définir la mesure produit.

Définition 3.21. Une *mesure produit* $\mu_1 \otimes \mu_2$ est une mesure sur l'espace probabilisable $(\Omega_1 \times \Omega_2, \Sigma_{\Omega_1} \otimes \Sigma_{\Omega_2})$. Elle est définie par

$$\mu_1 \otimes \mu_2(A_1 \times A_2) := \mu_1(A_1) \mu_2(A_2).$$

Variables aléatoires indépendantes

Grâce aux mesures produits, nous sommes (enfin) capable de définir l'indépendance dans les variables aléatoires.

Définition 3.22. Soient $\omega = (\omega_1, \omega_2) \sim \mu$, on dit que ω_1 et ω_2 sont indépendants si $\mu = \mu_1 \otimes \mu_2$ où $\omega_1 \sim \mu_1$ et $\omega_2 \sim \mu_2$.

Ainsi, grâce à la définition de l'indépendance et la définition d'une mesure, nous avons le corollaire suivant.

Corollaire 3.23. Si ω_1 et ω_2 sont indépendant si et seulement si

$$\mathbb{P}_{(\omega_1, \omega_2) \sim \mu} [\omega_1 \in A_1, \omega_2 \in A_2] = \mathbb{P}_{\omega_1 \sim \mu_1} [\omega_1 \in A_1] \mathbb{P}_{\omega_2 \sim \mu_2} [\omega_2 \in A_2]$$

Voici un exemple de variables aléatoires dépendantes.

Exemple. Soient

- ω_1 le résultat d'un dé à 6 faces,
- $\omega_2 = \omega_1 + 1$.

Alors, nous avons :

$$\begin{aligned} \mathbb{P}_{(\omega_1, \omega_2) \sim \mu} [\omega_1 = 1 \text{ et } \omega_2 = 3] &= 0, \\ \mathbb{P}_{(\omega_1, \omega_2) \sim \mu} [\omega_1 = 1] &= \frac{1}{6}, \\ \text{et } \mathbb{P}_{(\omega_1, \omega_2) \sim \mu} [\omega_2 = 3] &= \frac{1}{6}, \end{aligned}$$

Voici un exemple de variables aléatoires indépendantes.

Exemple. Soient

- ω_1 le résultat d'un lancer de dé à 6 faces,
- ω_2 le résultat d'un deuxième lancer de dé à 6 faces.

Théorème de Fubini-Tonelli

L'avantage d'avoir des variables indépendantes est que l'on peut ensuite intervertir leurs espérances. Ceci peut être effectuée grâce à l'un des deux théorèmes de Fubini.

Théorème 3.24. Soient $(\Omega_1, \Sigma_{\Omega_1}, \mu_1)$ et $(\Omega_2, \Sigma_{\Omega_2}, \mu_2)$ deux espaces probabilisés. Soient $(\Omega_1 \times \Omega_2, \Sigma_{\Omega_1} \otimes \Sigma_{\Omega_2}, \mu_1 \otimes \mu_2)$ un espace probabilisable muni de la mesure produit et $f : \Omega_1 \times \Omega_2 \rightarrow [0, +\infty]$ est une fonction mesurable alors

$$\begin{aligned} \mathbb{E}_{(\omega_1, \omega_2) \sim \mu_1 \otimes \mu_2} [f(\omega_1, \omega_2)] &= \mathbb{E}_{\omega_1 \sim \mu_1} \left[\mathbb{E}_{\omega_2 \sim \mu_2} [f(\omega_1, \omega_2)] \right] \\ &= \mathbb{E}_{\omega_2 \sim \mu_2} \left[\mathbb{E}_{\omega_1 \sim \mu_1} [f(\omega_1, \omega_2)] \right]. \end{aligned}$$

Théorème de Fubini-Lebesgue

Théorème 3.25. Soient $(\Omega_1, \Sigma_{\Omega_1}, \mu_1)$ et $(\Omega_2, \Sigma_{\Omega_2}, \mu_2)$ deux espaces probabilisés. Soient $(\Omega_1 \times \Omega_2, \Sigma_{\Omega_1} \otimes \Sigma_{\Omega_2}, \mu_1 \otimes \mu_2)$ un espace probabilisable muni de la mesure produit. Si $f : \Omega_1 \times \Omega_2 \rightarrow \mathbb{R}$ est intégrable, c'est à dire si

$$\mathbb{E}_{(\omega_1, \omega_2) \sim \mu_1 \otimes \mu_2} [|f(\omega_1, \omega_2)|] < +\infty$$

alors nous avons

$$\begin{aligned} \mathbb{E}_{(\omega_1, \omega_2) \sim \mu_1 \otimes \mu_2} [f(\omega_1, \omega_2)] &= \mathbb{E}_{\omega_1 \sim \mu_1} \left[\mathbb{E}_{\omega_2 \sim \mu_2} [f(\omega_1, \omega_2)] \right] \\ &= \mathbb{E}_{\omega_2 \sim \mu_2} \left[\mathbb{E}_{\omega_1 \sim \mu_1} [f(\omega_1, \omega_2)] \right]. \end{aligned}$$


Événements indépendants

Enfin, il existe une notion d'indépendance qui n'est pas sur les variables aléatoires mais sur les événements.

Définition 3.26. Soit $\omega \sim \mu$ où μ est une distribution sur Ω , deux événements $A \in \Sigma_\Omega$ et $B \in \Sigma_\Omega$ sont *indépendants* si et seulement si

$$\mathbb{P}_{\omega \sim \mu} [\omega \in A \cap B] = \mathbb{P}_{\omega \sim \mu} [\omega \in A] \cdot \mathbb{P}_{\omega \sim \mu} [\omega \in B].$$

Exemple. Nous pouvons (facilement) représenter graphiquement deux événements indépendants.



3.4 Probabilités conditionnelles

La probabilité conditionnelle correspond au calcul de nouvelles probabilités, en supposant que l'on apprenne qu'un événement B s'est réalisé ou va se réaliser. On suppose que l'événement B est compatible avec notre ensemble de mondes possibles. Dit autrement, l'événement B est probable, c'est-à-dire que $\mathbb{P}_{\omega \sim \mu} [\omega \in B] > 0$.


Définition 3.27. Soit $(\Omega, \Sigma_\Omega, \mu)$ un espace probabilisé, i.e., $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω . Soit $B \in \Sigma_\Omega$ avec $\mathbb{P}_{\omega \sim \mu} [\omega \in B] > 0$, on note la *probabilité (conditionnelle)* de $A \in \Sigma_\Omega$ étant donné B par

$$\mathbb{P}_{\omega \sim \mu} [\omega \in A \mid B] := \frac{\mathbb{P}_{\omega \sim \mu} [\omega \in A \cap B]}{\mathbb{P}_{\omega \sim \mu} [\omega \in B]}.$$

La notation $\mathbb{P}_{x \sim \mu} [x \in A \mid B]$, bien que classique, est un peu ambiguë, car $A \mid B$ ne désigne pas un événement !

Comme le montre le schéma ci-dessous, cela revient à considérer que le nouvel ensemble Ω est maintenant B , et de normaliser la mesure de probabilité par $\mathbb{P}_{\omega \sim \mu} [\omega \in B]$.

Exemple.



La probabilité conditionnelle permet en réalité de définir une nouvelle mesure de probabilité !

Proposition 3.28. Soit $(\Omega, \Sigma_\Omega, \mu)$ un espace probabilisé, i.e., $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω .

Soit $B \in \Sigma_\Omega$ avec $\mathbb{P}_{\omega \sim \mu} [\omega \in B] > 0$, alors notons

$$\mu_B(\cdot) := \mathbb{P}_{\omega \sim \mu} [\omega \in \cdot \mid B],$$

et $(\Omega, \Sigma_\Omega, \mu_B)$ est un espace probabilisé, i.e., μ_B est une mesure de probabilité sur Ω .

Ainsi, nous pouvons réécrire la probabilité conditionnelle de la façon suivante.

Corollaire 3.29. Soit $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω . Soit $B \in \Sigma_\Omega$ avec $\mathbb{P}_{\omega \sim \mu} [\omega \in B] > 0$, nous avons

$$\forall A \in \Sigma_\Omega, \quad \mathbb{P}_{\omega \sim \mu_B} [\omega \in A] = \frac{\mathbb{P}_{\omega \sim \mu} [\omega \in A \cap B]}{\mathbb{P}_{\omega \sim \mu} [\omega \in B]}.$$

Propriétés

Les probabilités conditionnelles nous permettent de dériver des propriétés assez naturelles (et pour certaine, très connues).

Proposition 3.30. Soit $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω . Si $A \in \Sigma_\Omega$ et $B \in \Sigma_\Omega$ sont deux événements indépendants, alors

$$\mathbb{P}_{\omega \sim \mu_B} [\omega \in A] = \mathbb{P}_{\omega \sim \mu} [\omega \in A].$$

Proposition 3.31 (règle du produit). Soit $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω . Soit $A \in \Sigma_\Omega$ et $B \in \Sigma_\Omega$ avec $\mathbb{P}_{\omega \sim \mu} [\omega \in A] > 0$ et $\mathbb{P}_{\omega \sim \mu} [\omega \in B] > 0$, alors nous avons

$$\mathbb{P}_{\omega \sim \mu} [\omega \in A \cap B] = \mathbb{P}_{\omega \sim \mu_B} [\omega \in A] \cdot \mathbb{P}_{\omega \sim \mu} [\omega \in B] = \mathbb{P}_{\omega \sim \mu_A} [\omega \in B] \cdot \mathbb{P}_{\omega \sim \mu} [\omega \in A].$$

Théorème 3.32 (formule de Bayes). Soit $\omega \sim \mu$ où μ est une mesure de probabilité sur Ω . Soit $A \in \Sigma_\Omega$ et $B \in \Sigma_\Omega$ avec $\mathbb{P}_{\omega \sim \mu} [\omega \in A] > 0$ et $\mathbb{P}_{\omega \sim \mu} [\omega \in B] > 0$. Nous avons

$$\begin{aligned} \mathbb{P}_{\omega \sim \mu_B} [\omega \in A] &= \frac{\mathbb{P}_{\omega \sim \mu} [\omega \in A]}{\mathbb{P}_{\omega \sim \mu} [\omega \in B]} \mathbb{P}_{\omega \sim \mu_A} [\omega \in B] \\ \iff \mathbb{P}_{\omega \sim \mu_B} [\omega \in A] \cdot \mathbb{P}_{\omega \sim \mu} [\omega \in B] &= \mathbb{P}_{\omega \sim \mu_A} [\omega \in B] \cdot \mathbb{P}_{\omega \sim \mu} [\omega \in A]. \end{aligned}$$

3.5 Variance

L'objectif est de mesurer l'écart par rapport à l'espérance. La variance est définie comme l'espérance des écarts au carré par rapport à la moyenne.

Définition

La variance de $f(\omega)$ où $\omega \sim \mu$ et $f : \Omega \rightarrow \mathbb{R}$ n'est définie que lorsque $f(\omega)^2$ est intégrable.

Définition 3.33. $f(\omega)$ où $\omega \sim \mu$ admet un moment d'ordre 2 si $f(\omega)^2$ est intégrable, i.e., si $\mathbb{E}_{\omega \sim \mu} [f(\omega)^2] < +\infty$.

Nous pouvons maintenant définir la variance d'une variable aléatoire $f(\omega)$ où $\omega \sim \mu$.

Définition 3.34. Si $f(\omega)$ admet un moment d'ordre 2, la variance de f est

$$\mathbb{V}_{\omega \sim \mu} [f(\omega)] := \mathbb{E}_{\omega \sim \mu} \left[\left(f(\omega) - \mathbb{E}_{\omega' \sim \mu} [f(\omega')] \right)^2 \right].$$

De plus, la variance est liée à une autre notion : l'écart-type.

Définition 3.35. L'écart-type est $\sqrt{\mathbb{V}_{\omega \sim \mu} [f(\omega)]}$.

Propriétés

Nous pouvons également obtenir les deux propriétés suivantes.

Proposition 3.36 (formule de König-Huygens). $\mathbb{V}_{\omega \sim \mu} [f(\omega)] = \mathbb{E}_{\omega \sim \mu} [f(\omega)^2] - (\mathbb{E}_{\omega \sim \mu} [f(\omega)])^2$.

Proposition 3.37. $\mathbb{V}_{\omega \sim \mu} [af(\omega) + b] = a^2 \mathbb{V}_{\omega \sim \mu} [f(\omega)]$.

Covariance

On cherche à mesurer si deux variables $f_1(\omega_1)$ et $f_2(\omega_2)$ sont corrélées, c'est-à-dire si un écart de $f_1(\omega_1)$ à sa moyenne, se traduit aussi par un écart de $f_2(\omega_2)$ à sa moyenne. Pour mesurer la corrélation, on définit la covariance comme l'espérance du produit des écarts.

Définition 3.38 (covariance). La covariance est

$$\text{cov}_{(\omega_1, \omega_2) \sim \mu} (f_1(\omega_1), f_2(\omega_2)) := \mathbb{E}_{(\omega_1, \omega_2) \sim \mu} \left(\left(f_1(\omega_1) - \mathbb{E}_{(\omega'_1, \omega'_2) \sim \mu} [f_2(\omega'_2)] \right) \left(f_2(\omega_2) - \mathbb{E}_{(\omega'_1, \omega'_2) \sim \mu} [f_2(\omega'_2)] \right) \right).$$

Propriétés

Nous pouvons également obtenir les deux propriétés suivantes.

Proposition 3.39 (formule de König-Huygens).

$$\text{cov}_{(\omega_1, \omega_2) \sim \mu} (f_1(\omega_1), f_2(\omega_2)) = \mathbb{E}_{(\omega_1, \omega_2) \sim \mu} [f_1(\omega_1) f_2(\omega_2)] - \mathbb{E}_{(\omega_1, \omega_2) \sim \mu} [f_1(\omega_1)] \mathbb{E}_{(\omega_1, \omega_2) \sim \mu} [f_2(\omega_2)].$$

Définition 3.40. $f_1(\omega_1)$ et $f_2(\omega_2)$ sont *corrélées* si $\text{cov}_{(\omega_1, \omega_2) \sim \mu} (f_1(\omega_1), f_2(\omega_2)) \neq 0$.
 $f_1(\omega_1)$ et $f_2(\omega_2)$ sont *corrélées positivement* si $\text{cov}_{(\omega_1, \omega_2) \sim \mu} (f_1(\omega_1), f_2(\omega_2)) > 0$.
 $f_1(\omega_1)$ et $f_2(\omega_2)$ sont *corrélées négativement* si $\text{cov}_{(\omega_1, \omega_2) \sim \mu} (f_1(\omega_1), f_2(\omega_2)) < 0$.

Proposition 3.41. $f_1(\omega_1)$ et $f_2(\omega_2)$ indépendantes *implique* que $\text{cov}_{(\omega_1, \omega_2) \sim \mu} (f_1(\omega_1), f_2(\omega_2)) = 0$.

Chapitre 4

Lois

4.1 Lois discrètes

Loi de Dirac

Nous allons tout d'abord voir la loi (ou distribution) de Dirac. C'est la distribution la plus simple qui correspond à ne pas avoir d'aléatoire.

Définition 4.1. ω suit une *loi de Dirac*, notée δ_a , en a , c'est-à-dire que $\omega \sim \delta_a$, si

$$\mathbb{P}_{\omega \sim \delta_a} [\omega = a] = 1.$$


Loi de Bernoulli

Une loi de Bernoulli $\mathcal{B}(p)$ modélise le lancer d'une pièce pipée où il y a une probabilité p de faire pile, et $1 - p$ de faire face. Pile est comptabilisé comme 1 (succès ✓ de faire pile), et face comme 0 (échec ✗ de faire pile).

Définition 4.2. Soit $p \in [0, 1]$, ω suit une *loi de Bernoulli*, notée $\mathcal{B}(p)$, c'est-à-dire que $\omega \sim \mathcal{B}(p)$, si

$$\underbrace{\mathbb{P}_{\omega \sim \mathcal{B}(p)} [\omega = 1] = p}_{\checkmark \text{ succès}} \quad \text{et} \quad \underbrace{\mathbb{P}_{\omega \sim \mathcal{B}(p)} [\omega = 0] = 1 - p}_{\times \text{ échec}}.$$

Exemple. Fonction de masse de la loi de Bernoulli $\mathcal{B}(0.4)$.



Nous pouvons déduire les propriétés suivantes pour la loi de Bernoulli.

Proposition 4.3. Soit $\omega \sim \mathcal{B}(p)$ avec $p \in [0, 1]$. Nous avons


$$\mathbb{E}_{\omega \sim \mathcal{B}(p)} [\omega] = p.$$

Proposition 4.4. Soit $\omega \sim \mathcal{B}(p)$ avec $p \in [0, 1]$. Nous avons

$$\mathbb{V}_{\omega \sim \mathcal{B}(p)} [\omega] = p(1 - p).$$

Loi binomiale

Une loi binomiale $\mathcal{B}(n, p)$ correspond au nombre de succès ✓ sur n essais. Dit autrement, c'est le nombre de fois que l'on a obtenu pile avec une pièce, lancée n fois, et toujours avec probabilité p de faire pile sur un lancer.



Définition 4.5. Soit $p \in [0, 1]$ et $n \in \mathbb{N}_*$, $\mathcal{B}(n, p)$ est la loi de $N(\omega_1, \dots, \omega_n) = \omega_1 + \dots + \omega_n$ où les $\omega_i \sim \mathcal{B}(p)$ sont *i.i.d.*.

Remarque 4.6. On voit que $\mathcal{B}(1, p) = \mathcal{B}(p)$.


Les lancers sont bien indépendants. Hors de question, par exemple que pour le 5e lancer, on recopie la valeur obtenue au 4e lancer ; les 4e et 5e lancers sont indépendants, c'est-à-dire qu'il faut bien relancer la pièce. Aussi, le résultat du 4e lancer n'influence pas du tout le résultat du 5e lancer. Nous pouvons également trouver l'expression de $\mathbb{P}_{N \sim \mathcal{B}(n, p)}[N = k]$.

Proposition 4.7. Si $N \sim \mathcal{B}(n, p)$ avec $p \in [0, 1]$ et $n \in \mathbb{N}_*$, alors pour tout $k \in \{0, \dots, n\}$ nous avons

$$\mathbb{P}_{N \sim \mathcal{B}(n, p)}[N = k] = \overbrace{\binom{n}{k}}^{\text{Façons de placer } k \text{ } \checkmark \text{ dans } n \text{ essais}} \cdot \underbrace{p^k \cdot (1-p)^{n-k}}_{\text{proba. d'avoir } k \text{ } \checkmark \text{ et } n-k \text{ } \times}$$

Du coup, $p^k(1-p)^{n-k}$ est la probabilité d'avoir $k \checkmark$ et $n-k \times$. $\binom{n}{k}$ est le nombre de sous-ensemble de cardinal k , c'est-à-dire le nombre de façons de placer ces k piles.

Exemple. Fonctions de masse des lois binomiales $\mathcal{B}(20, 0.4)$, $\mathcal{B}(40, 0.4)$, et $\mathcal{B}(40, 0.9)$.



Nous pouvons dériver les propriétés suivantes pour la loi binomiale.

Proposition 4.8. Soit $N \sim \mathcal{B}(n, p)$ avec $p \in [0, 1]$ et $n \in \mathbb{N}_*$. Nous avons

$$\mathbb{E}_{N \sim \mathcal{B}(n, p)}[N] = np.$$

Proposition 4.9. Soit $N \sim \mathcal{B}(n, p)$ avec $p \in [0, 1]$ et $n \in \mathbb{N}_*$. Nous avons

$$\mathbb{V}_{N \sim \mathcal{B}(n, p)}[N] = np(1-p).$$

Loi géométrique

La loi géométrique correspond au *nombre d'essais jusqu'à un succès* (essai avec succès compris). Par exemple, elle permet de calculer le nombre de lancers de pièce jusqu'à avoir pile (où nous avons par exemple 7 échecs $\times \times \times \times \times \times \times$ suivis d'un succès $\checkmark$).

Définition 4.10. Soit $p \in [0, 1]$, $\mathcal{G}(p)$ est la loi de $T(\omega_1, \dots) = \min(\{k \in \mathbb{N}^* \mid \omega_k = 1\})$ où $\omega_1, \omega_2, \dots \sim \mathcal{B}(p)$.


Nous pouvons en déduire l'expression suivante.

Proposition 4.11. Si $T \sim \mathcal{G}(p)$ avec $p \in [0, 1]$, alors nous avons

$$\forall k \in \mathbb{N}^*, \quad \mathbb{P}_{T \sim \mathcal{G}(p)}[T = k] = \mathbb{P}_{\omega_1, \dots \sim \mathcal{B}(p)}[T(\omega_1, \dots) = k] = \underbrace{(1-p)^{k-1}p}_{\text{proba. d'avoir } k \text{ } \checkmark \text{ puis un } \times},$$

où $T(\omega_1, \dots) = \min(\{k \in \mathbb{N}^* \mid \omega_k = 1\})$.

Exemple. Fonctions de masse des lois géométrique $\mathcal{G}(0.9)$, $\mathcal{G}(0.2)$.



Nous avons plusieurs propriétés que nous pouvons établir.

Proposition 4.12. Soit $T \sim \mathcal{G}(p)$ avec $p \in [0, 1]$. Nous avons

$$\mathbb{E}_{T \sim \mathcal{G}(p)}[T] = \sum_{k \in \mathbb{N}^*} \mathbb{P}_{T \sim \mathcal{G}(p)}[T = k] \cdot k = \frac{1}{p}.$$

Proposition 4.13. Soit $T \sim \mathcal{G}(p)$ avec $p \in [0, 1]$. Nous avons

$$\mathbb{V}_{T \sim \mathcal{G}(p)}[T] = \frac{(1-p)}{p^2}.$$

Proposition 4.14. Soit $T \sim \mathcal{G}(p)$ avec $p \in [0, 1]$. Nous avons

$$\forall k \in \mathbb{N}^*, \quad \mathbb{P}_{T \sim \mathcal{G}(p)}[T > k] = (1-p)^k.$$

Proposition 4.15 (sans mémoire). Soit $T \sim \mathcal{G}(p)$ avec $p \in [0, 1]$. Nous avons

$$\forall s, t \in \mathbb{N}, \quad \mathbb{P}_{T \sim \mathcal{G}(p)}[T > s+t \mid T > s] = \mathbb{P}_{T \sim \mathcal{G}(p)}[T > t].$$

Loi de Poisson

Si, dans la loi binomiale, p est très petit, et n grand, et en posant $\lambda = pn \in \mathbb{R}$, nous obtenons alors la loi de Poisson. En effet, nous avons


$$\begin{aligned} \mathbb{P}_{N \sim \mathcal{B}(n,p)}[N = k] &= \binom{n}{k} p^k (1-p)^{n-k} = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\ &= \frac{\lambda^k}{k!} \left(1 - \frac{\lambda}{n}\right)^n \frac{n! (1 - \frac{\lambda}{n})^{-k}}{(n-k)! n^k} \xrightarrow{n \rightarrow +\infty} \frac{\lambda^k}{k!} e^{-\lambda}. \end{aligned}$$

Définition 4.16. Si $N \sim \mathcal{P}(\lambda)$ avec $\lambda \in \mathbb{R}$, alors nous avons

$$\mathbb{P}_{N \sim \mathcal{P}(\lambda)}[N = k] = \frac{\lambda^k}{k!} e^{-\lambda}.$$

La loi de Poisson est utilisée pour modéliser des événements rares.

Exemple. Fonctions de masse des lois de Poisson $\mathcal{P}(1)$ et $\mathcal{P}(10)$.



Nous pouvons déterminer l'espérance et la variance d'une variable aléatoire N suivant une loi de Poisson.

Proposition 4.17. Soit $N \sim \mathcal{P}(\lambda)$ avec $\lambda \in \mathbb{R}$. Nous avons

$$\begin{aligned} \mathbb{E}_{N \sim \mathcal{P}(\lambda)}[N] &= \sum_{k \in \mathbb{N}^*} k e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \lambda e^{-\lambda} e^{\lambda} \\ &= \lambda. \end{aligned}$$

Proposition 4.18. Soit $N \sim \mathcal{P}(\lambda)$ avec $\lambda \in \mathbb{R}$. Nous avons

$$\mathbb{V}_{N \sim \mathcal{P}(\lambda)}[N] = \lambda.$$


4.2 Lois continues (à densité)

Lois uniformes

Voici l'une des lois continues les plus simples que nous avons rencontrées dans le Chapitre 1.

Définition 4.19. Soit $a < b$ avec $a, b \in \mathbb{R}$. La loi uniforme $\mathcal{U}(a, b)$ est de densité $\mathcal{U}_{a,b}(x) = \frac{1}{b-a} \mathbb{1}[x \in [a, b]]$.

Exemple. Fonction de densité $\mathcal{U}_{1,2}$ de la loi uniforme $\mathcal{U}(1, 2)$.




Loi exponentielle

Les lois exponentielles modélisent des *temps d'attente continus jusqu'à un succès*. Elles sont le pendant continu des lois géométriques.

Définition 4.20. La loi exponentielle $\mathcal{E}(\lambda)$ avec $\lambda \in \mathbb{R}$ est de densité $\mathcal{E}_\lambda(x) = \lambda e^{-\lambda \cdot x} \mathbb{1}[x \in \mathbb{R}^+]$.

Exemple. Fonctions de densité $\mathcal{E}_\lambda$ des lois exponentielles $\mathcal{E}(1)$ et $\mathcal{E}(1.5)$.



Voici l'espérance et la variance d'une variable aléatoire $T \sim \mathcal{E}(\lambda)$ suivant une loi exponentielle.

Proposition 4.21. Soit $T \sim \mathcal{E}(\lambda)$ avec $\lambda \in \mathbb{R}$. Nous avons

$$\mathbb{E}_{T \sim \mathcal{E}(\lambda)}[T] = \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

Proposition 4.22. Soit $T \sim \mathcal{E}(\lambda)$ avec $\lambda \in \mathbb{R}$. Nous avons

$$\mathbb{V}_{T \sim \mathcal{E}(\lambda)}[T] = \frac{1}{\lambda^2}$$

Voici deux autres propriétés (similaires à celles de la loi géométrique).

Proposition 4.23. Soit $T \sim \mathcal{E}(\lambda)$ avec $\lambda \in \mathbb{R}$. Nous avons

$$\forall s \in \mathbb{R}^+, \quad \mathbb{P}_{T \sim \mathcal{E}(\lambda)}[T > s] = e^{-\lambda s}.$$

Proposition 4.24 (sans mémoire). Soit $T \sim \mathcal{E}(\lambda)$ avec $\lambda \in \mathbb{R}$. Nous avons

$$\forall s, t \in \mathbb{R}^+, \quad \mathbb{P}_{T \sim \mathcal{E}(\lambda)}[T > s + t \mid T > s] = \mathbb{P}_{T \sim \mathcal{E}(\lambda)}[T > t].$$

Lois normales


Voici l'une des lois les plus connues des probabilités/statistiques : la loi normale.

Définition 4.25. Soit $\mu \in \mathbb{R}$ et $\sigma > 0$, la loi normale $\mathcal{N}(\mu, \sigma^2)$ est de densité

$$\mathcal{N}_{\mu, \sigma^2}(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2}.$$

Définition 4.26. La loi normale centrée réduite est la loi $\mathcal{N}(0, 1)$.

Exemple. Fonctions de densité $\mathcal{N}_{\mu, \sigma^2}$ des lois normales $\mathcal{N}(0, 1)$ et $\mathcal{N}(2.0, 0.5)$.



On peut passer d'une loi normale centrée réduite à n'importe quelle loi normale : on multiplie par l'écart-type σ puis on ajoute la moyenne μ .

Proposition 4.27. Soit $\mu \in \mathbb{R}$ et $\sigma > 0$, alors

1. si $\omega \sim \mathcal{N}(0, 1)$ alors nous avons $\mu + \sigma \cdot \omega \sim \mathcal{N}(\mu, \sigma^2)$,
2. si $\omega \sim \mathcal{N}(\mu, \sigma^2)$ alors $\frac{\omega - \mu}{\sigma} \sim \mathcal{N}(0, 1)$.

En d'autres mots, depuis n'importe quelle loi normale de moyenne μ et d'écart-type σ , on obtient une loi normale centrée réduite en retranchant la moyenne μ , puis en divisant par l'écart-type σ . Voici l'espérance et la variance d'une variable aléatoire suivant une loi normale.

Proposition 4.28. Soit $\omega \sim \mathcal{N}(\mu, \sigma^2)$ avec $\mu \in \mathbb{R}$ et $\sigma > 0$. Nous avons

$$\mathbb{E}_{\omega \sim \mathcal{N}(\mu, \sigma^2)} [\omega] = \mu$$

Proposition 4.29. Soit $\omega \sim \mathcal{N}(\mu, \sigma^2)$ avec $\mu \in \mathbb{R}$ et $\sigma > 0$. Nous avons


$$\mathbb{V}_{\omega \sim \mathcal{N}(\mu, \sigma^2)} [\omega] = \sigma^2$$

Cette loi est connue car elle nous permet d'*approximer la somme de variables aléatoires i.i.d.* suivant une distribution quelconque μ . En effet, le théorème central limite de Lindeberg–Lévy permet de justifier cette approximation. Voici un énoncé très informel de ce théorème que l'on verra en détail plus tard.

Théorème 4.30 (informel). Soit une séquence $\omega_1, \omega_2, \dots \sim \mu$ où $\mathbb{V}_{\omega \sim \mu} [\omega] < +\infty$. Lorsque $m \rightarrow +\infty$ nous avons

$$\sum_{i=1}^m \omega_i \sim \mathcal{N} \left(m \mathbb{E}_{\omega \sim \mu} [\omega], m \mathbb{V}_{\omega \sim \mu} [\omega] \right).$$

Exemple. On peut par exemple approximer la somme de variables aléatoires de Bernoulli $\mathcal{B}(p)$ grâce à une loi normale. Pour $p = 0.3$, voici l'approximation lorsque $m = 10$ et $m = 100$.



Chapitre 5

Simulation de lois

Dans ce chapitre, nous allons étudier comment simuler des lois sur un ordinateur. Nous allons voir plusieurs types d'algorithmes.

- *Algorithmes pour tirer selon $\mathcal{U}(0, 1)$:*

Ils permettent de créer des variables aléatoires sur un ordinateur.

- *Méthodes d'inversion :*

Ces algorithmes permettent de tirer selon une loi pour laquelle l'inverse de la fonction de répartition est connu.

- *Algorithmes utilisant l'astuce de la reparamétrisation :*

Ils permettent de tirer selon une loi grâce au tirage d'une autre loi et en reparamétrisant la variable aléatoire.

- *Méthodes du rejet :*

Ces algorithmes permettent de tirer selon une loi grâce à plusieurs tirages d'une autre loi et en rejetant certains tirages.

5.1 Le cas “simple” : la loi uniforme

Voici deux algorithmes très connus pour simuler la loi uniforme :

- Mersenne Twister
- Blum Blum Shub

Dans la réalité, on va utiliser des fonctions comme `random.random()` dans Python (qui utilise l'algorithme Mersenne Twister).

5.2 Méthodes d'inversion

Fonction de répartition


Afin d'évoquer les méthodes d'inversion, il est important de définir les fonctions de répartition (ainsi que de voir leurs propriétés).

Définition 5.1. Soit $\omega \sim \mu$ une variable aléatoire réelle, i.e., μ est une distribution sur $\mathbb{R}$. On appelle fonction de répartition associée à μ la fonction $F_\mu : \mathbb{R} \rightarrow [0, 1]$ définie par :


$$\forall \tau \in \mathbb{R}, \quad F_\mu(\tau) = \mathbb{P}_{\omega \sim \mu}[\omega \leq \tau].$$

La fonction de répartition F permet de connaître la probabilité que la variable $\omega \sim \mu$ prenne une valeur inférieure ou égale à un seuil donné τ .

Exemple. Voici la fonction de répartition de la loi $\mathcal{U}(1, 2)$.



Exemple. Voici la fonction de répartition de la loi $\mathcal{B}(0.4)$.



La fonction de répartition possède plusieurs propriétés importantes.

Proposition 5.2. Soit μ une distribution sur $\mathbb{R}$ et $F_\mu : \mathbb{R} \rightarrow [0, 1]$ sa fonction de répartition. Nous avons

1. F_μ est croissante ;
2. F_μ est continue à droite ;
3. $\lim_{\tau \rightarrow -\infty} F_\mu(\tau) = 0$ et $\lim_{\tau \rightarrow +\infty} F_\mu(\tau) = 1$.

Voici des propriétés qui permettent de montrer les liens forts qui existent entre une distribution et une fonction de répartition.

Proposition 5.3. Soit F une fonction de $\mathbb{R}$ dans $[0, 1]$, croissante, continue à droite avec $\lim_{\tau \rightarrow -\infty} F(\tau) = 0$ et $\lim_{\tau \rightarrow +\infty} F(\tau) = 1$. Alors, il existe une mesure de probabilité μ sur $\mathbb{R}$ dont la fonction de répartition est F .

Proposition 5.4. Soient μ_1 et μ_2 des distributions sur $\mathbb{R}$. $\mu_1 = \mu_2$ si et seulement si $F_{\mu_1} = F_{\mu_2}$.

Simulation par inversion

Si F est inversible et que nous avons une expression de son inverse, on peut générer une variable selon la loi F .

Algorithm 1 Simulation par inversion

Tirer $u \sim \mathcal{U}(0, 1)$

return $F_\mu^{-1}(u)$

Exemple. Considérons une variable aléatoire $\omega \sim \mathcal{E}(\lambda)$ de loi exponentielle de paramètre λ . Sa fonction de répartition est :

$$F_{\mathcal{E}(\lambda)}(\tau) = 1 - e^{-\lambda\tau}.$$

L'inverse de cette fonction est :

$$F_{\mathcal{E}(\lambda)}^{-1}(u) = -\frac{1}{\lambda} \ln(1 - u).$$

Ainsi, nous avons l'algorithme suivant.

Algorithm 2 Simulation d'une loi exponentielle

Tirer $u \sim \mathcal{U}(0, 1)$

return $-\frac{\ln(1-u)}{\lambda}$

Remarquons que $1-u \sim \mathcal{U}(0, 1)$ lorsque $u \sim \mathcal{U}(0, 1)$. On peut donc simplifier l'algorithme, ce qui donne une version "optimisée".

Algorithm 3 Simulation "optimisée" d'une loi exponentielle

Tirer $u \sim \mathcal{U}(0, 1)$

return $-\frac{\ln u}{\lambda}$

Fonction inverse généralisée

Au lieu de prendre l'inverse F^{-1} qui n'existe pas forcément, on considère la *fonction inverse généralisée* F^- de F . Il s'agit de l'inverse continue à gauche de F .

Définition 5.5. Soient une distribution μ et sa fonction de répartition $F_\mu : \mathbb{R} \rightarrow [0, 1]$. La fonction inverse généralisée est définie par

$$\forall u \in]0, 1[, \quad F_\mu^-(u) = \inf \{ \tau \in \mathbb{R} \mid F(\tau) \geq u \}, \quad .$$

Voici les différentes propriétés de la fonction inverse généralisée.

Proposition 5.6. Soient une distribution μ avec sa fonction de répartition $F_\mu : \mathbb{R} \rightarrow [0, 1]$. Si F_μ est bijective, alors $F_\mu^- = F_\mu^{-1}$.

Proposition 5.7. Soient une distribution μ avec sa fonction de répartition $F_\mu : \mathbb{R} \rightarrow [0, 1]$, $u \in]0, 1[$, et $\tau \in \mathbb{R}$, alors $F_\mu^-(u) \leq \tau$ si et seulement si $u \leq F(\tau)$.

Simulation par la fonction inverse généralisée

On peut maintenant généraliser¹ l'algorithme en utilisant la fonction inverse généralisée.

¹Désolé pour ce jeu de mots...

Algorithm 4 Simulation par la fonction inverse généralisée

Tirer $u \sim \mathcal{U}(0, 1)$

return $F_\mu^-(u)$

Nous pouvons ensuite prouver que cette algorithme est correct autrement dit que $F_\mu^-(u) \sim \mu$ si $u \sim \mathcal{U}(0, 1)$.

Proposition 5.8. L'algorithme de simulation est correct.

Démonstration. Soit $\omega' \sim \mu'$ la variable retournée par l'algorithme, c'est-à-dire $\omega' = F_\mu^-(u)$ avec $u \sim \mathcal{U}(0, 1)$. Montrons que $F_{\mu'}(\tau) = F_\mu(\tau)$ pour tout $\tau \in \mathbb{R}$:

$$\begin{aligned} F_{\mu'}(\tau) &= \mathbb{P}_{\omega' \sim \mu'} [\omega' \leq \tau] \\ &= \mathbb{P}_{u \sim \mathcal{U}(0, 1)} [F_\mu^-(u) \leq \tau] \\ &= \mathbb{P}_{u \sim \mathcal{U}(0, 1)} [u \leq F_\mu(\tau)] \\ &= F_\mu(\tau). \end{aligned}$$

□

Voici une liste de distribution avec leur fonction de répartition et leur inverse généralisée qui peuvent servir à l'algorithme pour simuler un tirage.

Distribution μ	$F_\mu(\tau)$	$F_\mu^-(u)$
Uniforme $\mathcal{U}(a, b)$	$\frac{\tau-a}{b-a}$ pour $\tau \in [a, b]$	$a + u(b - a)$
Exponentielle $\mathcal{E}(\lambda)$	$1 - e^{-\lambda\tau}$ pour $\tau \geq 0$	$-\frac{1}{\lambda} \ln(1 - u)$
Normale $\mathcal{N}(\mu, \sigma^2)$	$\frac{1}{2} \left[1 + \operatorname{erf} \left(\frac{\tau - \mu}{\sigma\sqrt{2}} \right) \right]$	$\mu + \sigma\sqrt{2} \cdot \operatorname{erf}^{-1}(2u - 1)$ (Pas calculable)
Poisson $\mathcal{P}(\lambda)$	$e^{-\lambda} \sum_{k=0}^{\tau} \frac{\lambda^k}{k!}$ pour $\tau \in \mathbb{N}$	Pas de forme close
Géométrique $\mathcal{G}(p)$	$1 - (1 - p)^\tau$ pour $\tau \in \mathbb{N}^*$	$\left\lceil \frac{\ln(1-u)}{\ln(1-p)} \right\rceil$
Binomiale $\mathcal{B}(n, p)$	$\sum_{k=0}^{\tau} \binom{n}{k} p^k (1-p)^{n-k}$ pour $\tau \in \mathbb{N}$	Pas de forme close
Weibull $\mathcal{W}(k, \lambda)$	$1 - e^{-(\tau/\lambda)^k}$ pour $\tau \geq 0$	$\lambda(-\ln(1 - u))^{1/k}$
Cauchy $\mathcal{C}(x_0, \gamma)$	$\frac{1}{\pi} \tan^{-1} \left(\frac{\tau - x_0}{\gamma} \right) + \frac{1}{2}$	$x_0 + \gamma \tan[\pi(u - 0.5)]$

5.3 Algorithme de Box-Muller : tirer selon $\mathcal{N}(0, 1)$

Voici une solution pour générer la loi normale : l'algorithme de Box-Muller. Ce dernier provient d'une interprétation probabiliste du calcul de l'intégrale de Gauss. Cet algorithme est en particulier utilisé dans `std::normal_distribution` de la bibliothèque Standard C++.

On considère deux variables $x_1 \sim \mu_1$ et $x_2 \sim \mu_2$ de loi normale centrée réduite indépendantes $\mathcal{N}(0, 1)$, avec les densités suivantes :

$$\begin{aligned} \mu_1(x_1) &= \frac{1}{\sqrt{2\pi}} e^{-\frac{x_1^2}{2}}, \\ \mu_2(x_2) &= \frac{1}{\sqrt{2\pi}} e^{-\frac{x_2^2}{2}}. \end{aligned}$$

Comme $x_1 \sim \mu_1$ et $x_2 \sim \mu_2$ sont indépendantes, la densité conjointe du couple $(x_1, x_2) \sim \mu_1 \otimes \mu_2$ est le produit des densités de chaque variable :

$$\begin{aligned} \mu_1 \otimes \mu_2(x_1, x_2) &= \mu_1(x_1) \otimes \mu_2(x_2) \\ &= \frac{1}{2\pi} e^{-\frac{x_1^2 + x_2^2}{2}}. \end{aligned}$$

L'idée est d'utiliser les coordonnées polaires. Comme (x_1, x_2) est un point aléatoire, on peut parler de ses coordonnées polaires (r, θ) , qui sont elles-mêmes des variables aléatoires :

$$\begin{aligned}x_1 &= r \cos(\theta), \\x_2 &= r \sin(\theta).\end{aligned}$$

Ensuite, en faisant des changements de variables, on peut voir que nous avons

$$\begin{aligned}\int_{\mathbb{R}} \int_{\mathbb{R}} \frac{1}{2\pi} e^{-\frac{x_1^2 + x_2^2}{2}} dx_1 dx_2 &= \int_{\mathbb{R}} \int_{\mathbb{R}} \frac{1}{2\pi} e^{-\frac{r^2}{2}} r dr d\theta \\&= \left[\int_{\mathbb{R}} e^{-\frac{r^2}{2}} r dr \right] \left[\int_{\mathbb{R}} \frac{1}{2\pi} d\theta \right] \\&= \left[\int_{\mathbb{R}} \frac{1}{2} e^{-\frac{s}{2}} ds \right] \left[\int_{\mathbb{R}} \frac{1}{2\pi} d\theta \right].\end{aligned}$$

Étant donné la densité de (x_1, x_2) , on voit que l'angle θ suit une loi uniforme :

$$\theta \sim \mathcal{U}(0, 2\pi).$$

De plus, le rayon $s = r^2$ suit une distribution exponentielle :

$$r^2 \sim \mathcal{E}\left(\frac{1}{2}\right).$$

Transformation de Box-Muller

Ainsi, grâce à ça, nous avons la proposition suivante.

Proposition 5.9. Soient $r^2 \sim \mathcal{E}\left(\frac{1}{2}\right)$ et $\theta \sim \mathcal{U}(0, 2\pi)$. Alors, nous avons

$$r \cos(\theta) \sim \mathcal{N}(0, 1) \quad \text{et} \quad r \sin(\theta) \sim \mathcal{N}(0, 1)$$

Algorithme de Box-Muller

Grâce à la proposition, nous pouvons en déduire un algorithme pour tirer une variable aléatoire suivant une loi normale.

Algorithm 5 Algorithme de Box-Muller

Tirer $\theta \sim \mathcal{U}(0, 2\pi)$ et $r^2 \sim \mathcal{E}\left(\frac{1}{2}\right)$

return $r \cos(\theta)$

5.4 Astuce de la reparamétrisation

Algorithme

L'astuce de la reparamétrisation permet de tirer selon une distribution pour laquelle nous n'avons pas d'algorithme pour effectuer un tirage en utilisant une autre distribution. Cette algorithme a été trouvé par (DEVROYE, 1996).

Algorithm 6 Simulation par l'astuce de la reparamétrisation

Tirer $\omega \sim \mu$

return $f(\omega)$

Exemples

Exemple. Voici un exemple simple pour tirer selon $\mathcal{U}(0, a)$.

Algorithm 7 Algorithme pour tirer $\mathcal{U}(0, a)$

Tirer $u \sim \mathcal{U}(0, 1)$

return $a \cdot u$

Exemple. Voici un autre exemple pour tirer selon $\mathcal{E}(\frac{1}{2})$.

Algorithm 8 Algorithme pour tirer $\mathcal{E}(\frac{1}{2})$

Tirer $u \sim \mathcal{U}(0, 1)$

return $-2 \ln(u)$

On peut en déduire un autre exemple (qui est connu ...).

Exemple. Nous avons déjà vu un algorithme utilisant cette astuce : l'algorithme de Box-Muller.

Algorithm 9 Algorithme de Box-Muller

Tirer $u_1 \sim \mathcal{U}(0, 1)$ et $u_2 \sim \mathcal{U}(0, 1)$

return $\sqrt{-2 \ln(u_1)} \cos(2\pi u_2)$

Dans le chapitre précédent, nous avons vu la proposition suivante.

Proposition. Soit $\mu \in \mathbb{R}$ et $\sigma > 0$, alors nous avons

$$\omega \sim \mathcal{N}(0, 1) \implies \mu + \sigma \cdot \omega \sim \mathcal{N}(\mu, \sigma^2)$$

Elle nous permet de directement obtenir un algorithme utilisant l'astuce de la reparamétrisation.

Exemple. En effet, nous sommes en mesure de tirer (simplement) une variable aléatoire selon $\mathcal{N}(\mu, \sigma^2)$.

Algorithm 10 Algorithme pour tirer selon $\mathcal{N}(\mu, \sigma^2)$

Tirer $\omega \sim \mathcal{N}(0, 1)$ (avec l'algorithme de Box-Muller)

return $\mu + \sigma \cdot \omega$

Voici plusieurs exemples de fonction f qui peut être utilisée pour faire des tirages. D'ailleurs, on définit la distribution $\mathcal{U}(0, 1)^{\otimes 2}$ par $\mathcal{U}(0, 1)^{\otimes 2} = \mathcal{U}(0, 1) \otimes \mathcal{U}(0, 1)$.

Cible	Source	Fonction f
Normal $\mathcal{N}(0, 1)$	$(u_1, u_2) \sim \mathcal{U}(0, 1)^{\otimes 2}$	$\sqrt{-2 \ln(u_1)} \cos(2\pi u_2)$
Normal $\mathcal{N}(\mu, \sigma^2)$	$\omega \sim \mathcal{N}(0, 1)$	$\mu + \sigma \cdot \omega$
Exponential $\mathcal{E}(1)$	$u \sim \mathcal{U}(0, 1)$	$\ln(1/u)$
Log-Normal $\ln \mathcal{N}(\mu, \sigma^2)$	$\omega \sim \mathcal{N}(\mu, \sigma^2)$	$\exp(\omega)$
Cauchy $\mathcal{C}(0, 1)$	$u \sim \mathcal{U}(0, 1)$	$\tan(\pi u)$
Rademacher $\mathcal{R}(\frac{1}{2})$	$\omega \sim \mathcal{B}(\frac{1}{2})$	$2\omega - 1$


5.5 Méthode du rejet

Cas simple : Loi uniforme sur le disque unité

L'objectif est de générer un point uniformément distribué dans le disque unité en utilisant la méthode du rejet.

Algorithm 11 Générer un point dans le disque unité par la méthode du rejet

```
Générer uniformément un point  $x$  dans  $[-1, 1]^2$ 
while  $x$  n'est pas dans le disque unité do
    Générer uniformément un point  $x$  dans  $[-1, 1]^2$ 
end while
return  $x$ 
```

Illustration de la méthode de rejet**Analyse du nombre d'itérations**

On peut analyser son nombre d'itérations en moyenne.

Proposition 5.10. Le nombre d'itérations suit la loi géométrique $\mathcal{G}(\frac{\pi}{4})$, et son espérance est donc $\frac{4}{\pi}$.

Démonstration. Un succès correspond à la génération d'un point à l'intérieur du disque unité. La probabilité de succès est donnée par :

$$P(\text{succès}) = \frac{\text{aire du disque}}{\text{aire du carré}} = \frac{\pi}{4}.$$

L'algorithme suit donc un processus où l'on répète les essais jusqu'à obtenir un succès, ce qui correspond à une loi géométrique. $\square$

Théorème 5.11. L'algorithme génère bien une distribution uniforme sur le disque unité.

Démonstration. On va le prouver en TD ! $\square$

Méthode du rejet pour une densité à support compact

Problème : Soit une densité $f(x)$ à support compact sur $[a, b]$ et bornée par M . On veut générer une variable de densité f .

Algorithm 12 Méthode du rejet pour une densité bornée

```
Générer  $(x, y)$  uniformément dans  $[a, b] \times [0, M]$ 
while  $y > f(x)$  do
    Générer  $(x, y)$  uniformément dans  $[a, b] \times [0, M]$ 
end while return  $x$ 
```

Algorithme du rejet généralisé

Arrêtons maintenant de supposer que f n'est plus à support compact. On suppose maintenant que l'on dispose d'une autre fonction de densité g dont on sait générer des tirages et tel qu'il existe un réel $a \in \mathbb{R}_+$, pour tout $x \in \mathbb{R}$, $f(x) \leq ag(x)$.

Remarquons que $a > 1$ car f et g sont des fonctions de densité (d'intégrale égale à 1). Le cas $a = 1$ signifie que $f = g$, mais ce cas-là est trivial !

Problème :

- une fonction de densité f ;
- une fonction de densité g telle que l'on peut générer des nombres selon la loi de densité g ;
- un nombre $a > 1$ avec $f(x) \leq ag(x)$.

Trouver un générateur pour la distribution de densité f .

Algorithme du rejet généralisé

On peut obtenir l'algorithme suivant.

Algorithm 13 Algorithme du rejet généralisé

```
Générer  $x$  suivant une loi de densité  $g$ 
Générer un nombre  $y$  uniformément dans l'intervalle  $[0, ag(x)]$ 
while  $y > f(x)$  do
  Générer  $x$  suivant une loi de densité  $g$ 
  Générer un nombre  $y$  uniformément dans l'intervalle  $[0, ag(x)]$ 
end while
return  $x$ 
```

Chapitre 6

Convergence des suites de variables aléatoires

6.1 Introduction

Dans les chapitres précédents, nous avons vu différents liens entre les distributions. Nous allons voir ici comment une suite de variables aléatoires peut se rapprocher d'une variable aléatoire.

Dans ce chapitre, nous allons explorer les principaux types de convergence :

- *Convergence presque sûre* :
Une convergence point par point sur un ensemble de probabilité 1.
- *Convergence en probabilité* :
Une convergence basée sur la probabilité que l'écart entre les variables et leur limite soit supérieur à une certaine valeur.
- *Convergence en loi* :
Une convergence basée sur la distribution des variables.

Ces notions seront illustrées par des exemples et des théorèmes fondamentaux, notamment :

- la loi forte des grands nombres ;
- la loi faible des grands nombres ;
- le théorème central limite.

6.2 Convergence presque sûre

Nous allons voir plusieurs types de convergence pour les suites de variables aléatoires. Nous allons voir tout d'abord la convergence presque sûre.

Définition 6.1. Soient une suite de variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ où $\omega_m \sim \mu_m$ et $\omega \sim \mu$. La suite $(\omega_m)_{m \in \mathbb{N}}$ de variables aléatoires converge presque sûrement vers la variable aléatoire ω si :

$$\mathbb{P}_{\omega \sim \mu, \omega_1 \sim \mu_1, \omega_2 \sim \mu_2, \dots} \left[\lim_{m \rightarrow +\infty} \omega_m = \omega \right] = 1.$$

Autrement dit, l'ensemble où ω_m ne converge pas vers ω forme un événement de mesure nulle. Plus précisément, voici la notation que nous allons utiliser.

Notation 6.2. Lorsqu'une suite de variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ converge presque sûrement vers ω , nous écrivons

$$\omega_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega$$

Remarque 6.3. En anglais, on trouve souvent la même notation dans laquelle "p.s." est remplacé par "a.s." (pour "almost sure").

Par exemple, nous pouvons montrer la convergence suivante.

Exemple 6.4. Soit $p \in [0, 1]$, nous avons

$$\omega_m(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i \quad \text{où } z_i \sim \mathcal{B}(p) \quad \xrightarrow[m \rightarrow +\infty]{P.S.} p.$$

Par exemple, la loi forte des grands nombres est un théorème très connu de la théorie des probabilités qui utilise la convergence presque sûre.

Théorème 6.5 (Loi forte des grands nombres). Soit une mesure de probabilité μ où $\mathbb{E}_{\omega \sim \mu} [|\omega|] < +\infty$, alors

$$\omega_m(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i \quad \text{où } z_i \sim \mu \quad \xrightarrow[m \rightarrow +\infty]{P.S.} \quad \mathbb{E}_{\omega \sim \mu} [\omega].$$

6.3 Convergence en probabilité

Il existe d'autres formes de convergence : voici la convergence en probabilité.

Définition 6.6. Soient une suite de variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ où $\omega_m \sim \mu_m$ et $\omega \sim \mu$. La suite de variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ converge en probabilité vers ω si :

$$\forall \varepsilon > 0, \quad \mathbb{P}_{\omega_m \sim \mu_m, \omega \sim \mu} [|\omega_m - \omega| \geq \varepsilon] \xrightarrow[m \rightarrow +\infty]{} 0.$$

La convergence en probabilité signifie que la probabilité que ω_m s'éloigne de ω d'une quantité arbitrairement petite ε devient de plus en plus faible lorsque m augmente. Autrement dit, les valeurs de ω_m se rapprochent de ω avec une forte probabilité à mesure que m tend vers l'infini.

Voici la notation que nous allons utiliser.

Notation 6.7. Lorsqu'une suite de variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ converge en probabilité vers ω , nous écrivons

$$\omega_m \xrightarrow[m \rightarrow +\infty]{P} \omega$$

Remarque 6.8. Parfois, la notation "P" est remplacé par μ ou $\mathbb{P}$.

Nous avons, par exemple, la convergence en probabilité suivante sur une distribution de Bernoulli.

Exemple 6.9. Soit $p \in [0, 1]$, nous avons

$$\omega_m \sim \mathcal{B}\left(\frac{p}{m}\right) \xrightarrow[m \rightarrow +\infty]{P} 0$$

Voici une version faible de la loi des grands nombres, faible car les hypothèses sont justement trop fortes. Ce théorème est pédagogiquement intéressant car c'est un exemple connu de convergence en probabilité.

Théorème 6.10 (Loi de Khintchine / Loi faible des grands nombres). Soit une mesure de probabilité μ où $\mathbb{E}_{x \sim \mu} [|\omega|] < +\infty$, alors

$$\omega_m(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i \quad \text{où } z_i \sim \mu \quad \xrightarrow[m \rightarrow +\infty]{P} \quad \mathbb{E}_{\omega \sim \mu} [\omega].$$

Démonstration. Nous allons le prouver plus tard ! □

6.4 Convergence en loi

Définition

Si on cherche à modéliser le fait que la loi de $\omega_m \sim \mu_m$ ressemble de plus en plus à la loi $\omega \sim \mu$ quand m tend vers l'infini, nous pouvons nous intéresser à la convergence en loi.

Définition 6.11. Soient une suite de variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ où $\omega_m \sim \mu_m$ et $\omega \sim \mu$. La suite de

variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ converge en loi vers la variable aléatoire ω si on a :

Pour toute fonction continue bornée g ,

$$\mathbb{E}_{\omega_m \sim \mu_m} [g(\omega_m)] \xrightarrow{m \rightarrow +\infty} \mathbb{E}_{\omega \sim \mu} [g(\omega)].$$

Voici la notation que nous allons utiliser.

Notation 6.12. Lorsqu'une suite de variables aléatoires $(\omega_m)_{m \in \mathbb{N}}$ converge en loi vers ω , nous écrivons

$$\omega_m \xrightarrow[m \rightarrow +\infty]{L} \omega$$

Propriétés

Nous disposons de plusieurs propriétés essentielles concernant la convergence des variables aléatoires, parmi lesquelles figure le théorème de Slutsky. Le théorème de Slutsky établit des conditions sous lesquelles la convergence en loi de deux suites de variables aléatoires est préservée sous la multiplication et l'addition.

Théorème 6.13 (Théorème de Slutsky). Si nous avons

$$\omega_m \xrightarrow[m \rightarrow +\infty]{L} \omega \quad \text{et} \quad \omega'_m \xrightarrow[m \rightarrow +\infty]{L} c, \quad \text{où } c \in \mathbb{R}$$

alors, on a

$$\omega_m + \omega'_m \xrightarrow[m \rightarrow +\infty]{L} \omega + c \quad \text{et} \quad \omega'_m \cdot \omega_m \xrightarrow[m \rightarrow +\infty]{L} c \cdot \omega.$$

Nous pouvons caractériser la convergence en loi pour des variables aléatoires à valeurs entières.

Proposition 6.14. Soient $(\omega_m)_{m \in \mathbb{N}}$ une suite de variables aléatoires à valeurs entières où $\omega_m \sim \mu_m$ et $\omega \sim \mu$. On a :

$$\omega_m \xrightarrow[m \rightarrow +\infty]{L} \omega \quad \text{si et seulement si, pour tout } k \in \mathbb{N}, \quad \mathbb{P}_{\omega_m \sim \mu_m} [\omega_m = k] \xrightarrow[m \rightarrow +\infty]{} \mathbb{P}_{\omega \sim \mu} [\omega = k].$$

Nous pouvons également caractériser la convergence en loi d'une variable aléatoire réelle grâce à la fonction de répartition.

Théorème 6.15. Soient $(\omega_m)_{m \in \mathbb{N}}$ une suite de variables aléatoires réelles où $\omega_m \sim \mu_m$ et $\omega \sim \mu$. Alors les deux assertions sont équivalentes :

- $\omega_m \xrightarrow[m \rightarrow +\infty]{L} \omega ;$

- Pour tout $\tau \in \mathbb{R}$, nous avons

$$\mathbb{P}_{\omega_m \sim \mu_m} [\omega_m \leq \tau] \xrightarrow[m \rightarrow +\infty]{} \mathbb{P}_{\omega \sim \mu} [\omega \leq \tau].$$

Par exemple, nous pouvons montrer que la suite de variables aléatoires $\omega_m \sim \mathcal{N}(0, \frac{1}{m})$ tend vers un Dirac centré en 0. En effet, nous avons l'exemple suivant.

Exemple 6.16 (Convergence en loi d'une gaussienne vers un Dirac). Nous avons

$$\omega_m \sim \mathcal{N}\left(0, \frac{1}{m}\right) \xrightarrow[m \rightarrow +\infty]{L} \omega \sim \delta_0.$$

Plus généralement, nous avons la convergence suivante.

Exemple 6.17. *Nous avons*

$$\omega_m \sim \mathcal{N}\left(0, \sigma^2 + \frac{1}{m}\right) \xrightarrow[m \rightarrow +\infty]{L} \omega \sim \mathcal{N}(0, \sigma^2).$$

Nous pouvons trouver des exemples similaires en jouant avec les paramètres des distributions.

Exemple 6.18 (Convergence vers une Bernoulli). *Nous avons*

$$\omega_m \sim \mathcal{B}\left(p + \frac{1-p}{m}\right) \xrightarrow[m \rightarrow +\infty]{L} \omega \sim \mathcal{B}(p)$$

Un dernier exemple sur les Gaussiennes qui illustre bien que l'on converge sur les différents tirages selon la distribution.

Exemple 6.19. *Nous avons*

$$\omega_m \sim \mathcal{B}\left(p + \frac{1-p}{m}\right) \xrightarrow[m \rightarrow +\infty]{L} \omega \sim \mathcal{B}(p).$$

Comme nous l'avons vu dans l'un des chapitres précédents, la somme de variables aléatoires *i.i.d.* est "approximativement" Gaussienne. Plus exactement, la somme de variables aléatoires *i.i.d.* converge en loi vers une distribution Gaussienne.

Théorème 6.20 (Théorème central limite de Lindeberg–Lévy). Soit une mesure de probabilité où $\mathbb{E}_{\omega \sim \mu} [|\omega|] < +\infty$ et $\mathbb{E}_{\omega \sim \mu} [\omega^2] < +\infty$. Nous avons

$$\frac{1}{\sqrt{m}} \sum_{i=1}^m z_i - \sqrt{m} \mathbb{E}_{\omega \sim \mu} [\omega] \quad \text{où } z_i \sim \mu \quad \xrightarrow[m \rightarrow +\infty]{L} \quad \omega \sim \mathcal{N}\left(0, \mathbb{V}_{\omega \sim \mu} [\omega]\right).$$

On relate ici deux convergences en loi que l'on a déjà évoquées. Ayant maintenant défini proprement la convergence en loi, nous pouvons revisiter le lien entre la loi binomiale et la loi de Poisson.

Théorème 6.21. Soit $\lambda = pn \in \mathbb{R}$. Nous avons

$$\omega' \sim \mathcal{B}\left(m, \frac{\lambda}{m}\right) \xrightarrow[m \rightarrow +\infty]{L} \omega \sim \mathcal{P}(\lambda).$$

Nous pouvons également établir un lien plus formel entre la loi géométrique et la loi exponentielle.

Théorème 6.22 (Cas spécial). Nous avons :

$$\frac{\omega_m}{\lambda m} \text{ avec } \omega_m \sim \mathcal{G}\left(\frac{1}{m}\right) \xrightarrow[m \rightarrow +\infty]{L} \omega \sim \mathcal{E}(\lambda).$$

6.5 Propriétés sur les types de convergence

Toutes les convergences ne se valent pas ! Certaines sont plus fortes, d'autres plus faibles.

Théorème 6.23. Nous avons

$$\omega_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega \implies \omega_m \xrightarrow[m \rightarrow +\infty]{P} \omega \implies \omega_m \xrightarrow[m \rightarrow +\infty]{L} \omega$$

Ainsi que

$$\omega_m \xrightarrow[m \rightarrow +\infty]{P} c \iff \omega_m \xrightarrow[m \rightarrow +\infty]{L} c.$$

Nous pouvons également effectuer différentes opérations sur les limites associées à ces différents types de convergence. Par exemple, la convergence est conservée par transformation affine d'une variable aléatoire.

Proposition 6.24. Soient $(\omega_m)_{m \in \mathbb{N}}$ et $(\omega'_m)_{m \in \mathbb{N}}$ deux suites de variables aléatoires, et ω une variable aléatoire. Pour tout $a, b \in \mathbb{R}$, nous avons :

- si $\omega_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega$, alors $a \cdot \omega_m + b \xrightarrow[m \rightarrow +\infty]{P.S.} a \cdot \omega + b$;
- si $\omega_m \xrightarrow[m \rightarrow +\infty]{P} \omega$, alors $a \cdot \omega_m + b \xrightarrow[m \rightarrow +\infty]{P} a \cdot \omega + b$;
- si $\omega_m \xrightarrow[m \rightarrow +\infty]{L} \omega$, alors $a\omega_m + b \xrightarrow[m \rightarrow +\infty]{L} a\omega + b$.

De plus, la convergence de l'addition de deux variables aléatoires est aussi conservée. En effet, nous avons la propriété suivante.

Proposition 6.25. Soient $(\omega_m)_{m \in \mathbb{N}}$ et $(\omega'_m)_{m \in \mathbb{N}}$ deux suites de variables aléatoires, et ω, ω' des variables aléatoires. Nous avons :

- si $\omega_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega$ et $\omega'_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega'$, alors $\omega_m + \omega'_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega + \omega'$;
- si $\omega_m \xrightarrow[m \rightarrow +\infty]{P} \omega$ et $\omega'_m \xrightarrow[m \rightarrow +\infty]{P} \omega'$, alors $\omega_m + \omega'_m \xrightarrow[m \rightarrow +\infty]{P} \omega + \omega'$;
- si $\omega_m \xrightarrow[m \rightarrow +\infty]{L} \omega$ et $\omega'_m \xrightarrow[m \rightarrow +\infty]{L} \omega'$, alors $\omega_m + \omega'_m \xrightarrow[m \rightarrow +\infty]{L} \omega + \omega'$.

De même, le mode de convergence est conservé par multiplication de deux variables aléatoires (sauf pour la convergence en loi).

Proposition 6.26. Soient $(\omega_m)_{m \in \mathbb{N}}$ et $(\omega'_m)_{m \in \mathbb{N}}$ deux suites de variables aléatoires, et ω, ω' des variables aléatoires. Nous avons :

- si $\omega_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega$ et $\omega'_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega'$, alors $\omega_m \omega'_m \xrightarrow[m \rightarrow +\infty]{P.S.} \omega \omega'$;
- si $\omega_m \xrightarrow[m \rightarrow +\infty]{P} \omega$ et $\omega'_m \xrightarrow[m \rightarrow +\infty]{P} \omega'$, alors $\omega_m \omega'_m \xrightarrow[m \rightarrow +\infty]{P} \omega \omega'$.

Partie II

Statistiques

Chapitre 7

Estimation

7.1 Echantillon

À partir de maintenant, la mesure de probabilité / distribution n'est plus considérée comme connue. Par contre, nous considérons que nous avons un échantillon (c'est-à-dire des réalisations) venant de cette distribution μ .

Définition 7.1 (Échantillon aléatoire / données). Un *échantillon aléatoire* ou des *données* S est une suite de variables aléatoires

$$z_1 \sim \mu, \dots, z_m \sim \mu$$

indépendantes et identiquement distribuées (*i.i.d.*), i.e., nous avons

$$S = (z_1, \dots, z_m) \sim \mu^{\otimes m}.$$

Voici plusieurs exemples d'échantillon.

Exemple (Pièce de monnaie). *Considérons une pièce de monnaie dont la probabilité d'obtenir pile (i.e., d'obtenir un succès ♥) est θ (qui est un paramètre inconnu). Pour modéliser les lancers, on considère un échantillon aléatoire tel que*

$$(z_1, \dots, z_m) \sim \mathcal{B}(\theta)^{\otimes m}.$$

Exemple (Longueur d'un animal). *On suppose que la longueur des sardines est modélisée par une loi normale de paramètres (inconnues) (μ, σ^2) où $\mu \in \mathbb{R}$ est la moyenne et $\sigma^2 \in \mathbb{R}^+$ la variance. Ainsi, nous avons*

$$(z_1, \dots, z_m) \sim \mathcal{N}(\mu, \sigma^2)^{\otimes m}.$$

L'objectif des statistiques est de récolter un maximum d'information sur la distribution μ à travers cet échantillon.

7.2 Statistique et Estimateur

Nous allons tout d'abord définir la notion de statistique.

Définition 7.2. Une statistique est une variable aléatoire réelle de la forme $\varphi(z_1, \dots, z_m)$ où $z_1 \sim \mu, \dots, z_m \sim \mu$ sont m variables aléatoires (qui est un échantillon aléatoire).

En d'autres termes, une statistique $\varphi(z_1, \dots, z_m)$ prend l'échantillon $(z_1, \dots, z_m) \sim \mu^{\otimes m}$ et retourne une valeur.

Voici plusieurs exemples de statistiques que nous pouvons rencontrer. Voici deux exemples basés sur une quantité très connus en statistiques : la moyenne.

Exemple 7.3. *La variable aléatoire*

$$\varphi(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i,$$

appelée moyenne de l'échantillon $S = (z_1, \dots, z_m)$, est une statistique.

Exemple 7.4. *La variable aléatoire*

$$\varphi(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i - \mathbb{E}_{z \sim \mu} [z]$$

est une statistique.

Un autre exemple de statistique très connu est la variance d'un échantillon.

Exemple 7.5. *La variable aléatoire*

$$\varphi(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m \left(z_i - \frac{1}{m} \sum_{j=1}^m z_j \right)^2,$$

appelée variance de l'échantillon $S = (z_1, \dots, z_m)$, est une statistique.

Exemple 7.6. *La variable aléatoire*

$$\varphi(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m \left(z_i - \frac{1}{m} \sum_{j=1}^m z_j \right)^2 - \mathbb{V}_{z \sim \mu}[z],$$

est une statistique.

Un moyen d'obtenir des informations sur la distribution inconnue μ est d'utiliser une statistique $\varphi(z_1, \dots, z_m)$ construite à partir de l'échantillon $S = (z_1, \dots, z_m) \sim \mu^{\otimes m}$. Lorsque cette statistique a pour objectif d'approcher une caractéristique inconnue θ de la distribution μ , on l'appelle un estimateur.

Définition 7.7. Un estimateur est une statistique, que l'on va noter

$$\hat{\theta}_m(z_1, \dots, z_m) := \varphi(z_1, \dots, z_m)$$

et qui ne dépend pas de la caractéristique θ inconnue à estimer de la distribution μ .

Autrement dit, à partir d'un échantillon $(z_1, \dots, z_m) \sim \mu^{\otimes m}$, on construit une fonction calculable, appelée estimateur, qui doit approcher la caractéristique θ lorsque la taille de l'échantillon m augmente. Notez que la valeur fournie par la fonction est appelée estimation.

Voici un exemple d'estimateur (qui est très populaire ...) : la moyenne ! En effet, la moyenne est un estimateur de l'espérance.

Exemple. *Supposons que la caractéristique d'intérêt à estimer soit l'espérance*

$$\theta = \mathbb{E}_{z \sim \mu}[z].$$

Pour l'estimer, on peut utiliser l'estimateur

$$\hat{\theta}_m(z_1, \dots, z_m) = \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}}(z_1, \dots, z_m) = \frac{z_1 + \dots + z_m}{m} = \frac{1}{m} \sum_{i=1}^m z_i.$$

Notez cependant que toutes les statistiques ne sont pas des estimateurs.

Exemple. *La variable aléatoire*

$$\varphi(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i - \mathbb{E}_{z \sim \mu}[z]$$

est une statistique, mais ce n'est pas un estimateur si l'espérance $\mathbb{E}_{z \sim \mu}[z]$ est inconnue.

Exemple. *La variable aléatoire*

$$\varphi(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m \left(z_i - \frac{1}{m} \sum_{j=1}^m z_j \right)^2 - \mathbb{V}_{z \sim \mu}[z]$$

est une statistique, mais ce n'est pas un estimateur si l'espérance $\mathbb{V}_{z \sim \mu}[z]$ est inconnue.

7.3 Qualité d'un estimateur

Une première mesure pour évaluer la qualité d'un estimateur consiste à s'intéresser au biais. Cette mesure indique si l'estimateur fournit, en espérance, la valeur de la caractéristique à estimer.

Définition 7.8 (Biais). Le biais d'un estimateur $\hat{\theta}_m$ servant à estimer θ est défini par

$$B_m(\theta) = \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} [\hat{\theta}_m(z_1, \dots, z_m)] - \theta.$$

Grâce à la notion de biais, nous pouvons déterminer si un estimateur est sans biais.

Définition 7.9 (Estimateur sans biais). L'estimateur $\hat{\theta}_m$ est *sans biais* / *non biaisé* si

$$B_m(\theta) = 0 \iff \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} [\hat{\theta}_m(z_1, \dots, z_m)] = \theta.$$

Autrement dit, dans le cas où l'estimateur est sans biais, l'estimateur $\hat{\theta}_m(z_1, \dots, z_m)$ est égal à la caractéristique réelle θ . On peut donc définir facilement un estimateur biaisé.

Définition 7.10 (Estimateur biaisé). L'estimateur $\hat{\theta}_m$ est *biaisé* si

$$B_m(\theta) \neq 0 \iff \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} [\hat{\theta}_m(z_1, \dots, z_m)] \neq \theta.$$

Nous pouvons, par exemple, montrer que la moyenne est un estimateur non biaisé de l'espérance.

Exemple. Soit $(z_1, \dots, z_m) \sim \mu^{\otimes m}$ un échantillon aléatoire dont l'espérance est $\theta = \mathbb{E}_{z \sim \mu} [z]$. Alors,

l'estimateur $\hat{\theta}_m(z_1, \dots, z_m) = \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} (z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i$ est sans biais.

Démonstration. Nous avons

$$\begin{aligned} \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} [\hat{\theta}_m(z_1, \dots, z_m)] &= \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} \left[\frac{z_1 + \dots + z_m}{m} \right] \\ &= \frac{1}{m} \left(\mathbb{E}_{z_1 \sim \mu} [z_1] + \dots + \mathbb{E}_{z_m \sim \mu} [z_m] \right) \\ &= \mathbb{E}_{z \sim \mu} [z] \\ &= \theta. \end{aligned}$$

□

Par contre, nous pouvons montrer que l'estimation naïve de la variance est un estimateur biaisé.

Exemple. Rappelons que

$$\theta = \mathbb{V}_{z \sim \mu} (z) = \mathbb{E}_{z \sim \mu} \left[\left(z - \mathbb{E}_{z \sim \mu} [z] \right)^2 \right].$$

L'estimation naïve de la variance $\theta = \mathbb{V}_{z \sim \mu} (z)$ définie par

$$\hat{\theta}_m(z_1, \dots, z_m) = \hat{\mathbb{V}}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} (z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m \left(z_i - \frac{1}{m} \sum_{j=1}^m z_j \right)^2$$

est biaisé car nous avons

$$\begin{aligned} \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} [\hat{\theta}_m(z_1, \dots, z_m)] &= \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} [\hat{\mathbb{V}}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} (z_1, \dots, z_m)] \\ &= \frac{m-1}{m} \mathbb{V}_{z \sim \mu} (z) = \frac{m-1}{m} \theta. \end{aligned}$$

De plus, nous pouvons corriger le biais de l'estimation naïve de la variance afin d'obtenir un estimateur sans biais.

Exemple. L'estimation corrigée de la variance définie par

$$\widehat{V}'_{(z_1, \dots, z_m) \sim \mu^{\otimes m}}(z_1, \dots, z_m) = \frac{1}{m-1} \sum_{i=1}^m \left(z_i - \frac{1}{m} \sum_{j=1}^m z_j \right)^2$$

est sans biais.

Même si certains estimateurs sont biaisés, le biais peut également diminuer lorsque la taille de l'échantillon m augmente. Dans ce cas-là, l'estimateur peut être asymptotiquement sans biais.

Définition 7.11. L'estimateur $\widehat{\theta}_m$ est *asymptotiquement sans biais* si nous avons

$$B_m(\theta) \xrightarrow{m \rightarrow +\infty} 0.$$

Nous pouvons montrer que l'estimation naïve de la variance est asymptotiquement sans biais.

Exemple. L'estimateur

$$\widehat{V}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}}(z_1, \dots, z_m)$$

est asymptotiquement sans biais.

Démonstration. Nous avons

$$\begin{aligned} B_m(\theta) &= \mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} \left[\widehat{V}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}}(z_1, \dots, z_m) \right] - \theta \\ &= \left(\frac{m-1}{m} - 1 \right) \theta \xrightarrow{m \rightarrow +\infty} 0. \end{aligned}$$

□

Nous pouvons mesurer la qualité d'un estimateur grâce à l'erreur quadratique moyenne.

Définition 7.12. L'erreur quadratique moyenne d'un estimateur est définie par

$$\mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} \left[\left(\widehat{\theta}_m(z_1, \dots, z_m) - \theta \right)^2 \right].$$

L'erreur quadratique moyenne peut se décomposer comme la somme d'un biais et d'une variance.

Théorème 7.13 (Décomposition Biais-Variance). Soit un estimateur $\widehat{\theta}_m$ de θ , nous avons

$$\mathbb{E}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} \left[\left(\widehat{\theta}_m(z_1, \dots, z_m) - \theta \right)^2 \right] = \mathbb{V}_{(z_1, \dots, z_m) \sim \mu^{\otimes m}} \left(\widehat{\theta}_m(z_1, \dots, z_m) \right) + B_m(\theta)^2$$

7.4 Estimation de paramètres de distributions : maximum de vraisemblance

On se place dans le cadre paramétré, c'est-à-dire que nous connaissons la forme générale de la loi, mais les paramètres restent inconnus.

Hypothèse 7.1. Nous avons une distribution μ_θ , paramétrée par des paramètres $\theta \in \Theta$ inconnus.

Exemple. Par exemple, on sait que le résultat d'un lancer de pièce suit une loi de Bernoulli, notée $\mathcal{B}(p)$, mais le paramètre p (la probabilité d'obtenir pile) est inconnu.

Exemple. Phénomène suivant une loi normale, mais avec des paramètres $\theta = (\mu, \sigma^2)$ (la moyenne et la variance) inconnus.

La vraisemblance

La vraisemblance mesure la compatibilité des données $(z_1, \dots, z_m) \sim \mu_\theta$ avec la loi de paramètres θ . L'idée est de rendre les probabilités d'observer chaque donnée z_i aussi grandes que possible.

Définition 7.14 (Vraisemblance pour une loi discrète ou continue). Soit θ les paramètres d'une loi discrète ou continue μ_θ (ayant une densité) et $(z_1, \dots, z_m) \sim \mu_\theta$ des données. La *vraisemblance* est définie par

$$\mathcal{L}_{\mu_\theta}(z_1, \dots, z_m) = \prod_{i=1}^m \mu_\theta(z_i).$$

Exemple. Soit $\mu = \mathcal{B}(\theta)$ une loi de Bernoulli de paramètre θ . Pour des données $(z_1, \dots, z_m) \sim \mathcal{B}(\theta)^{\otimes m}$, on a :

$$\mathcal{L}_{\mathcal{B}(\theta)}(z_1, \dots, z_m) = \theta^{\sum_{i=1}^m z_i} (1 - \theta)^{m - \sum_{i=1}^m z_i}.$$

Maximisation de la vraisemblance

Un estimateur des paramètres θ correspond aux paramètres $\theta' \in \Theta$ qui maximise la vraisemblance.

Définition 7.15 (Estimateur du maximum de vraisemblance). Un estimateur du maximum de vraisemblance est défini par

$$\hat{\theta}_m(z_1, \dots, z_m) \in \operatorname{argmax}_{\theta' \in \Theta} \mathcal{L}_{\mu_{\theta'}}(z_1, \dots, z_m).$$

Exemples

Théorème 7.16. Soit $z \sim \mathcal{B}(\theta)$, l'estimateur du maximum de vraisemblance de θ est

$$\hat{\theta}_m(z_1, \dots, z_m) = \frac{1}{m} \sum_{i=1}^m z_i.$$

Démonstration. La vraisemblance est

$$\mathcal{L}_{\mathcal{B}(\theta)}(z_1, \dots, z_m) = \theta^{\sum_{i=1}^m z_i} (1 - \theta)^{m - \sum_{i=1}^m z_i}.$$

En prenant le logarithme, on obtient

$$\log \mathcal{L}_{\mathcal{B}(\theta)}(z_1, \dots, z_m) = \left(\sum_{i=1}^m z_i \right) \log \theta + \left(m - \sum_{i=1}^m z_i \right) \log(1 - \theta).$$

En dérivant par rapport à θ et en posant la dérivée égale à zéro, on trouve que

$$\theta = \frac{1}{m} \sum_{i=1}^m z_i.$$

□

Théorème 7.17. Soit $z \sim \mathcal{N}(\mu, \sigma^2)$. L'estimateur du maximum de vraisemblance de (μ, σ^2) est donné par

$$\begin{aligned} \hat{\mu}(z_1, \dots, z_m) &= \frac{1}{m} \sum_{i=1}^m z_i, \\ \text{et } \hat{\sigma}^2(z_1, \dots, z_m) &= \frac{1}{m} \sum_{i=1}^m \left(z_i - \hat{\mu}(z_1, \dots, z_m) \right)^2. \end{aligned}$$

Démonstration. La vraisemblance est

$$\mathcal{L}_{\mathcal{N}(\mu, \sigma^2)}(z_1, \dots, z_m) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{z_i - \mu}{\sigma}\right)^2\right).$$

En prenant le logarithme et en dérivant par rapport à μ et σ , on obtient respectivement les formules ci-dessus. $\square$

7.5 Estimation d'un moment : méthode des moments

La méthode des moments est une alternative pour construire des estimateurs, moins utilisée que le maximum de vraisemblance mais intéressante à connaître.

Définition 7.18. Pour $k \in \mathbb{N}^*$, le *moment d'ordre k* de la variable aléatoire $z \sim \mu$ est défini par

$$\mathbb{E}_{z \sim \mu} [z^k].$$

Exemple. Si $z \sim \mathcal{E}(\theta)$, alors

$$\mathbb{E}_{z \sim \mathcal{E}(\theta)} [z^k] = \frac{k!}{\theta^k}.$$

Définition 7.19. Un *estimateur par la méthode des moments* de θ est obtenu en remplaçant un moment théorique d'ordre k par son estimation empirique, c'est-à-dire par

$$\frac{1}{m} \sum_{i=1}^m z_i^k.$$

Exemple. Si $z \sim \mathcal{E}(\theta)$, alors $\mathbb{E}_{z \sim \mathcal{E}(\theta)} [z] = \frac{1}{\theta}$, d'où

$$\theta = \frac{1}{\mathbb{E}_{z \sim \mathcal{E}(\theta)} [z]}.$$

L'estimateur par la méthode des moments est donc

$$\hat{\theta}_m(z_1, \dots, z_m) = \frac{m}{\sum_{i=1}^m z_i}.$$

Exemple 7.20. On a également $\mathbb{E}_{z \sim \mathcal{E}(\theta)} [z^2] = \frac{2}{\theta^2}$. On en déduit :

$$\theta = \sqrt{\frac{2}{\mathbb{E}_{z \sim \mathcal{E}(\theta)} [z^2]}}.$$

Ainsi, un autre estimateur par la méthode des moments est


$$\hat{\theta}_m(z_1, \dots, z_m) = \sqrt{\frac{2m}{\sum_{i=1}^m z_i^2}}.$$

Chapitre 8

Intervalle de confiance et inégalités de concentration

8.1 Introduction

Comme nous avons vu dans le dernier chapitre, la moyenne $\bar{\omega}_m$ va converger vers l'espérance lorsque le nombre de tirages m augmente.




Maintenant, si on suppose que $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ *i.i.d.* et que l'on veut estimer la moyenne $\bar{\omega}_m$. Au lycée, on énonce le résultat suivant.

Théorème 8.1. Soit des variables aléatoires réelles $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$. Nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)} \left[|\bar{\omega}_m - \mu| \leq 1.96 \frac{\sigma}{\sqrt{m}} \right] = \mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)} \left[\mu \in \left[\bar{\omega}_m \pm 1.96 \frac{\sigma}{\sqrt{m}} \right] \right] = 0.95.$$

Patience ! Nous allons le ré-énoncer plus tard. Mais c'est un bon point de départ pour comprendre l'intuition.

L'intervalle $\bar{\omega}_m \pm 1.96 \frac{\sigma}{\sqrt{m}}$ est l'intervalle de confiance. L'intervalle est *aléatoire* car il dépend de $\bar{\omega}_m$ qui est aléatoire. On remarque que plus m grandit, plus $1.96 \frac{\sigma}{\sqrt{m}}$ est petit et donc plus l'intervalle se resserre. C'est normal : plus on a de données, plus on est confiant.



Dans ce chapitre, nous allons voir :

- Les intervalles de confiance ;
- Comment construire un intervalle de confiance pour des distributions connues ;
- Comment construire un intervalle de confiance pour des distributions inconnues.

8.2 Intervalle de confiance

Dans la suite on va :

1. Donner la définition formelle d'un intervalle de confiance ;
2. Comprendre d'où vient le 1.96 : c'est la notion de quantile ;
3. Étudier la recette de cuisine pour construire un intervalle de confiance.

Définition

Tout d'abord, voici la définition d'un intervalle de confiance.

Définition 8.2. Un intervalle de confiance pour $\mathbb{E}_{\omega \sim \mu} [\omega]$ de niveau de confiance $\delta \in (0, 1)$ est un intervalle aléatoire $I : \Omega^m \times (0, 1) \rightarrow \mathbb{R}$ où nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} \left[\mathbb{E}_{\omega \sim \mu} [\omega] \in I(\omega_1, \dots, \omega_m, \delta) \right] \geq 1 - \delta.$$

Quantiles

Nous allons voir plus tard que nous avons besoin de la notion de quantile. Voici sa définition.

Définition 8.3. Soient $\omega \sim \mu$ une variable aléatoire réelle et $\delta \in (0, 1)$. Un δ -quantile de $\omega \sim \mu$ est un nombre q_δ avec $F_\mu(q_\delta) = \delta$ où F_μ est la fonction de répartition de $\omega \sim \mu$.

Quartiles, déciles, centiles

En pratique, quand on discute avec des statisticiens et statisticiennes, on parle parfois de quantiles particuliers : le médian, les quartiles, déciles, centiles.

Définition 8.4.


- Le *médian* est le quantile $q_{0.5}$.
- Les *quartiles* sont les quantiles $q_{0.25}$, $q_{0.5}$, $q_{0.75}$.
- Les *déciles* sont les quantiles $q_{0.1}$, $q_{0.2}$, $q_{0.3}$, $q_{0.4}$, $q_{0.5}$, $q_{0.6}$, $q_{0.7}$, $q_{0.8}$, $q_{0.9}$.
- Les *centiles* sont les quantiles $q_{0.01}$, $q_{0.02}$, $q_{0.03}$, etc.

Remarque 8.5. Attention, un quantile d'ordre δ n'est pas forcément unique ! S'il en a plusieurs, le quantile est l'ensemble des nombres τ avec $F_\mu(\tau) = \mathbb{P}_{\omega \sim \mu} [\omega \leq \tau] = \delta$.

Remarque 8.6. Dans les exemples, F_μ est toujours inversible car on va considérer que des variables μ à loi continue. Du coup, on a un unique δ -quantile de $\omega \sim \mu$:

$$q_\delta = F_\mu^{-1}(\delta).$$

Exemple 8.7 (quantiles vu sur la fonction de densité de la loi normale centrée réduite). Pour une loi normale centrée réduite, le quantile d'ordre $1/2$ vaut 0, puisque qu'il y a une probabilité de $1/2$ d'être négatif (sous le seuil 0). Le quantile d'ordre $1/4$ vaut -0,6745. Le quantile d'ordre $3/4$ vaut 0,6745.



Comme vu dans l'exemple précédent, nous avons une loi normale centrée (réduite), les quantiles sont symétriques dans le sens suivant. Par exemple, $q_{1/4} = -q_{3/4}$. Ainsi, nous avons la proposition suivante.

Proposition 8.8. Soit $\omega \sim \mathcal{N}(0, \sigma^2)$. Alors pour tout $\delta \in]0, 1[$ on a

$$q_{1-\delta} = -q_\delta.$$

Démonstration. Soit $\omega \sim \mathcal{N}(0, \sigma^2)$. Alors la fonction $F_{\mathcal{N}(0, \sigma^2)}$ vérifie $F_{\mathcal{N}(0, \sigma^2)}(-\tau) = 1 - F_{\mathcal{N}(0, \sigma^2)}(\tau)$ pour tout $\tau \in \mathbb{R}$. Ainsi, on a

$$\begin{aligned} F_{\mathcal{N}(0, \sigma^2)}(q_{1-\delta}) &= 1 - \delta && \text{par définition du quantile } q_{1-\delta} \\ &= 1 - F_{\mathcal{N}(0, \sigma^2)}(q_\delta) && \text{par définition du quantile } q_\delta \\ &= 1 - F_{\mathcal{N}(0, \sigma^2)}(-q_{1-\delta}) && \text{par la propriété de symétrie} \end{aligned}$$

Ainsi, on a $F_{\mathcal{N}(0, \sigma^2)}(q_\delta) = F_{\mathcal{N}(0, \sigma^2)}(-q_{1-\delta})$. Comme $F_{\mathcal{N}(0, \sigma^2)}(\cdot)$ est injective, on a

$$q_\delta = -q_{1-\delta}.$$

□

Estimation de la moyenne d'une loi normale avec écart-type connu

Nous avons presque tous les ingrédients pour dériver un intervalle de confiance. On va donc regarder un cas simple : une loi normale avec écart-type connu.

Soit $\omega \sim \mathcal{N}(\mu, \sigma^2)$ où la moyenne μ est inconnue. Autrement dit, il faut estimer μ avec la moyenne $\bar{\omega}_m$.

Nous voulons obtenir à la fin le théorème suivant.

Théorème 8.9. Soient des variables aléatoires réelles $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$. Nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)} \left[|\bar{\omega}_m - \mu| \leq 1.96 \frac{\sigma}{\sqrt{m}} \right] = \mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)} \left[\mu \in \left[\bar{\omega}_m \pm 1.96 \frac{\sigma}{\sqrt{m}} \right] \right] = 0.95.$$

Recette de cuisine pour obtenir un intervalle de confiance

Dans la suite, on utilise cette définition.

Définition 8.10. Une statistique est *pivotal* si sa loi est la même quelque soit le paramètre à estimer.

Voici la recette de cuisine à appliquer pour obtenir un intervalle de confiance.

1. Définir une statistique *pivotal*. L'expression de cette statistique contient le paramètre, forcément pour faire que la loi ne dépend pas du paramètre ;
2. Étudier la loi de cette statistique. Généralement, c'est une loi connue déjà, comme $\mathcal{N}(0, 1)$;

3. Établir des quantiles de cette loi. Pareil, la loi est connue, donc pas de soucis ;
4. Donner un intervalle de confiance. On reprend l'encadrement de la statistique avec des quantiles pour avoir l'intervalle de confiance.

On va donc définir une statistique pivotale lorsque un ω_i est tiré selon $\mathcal{N}(\mu, \sigma^2)$.

Proposition 8.11. Soit $\omega_1, \dots, \omega_m$ un échantillon aléatoire de loi $\mathcal{N}(\mu, \sigma^2)$. Alors

$$\frac{\sqrt{m}}{\sigma}(\bar{\omega}_m - \mu) \sim \mathcal{N}(0, 1).$$

Démonstration. Soit $\omega_1, \dots, \omega_m$ un échantillon aléatoire de loi $\mathcal{N}(\mu, \sigma^2)$. Donc, nous avons

$$\sum_{i=1}^m \omega_i + \dots + \omega_m \sim \mathcal{N}(m\mu, m\sigma^2).$$

En divisant par m , on divise la variance par m^2 , on a donc :

$$\bar{\omega}_m = \frac{1}{m} \sum_{i=1}^m \omega_i \sim \mathcal{N}\left(\mu, \frac{1}{m^2} m\sigma^2\right) = \mathcal{N}\left(\mu, \frac{1}{m} \sigma^2\right).$$

On applique ensuite le changement vers loi normale réduite :

$$\bar{\omega}_m - \mu \sim \mathcal{N}\left(0, \frac{1}{m} \sigma^2\right).$$

Ainsi en divisant par l'écart-type $\sigma/\sqrt{m}$ on obtient :

$$\frac{\sqrt{m}}{\sigma}(\bar{\omega}_m - \mu) \sim \mathcal{N}(0, 1).$$

□

Intervalle de confiance pour la moyenne μ quand écart-type σ est connu

Grâce à la statistique pivotale, nous avons le résultat suivant.

Théorème 8.12. Soient des variables aléatoires réelles $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ et $\delta \in (0, 1)$. Nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)} \left[|\bar{\omega}_m - \mu| \leq q_{1-\delta/2} \frac{\sigma}{\sqrt{m}} \right] = \mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)} \left[\mu \in \left[\bar{\omega}_m \pm q_{1-\delta/2} \frac{\sigma}{\sqrt{m}} \right] \right] = 1 - \delta.$$

où $q_{1-\delta/2}$ est le quantile d'ordre $1 - \delta/2$ de $\mathcal{N}(0, 1)$.

Démonstration. Tout d'abord, nous avons :

$$\begin{aligned} \mathbb{P} \left[\frac{\sqrt{m}}{\sigma}(\bar{\omega}_m - \mu) \in [0 \pm q_{\delta/2}] \right] &= 1 - \mathbb{P} \left[\frac{\sqrt{m}}{\sigma}(\bar{\omega}_m - \mu) \leq q_{\delta/2} \right] - \mathbb{P} \left[\frac{\sqrt{m}}{\sigma}(\bar{\omega}_m - \mu) \geq q_{1-\delta/2} \right] \\ &= 1 - 2 \mathbb{P} \left[\frac{\sqrt{m}}{\sigma}(\bar{\omega}_m - \mu) \geq q_{\delta/2} \right] \\ &= 1 - 2\delta/2 \\ &= 1 - \delta. \end{aligned}$$

Enfin nous avons :

$$\mathbb{P} \left[\frac{\sqrt{m}}{\sigma}(\bar{\omega}_m - \mu) \in [0 \pm q_{\delta/2}] \right] = \mathbb{P} \left[\mu \in \left[\bar{\omega}_m \pm q_{1-\delta/2} \frac{\sigma}{\sqrt{m}} \right] \right].$$

□

Du coup, lorsque l'on fixe $\delta = 0.05$, nous obtenons le résultat.

Exemple 8.13.

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)} \left[|\bar{\omega}_m - \mu| \leq 1.96 \frac{\sigma}{\sqrt{m}} \right] = 1 - 0.05,$$

où $1.96 \frac{\sigma}{\sqrt{m}}$ est un intervalle de confiance pour l'espérance inconnue μ de niveau de confiance 0.95.

Nous pouvons également étendre le résultat lorsque σ est inconnu.

Proposition 8.14 (intervalle de confiance pour la moyenne μ quand écart-type σ est inconnu). Soient des variables aléatoires réelles $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ et $\delta \in (0, 1)$. Nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} \left[|\bar{\omega}_m - \mu| \leq q_{1-\delta/2} \frac{S_m}{\sqrt{m}} \right] = 1 - \delta,$$

où $q_{1-\delta/2}$ est le quantile d'ordre $1 - \delta/2$ de la loi de Student à $m - 1$ degré de liberté, et où S_m^2 est l'estimateur sans biais de la variance des $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$.

8.3 Inégalité de concentration

Lorsque la distribution μ est complètement inconnue, nous ne pouvons pas utiliser la technique du quantile. Par contre, nous pouvons utiliser des inégalités de concentration !

Définition 8.15 (Inégalités de concentration). Soient une variable aléatoire réelle $\omega \sim \mu$ et une fonction $\phi : \mathbb{R} \rightarrow \mathbb{R}$. Une inégalité de concentration est définie de la manière suivante :

$$\mathbb{P}_{\omega \sim \mu} [\omega \geq \varepsilon] \leq \phi(\varepsilon) \quad \text{et} \quad \mathbb{P}_{\omega \sim \mu} [\omega \leq \phi^{-1}(\delta)] \geq 1 - \delta.$$

Les inégalités de concentration sont beaucoup utilisées : nous pouvons les retrouver en apprentissage statistique, pour l'analyse d'algorithmes aléatoires, en théorie de l'information et en physique statistique. Nous allons voir, l'inégalité de Markov, de Chebychev, de Chernoff, et de Hoeffding. Nous allons maintenant voir pleiiiiinnss d'inégalités pour arriver à l'inégalité de Hoeffding.

Théorème 8.16 (Inégalité de Hoeffding). Pour toute variable aléatoire bornée $\omega \sim \mu$ telle que $\omega \in [0, 1]$ presque sûrement, pour tout $\varepsilon > 0$ et $\delta \in (0, 1]$, nous avons

$$\mathbb{P}_{\omega_1 \sim \mu, \dots, \omega_m \sim \mu} \left[|\bar{\omega}_m - \mathbb{E}_{\omega \sim \mu} [\omega]| \geq \varepsilon \right] \leq 2 \exp(-2m\varepsilon^2) \quad \text{et} \quad \mathbb{P}_{\omega_1 \sim \mu, \dots, \omega_m \sim \mu} \left[|\bar{\omega}_m - \mathbb{E}_{\omega \sim \mu} [\omega]| \leq \sqrt{\frac{\ln(\frac{2}{\delta})}{2m}} \right] \geq 1 - \delta.$$

L'inégalité la plus basique (celle que je préfère !) est l'inégalité de Markov.

Définition 8.17 (Inégalité de Markov). Pour toute variable aléatoire positive $\omega \sim \mu$, pour tout $\varepsilon > 0$ et $\delta \in (0, 1]$, nous avons

$$\mathbb{P}_{\omega \sim \mu} [\omega \geq \varepsilon] \leq \frac{\mathbb{E}_{\omega \sim \mu} [\omega]}{\varepsilon} \quad \text{et} \quad \mathbb{P}_{\omega \sim \mu} \left[\omega \leq \frac{1}{\delta} \mathbb{E}_{\omega \sim \mu} [\omega] \right] \geq 1 - \delta.$$

Démonstration. Remarquons que pour tout $\omega > 0$ et $\varepsilon > 0$, nous avons

$$\varepsilon \mathbb{1}[\omega \geq \varepsilon] \leq \omega \iff \mathbb{1}[\omega \geq \varepsilon] \leq \frac{\omega}{\varepsilon}.$$

En prenant l'espérance, on obtient le résultat

$$\mathbb{P}_{\omega \sim \mu} [\omega \geq \varepsilon] = \mathbb{E}_{\omega \sim \mu} [\mathbb{1}[\omega \geq \varepsilon]] \leq \frac{\mathbb{E}_{\omega \sim \mu} [\omega]}{\varepsilon}.$$

□

A partir de l'inégalité de Markov, nous pouvons obtenir plusieurs inégalités : celle de Chebyshev et de Chernoff.

Théorème 8.18 (Inégalité de Chebyshev). Pour toute variable aléatoire réelle $\omega \sim \mu$, pour tout $\varepsilon > 0$ et $\delta \in (0, 1]$, nous avons

$$\mathbb{P}_{\omega \sim \mu} \left[|\omega - \mathbb{E}_{\omega \sim \mu} [\omega]| \geq \varepsilon \right] \leq \frac{\mathbb{V}_{\omega \sim \mu} [\omega]}{\varepsilon^2} \quad \text{et} \quad \mathbb{P}_{\omega \sim \mu} \left[|\omega - \mathbb{E}_{\omega \sim \mu} [\omega]| \leq \sqrt{\frac{1}{\delta} \mathbb{V}_{\omega \sim \mu} [\omega]} \right] \geq 1 - \delta.$$

Démonstration. Appliquer l'inégalité de Markov avec $(\omega - \mathbb{E}_{\omega \sim \mu} [\omega])^2$ (au lieu de ω) et ε^2 (au lieu de ε). $\square$

Théorème 8.19 (Inégalité de Chernoff). Pour toute variable aléatoire réelle $\omega \sim \mu$, pour tout $\varepsilon > 0$ et $\delta \in (0, 1]$, nous avons pour tout $t > 0$

$$\mathbb{P}_{\omega \sim \mu} [\omega \geq \varepsilon] \leq \frac{\mathbb{E}_{\omega \sim \mu} [e^{t\omega}]}{e^{t\varepsilon}} \quad \text{et} \quad \mathbb{P}_{\omega \sim \mu} \left(\omega \leq \frac{1}{t} \ln \left(\frac{1}{\delta} \mathbb{E}_{\omega \sim \mu} [e^{t\omega}] \right) \right) \geq 1 - \delta.$$

Démonstration. Appliquer l'inégalité de Markov avec $\exp(t\omega)$ (au lieu de ω) et $\exp(-t\varepsilon)$ (au lieu de ε). $\square$

Le terme $\mathbb{E}_{\omega \sim \mu} [e^{t\omega}]$ est connu dans la littérature.

Définition 8.20 (Fonction génératrice des moments). Soit une variable aléatoire réelle $\omega \sim \mu$. La fonction génératrice des moments est la fonction suivante :

$$M_\mu(t) = \mathbb{E}_{\omega \sim \mu} [e^{t\omega}].$$

Exemple (Inégalité de Chernoff). En utilisant la notation $M_\mu(t)$ dans l'inégalité de Chernoff, nous obtenons la borne suivante :

$$\mathbb{P}_{\omega \sim \mu} \left(\omega \leq \frac{1}{t} \ln \left(\frac{1}{\delta} M_\mu(t) \right) \right) \geq 1 - \delta$$

La fonction génératrice des moments pour une variable gaussienne est connue.

Exemple (Variable aléatoire gaussienne). Si $\omega \sim \mathcal{N}(\mu, \sigma^2)$ alors

$$M_{\mathcal{N}(\mu, \sigma^2)}(t) = \mathbb{E}_{\omega \sim \mathcal{N}(\mu, \sigma^2)} [e^{t\omega}] = \exp \left(t\mu + \frac{\sigma^2 t^2}{2} \right).$$

Certaines variables aléatoires vont respecter une propriété sur $M_\mu(t)$. Voici la plus connue.

Définition 8.21 (Variable aléatoire σ^2 -sous-gaussienne). Si $\omega \sim \mu$ est σ^2 -sous-gaussienne alors

$$M_\mu(t) = \mathbb{E}_{\omega \sim \mu} [e^{t\omega}] \leq \exp \left(t \cdot \mathbb{E}_{\omega \sim \mu} [\omega] + \frac{\sigma^2 t^2}{2} \right)$$

Nous pouvons aussi borner la fonction génératrice des moments d'une variable aléatoire bornée grâce au lemme de Hoeffding.

Lemme 8.22 (Lemme de Hoeffding). Soit une variable aléatoire réelle $\omega \sim \mu$ telle que $\mathbb{E}_{\omega \sim \mu} [\omega] = 0$ et $\mathbb{P}_{\omega \sim \mu} [a \leq \omega \leq b] = 1$ (où $a \leq b$). Alors, pour tout $t > 0$, nous avons

$$\mathbb{E}_{\omega \sim \mu} [e^{t\omega}] \leq \exp \left(\frac{t^2 (b-a)^2}{8} \right).$$

Grâce à l'hypothèse de sous-gaussianité, nous pouvons dériver le résultat suivant (qui est très proche du théorème de Hoeffding).

Corollaire 8.23 (Inégalité de Chernoff pour les variables aléatoires σ^2 -sous-gaussiennes). Pour toute variable aléatoire σ^2 -sous-gaussienne $\omega \sim \mu$ où $\mathbb{E}_{\omega \sim \mu}[\omega] = 0$, pour tout $\varepsilon > 0$ et $\delta \in (0, 1]$, nous avons

$$\mathbb{P}_{\omega \sim \mu}[\omega \geq \varepsilon] \leq \exp\left(-\frac{\varepsilon^2}{2\sigma^2}\right) \quad \text{et} \quad \mathbb{P}_{\omega \sim \mu}\left[\omega \leq \sigma\sqrt{2\ln\left(\frac{1}{\delta}\right)}\right] \geq 1 - \delta.$$

Démonstration. On applique l'inégalité de Chernoff et on utilise $\mathbb{E}_{\omega \sim \mu}[e^{t\omega}] \leq \exp\left(\frac{\sigma^2 t^2}{2}\right)$ puis on trouve le t optimal. $\square$

Grâce au théorème précédent nous avons une généralisation de l'inégalité de Hoeffding.


Théorème 8.24 (Inégalité de Hoeffding "généralisée"). Pour toute variable aléatoire σ^2 -sous-gaussienne $|\omega - \mathbb{E}_{\omega \sim \mu}[\omega]|$ avec $\omega \sim \mu$, pour tout $\varepsilon > 0$ et $\delta \in (0, 1]$, nous avons


$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} \left[\left| \bar{\omega}_m - \mathbb{E}_{\omega \sim \mu}[\omega] \right| \geq \varepsilon \right] \leq 2 \exp\left(-\frac{m\varepsilon^2}{2\sigma^2}\right) \text{ et } \mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} \left[\left| \bar{\omega}_m - \mathbb{E}_{\omega \sim \mu}[\omega] \right| \leq \sigma\sqrt{\frac{2\ln\left(\frac{2}{\delta}\right)}{m}} \right] \geq 1 - \delta.$$

Démonstration. D'abord, on montre $|\bar{\omega}_m - \mathbb{E}_{\omega \sim \mu}[\omega]|$ est σ^2/m -sous-gaussienne :

$$\begin{aligned} \mathbb{E}_{\omega_1 \sim \mu, \dots, \omega_m \sim \mu} [e^{t|\bar{\omega}_m - \mathbb{E}_{\omega \sim \mu}[\omega]|}] &\leq \mathbb{E}_{\omega_1 \sim \mu, \dots, \omega_m \sim \mu} [e^{\frac{t}{m} \sum_{i=1}^m |\omega_i - \mathbb{E}_{\omega \sim \mu}[\omega]|}] \\ &\leq \exp\left(\frac{\sigma^2 t^2}{2m}\right). \end{aligned}$$

Enfin, on applique Corollaire 8.23 avec la variable aléatoire $|\bar{\omega}_m - \mathbb{E}_{\omega \sim \mu}[\omega]|$. $\square$





Voici, enfin (!), l'inégalité de Hoeffding.

Théorème 8.25 (Inégalité de Hoeffding). Pour toute variable aléatoire bornée $\omega \sim \mu$ telle que $\omega \in [0, 1]$ presque sûrement, pour tout $\varepsilon > 0$ et $\delta \in (0, 1]$, nous avons

$$\mathbb{P}_{\omega_1 \sim \mu, \dots, \omega_m \sim \mu} \left[|\bar{\omega}_m - \mathbb{E}_{\omega \sim \mu} [\omega]| \geq \varepsilon \right] \leq 2 \exp(-2m\varepsilon^2) \text{ et } \mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} \left[|\bar{\omega}_m - \mathbb{E}_{\omega \sim \mu} [\omega]| \leq \sqrt{\frac{\ln(\frac{2}{\delta})}{2m}} \right] \geq 1 - \delta.$$

Démonstration. On utilise le lemme de Hoeffding qui montre que

$$\mathbb{E}_{\omega \sim \mu} \left[e^{t|\omega - \mathbb{E}_{\omega \sim \mu} [\omega]|} \right] \leq \exp\left(\frac{t^2}{8}\right),$$

et donc que $|\omega - \mathbb{E}_{\omega \sim \mu} [\omega]|$ est $\frac{1}{2}$ -sous-gaussienne. Enfin, on peut appliquer l'inégalité de Hoeffding "généralisée". $\square$

8.4 Autres inégalités (utiles !)

Voici une inégalité super utile : l'inégalité de Jensen.

Théorème 8.26 (Inégalité de Jensen). Soient une variable aléatoire $\omega \sim \mu$ et f une fonction convexe $f : \Omega \rightarrow \mathbb{R}$. Nous avons

$$f\left(\mathbb{E}_{\omega \sim \mu} [\omega]\right) \leq \mathbb{E}_{\omega \sim \mu} [f(\omega)].$$

Remarque 8.27. Soient une variable aléatoire $\omega \sim \mu$ et f une fonction concave $f : \Omega \rightarrow \mathbb{R}$. Nous avons

$$\mathbb{E}_{\omega \sim \mu} [f(\omega)] \leq f\left(\mathbb{E}_{\omega \sim \mu} [\omega]\right).$$

Grâce à l'inégalité de Jensen, nous pouvons dériver une autre inégalité utile : l'inégalité de Hölder.

Théorème 8.28 (Inégalité de Hölder). Soient $\omega \sim \mu$, $p, q \in [1, +\infty]$ avec $\frac{1}{p} + \frac{1}{q} = 1$, et $f : \Omega \rightarrow \mathbb{R}$, $g : \Omega \rightarrow \mathbb{R}$ deux fonctions mesurables. Nous avons

$$\mathbb{E}_{\omega \sim \mu} [|f(\omega)g(\omega)|] \leq \mathbb{E}_{\omega \sim \mu} [|f(\omega)|^p]^{\frac{1}{p}} \cdot \mathbb{E}_{\omega \sim \mu} [|g(\omega)|^q]^{\frac{1}{q}}.$$

L'inégalité de Hölder permet de trouver deux autres inégalités connues.

Corollaire 8.29 (Inégalité de Cauchy-Schwartz). Soient $\omega \sim \mu$, $p \in [1, +\infty]$, et $f : \Omega \rightarrow \mathbb{R}$, $g : \Omega \rightarrow \mathbb{R}$ deux fonctions mesurables. Nous avons

$$\left| \mathbb{E}_{\omega \sim \mu} [f(\omega)g(\omega)] \right|^2 \leq \mathbb{E}_{\omega \sim \mu} [f(\omega)^2] \cdot \mathbb{E}_{\omega \sim \mu} [g(\omega)^2] .$$

Démonstration. On applique l'inégalité de Hölder avec $p = 2$. □

Corollaire 8.30 (Inégalité de Minkowski). Soient $\omega \sim \mu$, $p \in [1, +\infty]$, et $f : \Omega \rightarrow \mathbb{R}$, $g : \Omega \rightarrow \mathbb{R}$ deux fonctions mesurables. Nous avons

$$\left(\mathbb{E}_{\omega \sim \mu} [|f(\omega) + g(\omega)|^p] \right)^{\frac{1}{p}} \leq \left(\mathbb{E}_{\omega \sim \mu} [|f(\omega)|^p] \right)^{\frac{1}{p}} + \left(\mathbb{E}_{\omega \sim \mu} [|g(\omega)|^p] \right)^{\frac{1}{p}} .$$

Chapitre 9

Apprentissage statistique

9.1 Introduction

Introduction

Dans le chapitre précédent, nous avons vu le problème de l'estimation en statistique qui est le suivant.

Problème de l'estimation

- **Hypothèses :**

1. Une distribution $\mathcal{D}_\theta$ sur X paramétrée par des paramètres $\theta \in \Theta$ inconnus.
2. On dispose de données $x_1, \dots, x_m \sim \mathcal{D}_\theta$.

- **Objectif :** Approcher la valeur des paramètres θ en construisant un estimateur $\hat{\theta} \in \Theta$ qui minimise

$$\min_{\hat{\theta} \in \Theta} \|\hat{\theta} - \theta\| \quad \text{où } \|\cdot\| \text{ est une norme sur } \Theta.$$

Nous allons voir comment élargir le problème de l'estimation aux problèmes d'apprentissage statistique que l'on peut rencontrer sur des données où une (simple) estimation ne permet pas de poser un modèle correct sur les données.

Apprentissage en général

L'apprentissage statistique consiste à construire des modèles capables de prédire ou d'expliquer un phénomène à partir des données. Nous pouvons en règle générale, définir l'apprentissage de la manière suivante.¹

Apprentissage

- **Hypothèses sur les données :**

1. Une distribution $\mathcal{D}$ sur un ensemble d'exemples Z
2. Echantillon de données $\mathcal{S} = (z_1, \dots, z_m) \sim \mathcal{D}^{\otimes m}$

- **Hypothèse sur le modèle :**

1. Ensemble de modèles $H \subseteq \{h : Z \rightarrow Y\}$

- **Hypothèses pour évaluer la qualité du modèle :**

1. Fonction optimale $h^* : Z \rightarrow Y^*$
2. Fonction de perte $\ell : Y \times Y^* \rightarrow \mathbb{R}$ pour évaluer la qualité de $h \in H$ par rapport à h^*

- **Objectif :** Trouver une fonction $h \in H$ afin de minimiser

$$\frac{1}{m} \sum_{i=1}^m \ell(h(z_i), h^*(z_i))$$

¹Attention, c'est indigeste, mais nous allons voir des exemples.

9.2 Apprentissage non supervisé

Apprentissage non supervisé

Nous pouvons spécifier le cadre d'apprentissage à l'apprentissage non supervisé.

Apprentissage non supervisé

- **Hypothèse supplémentaire** : la fonction optimale $h^* : Z \rightarrow Y^*$ est soit
 1. inconnue
 2. construite à la main
- **Objectif** : Trouver une fonction $h \in H$ afin de minimiser

$$\frac{1}{m} \sum_{i=1}^m \ell(h(z_i), h^*(z_i))$$

Estimation

L'estimation en statistique est un exemple (très simple) d'apprentissage non supervisé.

Problème de l'estimation

- **Hypothèse sur le modèle** :
 1. Ensemble de modèle $H = \{z \mapsto \hat{\theta}(z_1, \dots, z_m) \mid (z_1, \dots, z_m) \in Z^m\}$
- **Hypothèses pour évaluer la qualité du modèle** :
 1. Fonction optimale $h^* : z \mapsto \theta$
 2. Fonction de perte $\|\cdot\|$ est la norme sur Θ

Exemples d'apprentissage non supervisé

Voici des exemples d'apprentissage non supervisé (parmi beaucoup d'autres) :

- **Estimation** : Maximisation de la vraisemblance, Méthode des moments ;
- **Clustering** : *Algorithme des k-moyennes*, Algorithme espérance-maximisation ;
- **Visualisation de données** : Analyse en composantes principales, Algorithme t-SNE ;
- **Estimation de densités** : Méthode de Parzen-Rosenblatt.


Nous allons voir un peu plus en détails l'algorithme des k -moyennes.

Problème de clustering

Problème de clustering

Entrée : des données $z_1, \dots, z_m \sim \mathcal{D}$ où $\mathcal{D}$ est une distribution sur Z

Sortie : une fonction $h : Z \rightarrow \{1, \dots, K\}$ permettant de partitionner les données en K clusters



Définition 9.1 (Partition en clusters). On partitionne l'ensemble des données :

$$\{x_1, \dots, x_m\} = \bigsqcup_{k=1}^K C_k,$$

avec $C_k \neq \emptyset$.

Définition 9.2 (Cluster). Chaque ensemble C_k est appelé un cluster.

Définition 9.3 (Centroïde). Le centroïde du cluster C_k est défini par

$$\mu_{C_k} := \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

Problème de clustering

- **Hypothèse sur le modèle :**

1. Ensemble de modèle $H \subseteq \cup_{k \in \mathbb{N}^*} \{h : Z \rightarrow \{1, \dots, K\}\}$

- **Hypothèses pour évaluer la qualité du modèle :**

1. Clustering optimal (et inconnu) $h^* : Z \rightarrow \{1, \dots, K\}$
2. Fonction de perte $y, y^* \mapsto \mathbb{1}[y \neq y^*]$ appelé perte 0-1

Algorithme des k -moyennes

Problème des k -moyennes

Entrée : des données $x_1, \dots, x_m \in \mathbb{R}^p$

Sortie : une partition en K clusters $C_1, \dots, C_K$ qui minimise

$$\sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_{C_k}\|_2^2.$$

Algorithme de Lloyd (Pseudo-code)

Algorithme de Lloyd

1. Choisir aléatoirement K centres $\mu_1, \dots, \mu_K$ (parmi les données).
2. **Tant que la partition change :**
 - (a) Pour chaque donnée x_i , assigner x_i au cluster C_k tel que $k = \arg \min_j \|x_i - \mu_j\|_2$.
 - (b) Pour chaque cluster C_k , mettre à jour le centroïde :

$$\mu_k := \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

3. Sortie : la partition $\{C_1, \dots, C_K\}$.

9.3 Apprentissage supervisé

Apprentissage supervisé

Apprentissage supervisé

- **Hypothèses sur les données :**

1. Un exemple $z_i = (\mathbf{x}_i, y_i) \in X \times Y = Z$ est un couple entrée/sortie
2. Echantillon de données $\mathcal{S} = (z_1, \dots, z_m) \sim \mathcal{D}^{\otimes m}$

- **Hypothèse sur le modèle :**

1. Ensemble de modèle $H \subseteq \{h : X \rightarrow Y'\}$


- **Hypothèses pour évaluer la qualité du modèle :**

1. Fonction optimale $(x, y) \mapsto y$
2. Fonction de perte $\ell : Y' \times Y \rightarrow \mathbb{R}$ pour évaluer la qualité de $h \in H$

- **Objectif :** Trouver une fonction $h \in H$ afin de minimiser

$$\frac{1}{m} \sum_{i=1}^m \ell(h(\mathbf{x}_i), y_i)$$

Nous ne verrons pas le problème dans le cours, mais lorsque nous apprenons un modèle $h \in H$, nous pouvons rencontrer deux types de problèmes : le sous-apprentissage ou le sur-apprentissage.



Le sous-apprentissage se produit lorsque le modèle est trop simple pour saisir la complexité réelle des données, ce qui entraîne une performance médiocre sur les données. A l'inverse, le sur-apprentissage survient lorsqu'un modèle trop "complexe" s'ajuste excessivement aux données, au point de perdre sa capacité à généraliser sur le problème réel (la distribution $\mathcal{D}$).

Apprentissage supervisé

Il existe beaaaaaauuuuuucoup de modèles ! Voici des exemples séparés en deux types.

- **Modèles paramétriques :** Modèle entièrement décrit par un nombre fixe de paramètres

- Régression linéaire ;
- Régression logistique ;
- Réseaux de neurones

- **Modèles non-paramétriques :** Modèle non décrit par des paramètres

- k -plus proches voisins ;
- Arbres de décision ;
- Méthodes à noyaux

Nous allons voir un exemple dans la suite : la régression linéaire.

Régression linéaire

Voici comment nous pouvons présenter le problème de la régression linéaire.

Régression linéaire

Entrée : des données $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m) \in \mathbb{R}^p \times \mathbb{R}$

Sortie : trouver $\boldsymbol{\theta} = (\theta^0, \theta^1, \dots, \theta^p) \in \mathbb{R}^{p+1}$ qui minimise

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^{p+1}} \left\{ \mathcal{J}(\boldsymbol{\theta}) = \sum_{i=1}^m \left[y_i - (\theta^0 + \theta^1 x_i^1 + \dots + \theta^p x_i^p) \right]^2 \right\}.$$

Autrement dit, on cherche à modéliser $y \in \mathbb{R}$ comme une combinaison linéaire des composantes de $\mathbf{x} \in \mathbb{R}^p$. Nous pouvons trouver la solution du problème d'optimisation de façon analytique. Pour cela, nous avons besoin de représenter les données sous la forme d'une matrice et d'un vecteur.

Définition 9.4 (Matrice des données). La matrice des données s'écrit

$$\mathbf{X} = \begin{pmatrix} 1 & x_1^1 & \dots & x_1^p \\ \vdots & \vdots & & \vdots \\ 1 & x_m^1 & \dots & x_m^p \end{pmatrix} \in \mathbb{R}^{m \times (p+1)} \quad \text{et} \quad \mathbf{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix} \in \mathbb{R}^m.$$

Chaque ligne correspond à une observation (avec la première colonne composée de 1 pour le terme constant).

Ensuite, nous pouvons trouver le paramètre optimal pour ces données.

Théorème 9.5. Si $\mathbf{X}^\top \mathbf{X}$ est inversible, alors l'estimateur par moindres carrés est

$$\boldsymbol{\theta}^* = \operatorname{argmax}_{\boldsymbol{\theta} \in \mathbb{R}^{p+1}} \mathcal{J}(\boldsymbol{\theta}) \quad \text{où} \quad \boldsymbol{\theta}^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Démonstration. La fonction à minimiser est

$$\mathcal{J}(\boldsymbol{\theta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\theta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}).$$

Le gradient est

$$\nabla_{\boldsymbol{\theta}} \mathcal{J}(\boldsymbol{\theta}) = -2\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\theta}).$$

En annulant le gradient, on obtient $\mathbf{X}^\top \mathbf{y} = \mathbf{X}^\top \mathbf{X}\boldsymbol{\theta}$, d'où le résultat. $\square$

Remarque 9.6. Si $\mathbf{X}^\top \mathbf{X}$ n'est pas inversible, on peut utiliser le pseudo-inverse (par exemple celui de Moore-Penrose) ou éliminer les features redondantes.

Cet estimateur a d'ailleurs une propriété intéressante.

Définition 9.7 (BLUE). Un estimateur linéaire non biaisé $\boldsymbol{\theta}^*$ est dit *BLUE* (Best Linear Unbiased Estimator) s'il possède la plus petite variance parmi tous les estimateurs linéaires non biaisés.

Théorème 9.8 (Théorème de Gauss-Markov). Si nous avons la relation suivante :

$$\forall x \in X, \quad y = \mathbf{x}^T \boldsymbol{\theta} + \varepsilon.$$

avec $\mathbb{E}_{\varepsilon \sim \mu}[\varepsilon] = 0$ et $\mathbb{V}_{\varepsilon \sim \mu}(\varepsilon) = \sigma^2$, l'estimateur

$$\theta^* = \underset{\theta \in \mathbb{R}^{p+1}}{\operatorname{argmax}} \mathcal{J}(\theta) \quad \text{où} \quad \theta^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

est le BLUE.

9.4 Généralisation et théorie de l'apprentissage

Risque vrai et risque empirique

Définitions

Soit une fonction de perte $\ell : Y' \times Y \rightarrow \mathbb{R}_+$.

- **Risque vrai (erreur de généralisation) :**

$$\mathcal{R}(h) = \mathbb{E}_{z \sim \mathcal{D}} [\ell(h, z)]$$

- **Risque empirique :**

$$\hat{\mathcal{R}}_m(h) = \frac{1}{m} \sum_{i=1}^m \ell(h, z_i)$$

Problème : $\mathcal{D}$ est inconnue $\Rightarrow$ on ne peut pas calculer $\mathcal{R}(h)$.

On minimise donc $\hat{\mathcal{R}}_m(h)$ (principe ERM).

Principe ERM et question centrale

Empirical Risk Minimization (ERM)

$$h_m = \arg \min_{h \in H} \hat{\mathcal{R}}_m(h)$$

Question fondamentale :

Est-ce que minimiser le risque empirique garantit un faible risque vrai ?

Autrement dit :

$$\mathcal{R}(h_m) \approx \min_{h \in H} \mathcal{R}(h)$$

C'est le problème de la **généralisation**.

Décomposition de l'erreur

Soit

$$h^* = \arg \min_{h \in H} \mathcal{R}(h)$$

Alors :

$$\mathcal{R}(h_m) - \mathcal{R}(h^*) = \underbrace{\mathcal{R}(h_m) - \hat{\mathcal{R}}_m(h_m)}_{\text{erreur d'estimation}} + \underbrace{\hat{\mathcal{R}}_m(h_m) - \hat{\mathcal{R}}_m(h^*)}_{\leq 0} + \underbrace{\hat{\mathcal{R}}_m(h^*) - \mathcal{R}(h^*)}_{\text{erreur d'estimation}}$$

Donc :

$$\mathcal{R}(h_m) - \mathcal{R}(h^*) \leq 2 \sup_{h \in H} |\mathcal{R}(h) - \hat{\mathcal{R}}_m(h)|$$

Il suffit donc de contrôler la déviation uniforme :

$$\sup_{h \in H} |\mathcal{R}(h) - \hat{\mathcal{R}}_m(h)|$$

Cas fini : $|H| = k$

On suppose $H = \{h_1, \dots, h_k\}$.

Inégalité de Hoeffding

Pour tout $h \in H$ et tout $\varepsilon > 0$:

$$\mathbb{P}(|\mathcal{R}(h) - \hat{\mathcal{R}}_m(h)| \geq \varepsilon) \leq 2e^{-2\varepsilon^2 m}$$

En utilisant l'inégalité de l'union :

$$\mathbb{P}\left(\sup_{h \in H} |\mathcal{R}(h) - \hat{\mathcal{R}}_m(h)| \geq \varepsilon\right) \leq 2ke^{-2\varepsilon^2 m}$$

Borne de généralisation (cas fini)

Fixons un niveau de confiance $\delta \in (0, 1)$.

Alors avec probabilité au moins $1 - \delta$:

$$\forall h \in H, \quad \mathcal{R}(h) \leq \hat{\mathcal{R}}_m(h) + \sqrt{\frac{1}{2m} \ln \frac{2k}{\delta}}$$

En particulier, pour h_m (ERM) :

$$\mathcal{R}(h_m) \leq \mathcal{R}(h^*) + 2\sqrt{\frac{1}{2m} \ln \frac{2k}{\delta}}$$

Interprétation de la borne

$$\mathcal{R}(h_m) \leq \mathcal{R}(h^*) + 2\sqrt{\frac{1}{2m} \ln \frac{2k}{\delta}}$$

La borne dépend de :

- m : nombre d'exemples (plus m est grand, mieux on généralise)
- $k = |H|$: complexité de l'espace d'hypothèses
- δ : niveau de confiance

Conclusion :

Plus H est complexe, plus il faut de données.

C'est une formulation mathématique du compromis biais-variance.

Cas infini : dimension VC

Lorsque H est infini, la cardinalité ne suffit plus.

Dimension VC

La dimension VC d_H est la taille du plus grand ensemble de points que H peut séparer de toutes les manières possibles.

Exemple :

Un classifieur linéaire en dimension p a :

$$d_H = p + 1$$

Borne avec dimension VC

Si H a une dimension VC d_H , alors avec probabilité au moins $1 - \delta$:

$$\mathcal{R}(h) \leq \hat{\mathcal{R}}_m(h) + \sqrt{\frac{d_H \ln\left(\frac{2m}{d_H}\right) + \ln\left(\frac{4}{\delta}\right)}{m}}$$

Pour l'ERM :

$$\mathcal{R}(h_m) \leq \mathcal{R}(h^*) + 2\sqrt{\frac{d_H \ln\left(\frac{2m}{d_H}\right) + \ln\left(\frac{4}{\delta}\right)}{m}}$$

Message clé

La généralisation dépend uniquement de la complexité de H et du nombre d'exemples m .

- Si $m \gg d_H$: bonne généralisation
- Si $d_H \gg m$: sur-apprentissage

Conséquence pratique :

Régularisation = contrôle de la complexité = amélioration de la généralisation.

ERM et biais d'optimisme

On rappelle :

$$h_m = \arg \min_{h \in H} \hat{\mathcal{R}}_m(h)$$

Question :

Est-ce que $\hat{\mathcal{R}}_m(h_m)$ est un estimateur non biaisé de $\mathcal{R}(h_m)$?

Réponse : Non.

En général,

$$\mathbb{E}[\hat{\mathcal{R}}_m(h_m)] \leq \mathbb{E}[\mathcal{R}(h_m)]$$

Le risque empirique est optimiste.

Pourquoi ce biais apparaît ?

Le problème vient du fait que :

$$h_m = \arg \min_{h \in H} \hat{\mathcal{R}}_m(h)$$

On choisit le modèle **qui minimise l'erreur sur l'échantillon.**

Donc :

- le modèle est adapté aux fluctuations aléatoires des données
- on "réutilise" les données pour évaluer le modèle

Conclusion :

Minimiser le risque empirique introduit un biais de sélection.

Rôle des bornes de généralisation

Comme $\hat{\mathcal{R}}_m(h_m)$ est biaisé, on cherche à contrôler :

$$|\mathcal{R}(h_m) - \hat{\mathcal{R}}_m(h_m)|$$

Les bornes de généralisation permettent de dire :

Avec grande probabilité, le risque vrai n'est pas trop loin du risque empirique.

Exemple (cas fini) :

$$\mathcal{R}(h) \leq \hat{\mathcal{R}}_m(h) + \sqrt{\frac{1}{2m} \ln \frac{2|H|}{\delta}}$$

En pratique : séparation des données

Les bornes théoriques sont souvent pessimistes.

En pratique, on sépare les données :

- $\mathcal{S}_{\text{train}}$: apprentissage du modèle
- $\mathcal{S}_{\text{test}}$: estimation du risque

On définit :

$$\hat{\mathcal{R}}_{\text{test}}(h) = \frac{1}{m_{\text{test}}} \sum_{z_i \in \mathcal{S}_{\text{test}}} \ell(h, z_i)$$

Borne avec ensemble de test

Supposons que :

- h est appris sur $\mathcal{S}_{\text{train}}$
- $\mathcal{S}_{\text{test}}$ est indépendant
- la perte est bornée dans $[0, 1]$

Alors (Hoeffding) :

$$\mathbb{P}\left(|\mathcal{R}(h) - \hat{\mathcal{R}}_{\text{test}}(h)| \geq \varepsilon\right) \leq 2e^{-2\varepsilon^2 m_{\text{test}}}$$

Interprétation

Avec probabilité au moins $1 - \delta$:

$$\mathcal{R}(h) \leq \hat{\mathcal{R}}_{\text{test}}(h) + \sqrt{\frac{1}{2m_{\text{test}}} \ln \frac{2}{\delta}}$$

Différence fondamentale :

- Pour ERM $\rightarrow$ borne dépend de $|H|$ ou d_H
- Pour test set $\rightarrow$ borne ne dépend pas de H

Pourquoi ?

Parce que h est fixé avant de regarder le test.

Résumé conceptuel

- Le risque empirique d'ERM est optimiste (biaisé)
- Les bornes uniformes contrôlent le biais de sélection
- En pratique : on sépare train / test
- Le test set donne une estimation non biaisée

Ne jamais évaluer un modèle sur les données utilisées pour l'entraîner.

Chapitre 10

Généralités sur les tests statistiques

10.1 Introduction

Dans ce chapitre, nous voulons répondre à des *questions binaires*.

Exemple. Voici deux exemples de questions binaires :

- Est-ce que ma pièce de monnaie est pipée ?
- Est-ce que le médicament est plus efficace qu'un placebo ?

Pour répondre à ces questions de recherche, on met en place des *expériences (aléatoires)* que l'on suppose bien conçue de façon à bien répondre à la question.

Exemple (Lancer de pièces). Lancer la pièce plusieurs fois.

Exemple (Efficacité d'un médicament). Tester le médicament sur un premier groupe de patients et le placebo sur un deuxième groupe.

10.2 Hypothèses

On considère une hypothèse privilégiée H_0 , considérée comme la plus vraisemblable, dont le rejet à tort est le plus préjudiciable.

Définition 10.1 (hypothèse nulle). L'hypothèse H_0 s'appelle l'*hypothèse nulle*.

L'autre hypothèse se note H_1 . On sait que soit H_0 ou H_1 est vraie. Souvent H_1 est la négation de H_0 , mais pas toujours.

Définition 10.2 (hypothèse alternative). L'hypothèse H_1 s'appelle l'*hypothèse alternative*.

Voici un exemple d'hypothèse nulle et alternative.

Exemple (Lancer de pièces). Soit un lancer de pièce $\omega \sim \mathcal{B}(p)$ où p est la probabilité de faire pile.

$$\begin{aligned} H_0 : & \quad p = \frac{1}{2} \quad (\text{la pièce est équilibrée}) \\ H_1 : & \quad p \neq \frac{1}{2} \quad (\text{la pièce est pipée}) \end{aligned}$$

Afin de "vérifier" l'hypothèse H_0 , nous allons utiliser un test statistique.

Définition 10.3 (test). Un *test statistique* est un algorithme qui répond au problème :

- **Entrée** : données $\omega_1, \dots, \omega_m$;
- **Sortie** : conserver H_0 , ou rejeter H_0 .

10.3 Un premier test

Généralement, un test statistique prend la forme suivante.

Algorithm 14 Test statistique (*informel*)

```
1: Entrée :  $\omega_1, \dots, \omega_m$ 
2: Sortie : Décision sur  $H_0$ 
3: Calculer une certaine quantité  $T(\omega_1, \dots, \omega_m)$ 
4: if la valeur  $T(\omega_1, \dots, \omega_m)$  est plausible selon  $H_0$  then
5:   Conserver  $H_0$ 
6: else
7:   Rejeter  $H_0$ 
8: end if
```

Exemple. Voici un exemple de test lorsque nous lançons 100 fois la même pièce.

Algorithm 15 Test pour le lancer de pièces

```
1: Calculer la statistique  $\hat{N} \leftarrow \sum_{i=1}^{100} \omega_i$ 
2: if  $\hat{N} \in [41, 59]$  then
3:   Conserver  $H_0$ 
4: else
5:   Rejeter  $H_0$ 
6: end if
```

Dans l'exemple précédent, nous avons utilisé l'intervalle $[41, 59]$. Ceci n'est pas dû au hasard¹ ! Voici comment choisir l'intervalle, dans le cas du lancer d'une pièce pipée, pour avoir un test valide.

Proposition 10.4. Supposons H_0 , c'est à dire que $p = \frac{1}{2}$. Alors $\omega_1, \dots, \omega_{100} \sim \mathcal{B}(1/2)$ et sont indépendantes. Alors $N = \sum_{i=1}^{100} \omega_i$ suit $\mathcal{B}(1/2, 100)$ et nous avons

$$\mathbb{P}_{N \sim \mathcal{B}(1/2, 100)} [N \in [41, 59]] = 0.95.$$

Ainsi, grâce à Proposition 10.4, nous pouvons caractériser la probabilité que le test prenne la mauvaise décision.

Corollaire 10.5. Si on suppose que H_0 est vraie et donc que $p = \frac{1}{2}$, alors nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_{100} \sim \mathcal{B}(p)} [\text{décision}(\omega_1, \dots, \omega_{100}) = \text{"Rejeter } H_0\text{"}] = 0.05.$$

Démonstration. Si on suppose que H_0 est vraie (et grâce à Proposition 10.4), nous avons

$$\begin{aligned} & \mathbb{P}_{\omega_1, \dots, \omega_{100} \sim \mathcal{B}(p)} [\text{décision}(\omega_1, \dots, \omega_{100}) = \text{"Rejeter } H_0\text{"}] \\ &= \mathbb{P}_{\omega_1, \dots, \omega_{100} \sim \mathcal{B}(1/2)} [\text{décision}(\omega_1, \dots, \omega_{100}) = \text{"Rejeter } H_0\text{"}] \\ &= \mathbb{P}_{\omega_1, \dots, \omega_{100} \sim \mathcal{B}(1/2)} \left[\sum_{i=1}^{100} \omega_i \notin [41, 59] \right] \\ &= \mathbb{P}_{N \sim \mathcal{B}(1/2, 100)} [N \notin [41, 59]] \\ &= 0.05. \end{aligned}$$

□

10.4 Intervalle de fluctuation


De manière générale, l'intervalle utilisé dans un test statistique (comme par exemple, $[41, 59]$) s'appelle un intervalle de fluctuation. Voici une définition plus générale.

¹Sans mauvais jeu de mots...

Définition 10.6. Soit $\omega \sim \mu$ une variable aléatoire réelle. Un *intervalle de fluctuation* au seuil de $1 - \alpha$ est un intervalle $I_\alpha(m)$ non aléatoire tel que

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} [T(\omega_1, \dots, \omega_m) \in I_\alpha(m)] \geq 1 - \alpha.$$

Exemple 10.7. Soit $\omega \sim \mathcal{N}(0, 1)$ alors $[-1.96, 1.96]$ est un intervalle de fluctuation au seuil de 95%. Le dessin suivant montre la fonction de densité de $\mathcal{N}(0, 1)$. L'aire coloriée est $\mathbb{P}_{\omega \sim \mu} [\omega \in [-1.96, 1.96]]$ et vaut environ 0.95.



Nous pouvons d'ailleurs définir le cas général.

Exemple 10.8. Soit $\omega \sim \mathcal{N}(\mu, \sigma^2)$ alors

$$[\mu \pm 1.96\sigma]$$

est un intervalle de fluctuation au seuil de 0.95.

Nous pouvons également prendre le cas d'une loi de Bernoulli $\mathcal{B}(p)$.

Exemple 10.9. Soit $\omega_1, \dots, \omega_m$ qui suivent une loi de Bernoulli $\mathcal{B}(p)$. On approxime $\frac{1}{m} \sum_{i=1}^m \omega_i$ via le théorème central limite par $\mathcal{N}(p, \frac{p(1-p)}{m})$. Ainsi, l'intervalle de fluctuation est

$$[p \pm 1.96 \sqrt{\frac{p(1-p)}{m}}].$$

au seuil de 0.95.

Nous pouvons directement utiliser cette intervalle de fluctuation dans un test statistique.

Algorithm 16 Test statistique (appliqué à un intervalle de fluctuation)

```

1: Paramètre : Seuil  $1 - \alpha$ 
2: Entrée :  $\omega_1, \dots, \omega_m$ 
3: Sortie : Décision sur  $H_0$ 
4: Calculer une certaine quantité  $T(\omega_1, \dots, \omega_m)$ 
5: if  $T(\omega_1, \dots, \omega_m) \in I_\alpha(m)$  then
6:   Conserver  $H_0$ 
7: else
8:   Rejeter  $H_0$ 
9: end if
```

L'avantage d'utiliser ce type de test est que l'on a directement une garantie sur la probabilité que le test prenne la mauvaise décision (si on suppose que l'hypothèse est vraie). En effet, nous avons la proposition suivante.

Proposition. Si on suppose que H_0 est vraie, alors nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} [\text{décision}(\omega_1, \dots, \omega_m) = \text{“Rejeter } H_0\text{”}] = \alpha.$$

Démonstration. En développant, nous obtenons :

$$\begin{aligned} & \mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} [\text{décision}(\omega_1, \dots, \omega_m) = \text{“Rejeter } H_0\text{”}] \\ &= \mathbb{P}_{\omega_1, \dots, \omega_m \sim \mu} [T(\omega_1, \dots, \omega_m) \notin I_\alpha(m)] \\ &= \alpha. \end{aligned}$$

□

10.5 Test Z

On suppose que les données proviennent d'une loi normale $\mathcal{N}(\mu, \sigma^2)$ de moyenne inconnue, mais de variance connue.

Hypothèse. Soit $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ où σ est connue. On suppose que l'on a

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0,$$

avec $\mu_0 \in \mathbb{R}$.

Ce cadre est assez restrictif, mais ce test a une vocation pédagogique, car on a besoin de rien connaître quasiment, à part les lois normales (pas besoin de connaître la loi de Student ici). Cette section est donc un préambule pour le test de Student, qui est similaire, sauf que l'on suppose que la variance est inconnue. Voici un exemple d'hypothèse sur des données “réelles”.

Exemple. On suppose que l'on a

$$H_0 : \mu = 42 \quad (\text{les longueurs de sardines sont en moyenne de 42cm})$$

$$H_1 : \mu \neq 42.$$


Afin de pouvoir créer le test, nous allons considérer la statistique suivante :

Proposition 10.10. Soient $(\omega_1, \dots, \omega_m)$ où $\omega_i \sim \mathcal{N}(\mu, \sigma^2)$ et

$$Z(\omega_1, \dots, \omega_m) := \sqrt{m} \frac{\bar{\omega}_m - \mu_0}{\sigma}.$$

Alors, sous l'hypothèse H_0 , nous avons $Z \sim \mathcal{N}(0, 1)$.

On sait alors qu'on a 95% de chances d'être dans la zone grise :



où les bords -1.96 et 1.96 sont respectivement les quantiles $q_{0.025} = q_{\alpha/2}$ et $q_{0.975} = q_{1-\alpha/2}$ pour $\alpha = 0.05$. De façon général, nous avons la proposition suivante (que l'on a déjà croisé dans le chapitre précédent).

Proposition 10.11. Sous l'hypothèse H_0 , nous avons $Z \sim \mathcal{N}(0, 1)$ et

- $\mathbb{P}_{Z \sim \mathcal{N}(0,1)} [Z \leq q_\alpha] = \alpha$;
- $\mathbb{P}_{Z \sim \mathcal{N}(0,1)} [Z \geq q_{1-\alpha}] = \alpha$;
- $\mathbb{P}_{Z \sim \mathcal{N}(0,1)} [|Z| \geq q_{1-\alpha/2}] = \alpha$.

Basé sur cette statistique, nous pouvons maintenant définir le test Z .

Algorithm 17 Test Z

```

1: Paramètre : Seuil  $1 - \alpha$ 
2: Entrée :  $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ 
3: Sortie : Décision sur  $H_0$ 
4: Calculer  $Z(\omega_1, \dots, \omega_m)$ 
5: if  $Z \in [-q_{1-\alpha/2}, q_{1-\alpha/2}]$  then
6:   Conserver  $H_0$ 
7: else
8:   Rejeter  $H_0$ 
9: end if
```

Etant donné que ce test utilise un intervalle de fluctuation, nous avons directement le théorème suivant.

Proposition. Si on suppose que H_0 est vraie, alors nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(0,1)} [\text{décision}(\omega_1, \dots, \omega_m) = \text{"Rejeter } H_0\text{"}] = \alpha.$$

Proposition. Si on suppose que H_0 est fausse (et donc H_1 est vraie), alors nous avons

$$\mathbb{P}_{\omega_1, \dots, \omega_m \sim \mathcal{N}(0,1)} [\text{décision}(\omega_1, \dots, \omega_m) = \text{"Rejeter } H_0\text{"}] = \mathbb{P}_{Z \sim \mathcal{N}(\mu - \mu_0, 1)} [|Z| \leq q_{1-\alpha/2}].$$

La *p-value* est la probabilité d'observer une statistique de test qui est au moins aussi extrême que celle obtenue avec les données, en supposant l'hypothèse H_0 . Dans le cas du test Z , elle est définie comme suit.

Définition 10.12. Soit $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ les données. La *p-value* est donnée par

$$\mathbb{P}_{\omega'_1, \dots, \omega'_m \sim \mathcal{N}(\mu_0, \sigma^2)} [|Z(\omega'_1, \dots, \omega'_m)| \geq |Z(\omega_1, \dots, \omega_m)|].$$

10.6 Test de Student

On présente le même cadre que le test Z , mais avec une variance inconnue. On sait que les données proviennent d'une loi normale $\mathcal{N}(\mu, \sigma^2)$, mais à la fois la moyenne μ et la variance σ^2 sont inconnues. On souhaite tester si $\mu = \mu_0$ pour une certaine constante μ_0 .

Hypothèse. Soit $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ où σ est connue. On suppose que l'on a

$$\begin{aligned} H_0 : & \mu = \mu_0 \\ H_1 : & \mu \neq \mu_0, \end{aligned}$$

avec $\mu_0 \in \mathbb{R}$.

On considère un échantillon $(\omega_1, \dots, \omega_m)$ où $\omega_i \sim \mathcal{N}(\mu, \sigma^2)$. On définit la statistique

$$Z = \sqrt{m} \frac{\bar{\omega}_m - \mu_0}{S_m}.$$

où S_m est l'estimateur sans biais de la variance.

De plus, nous connaissons la distribution associée à la statistique Z . Elle est donnée dans la proposition suivante.

Proposition. Si H_0 est vraie, alors $Z \sim t(n-1)$ où $t(n-1)$ est la loi de Student à $n-1$ degré de liberté.

De plus, nous avons la proposition suivante.

Proposition 10.13. Soit $Z \sim t(n-1)$. Alors, nous avons

- $\mathbb{P}_{Z \sim t(n-1)} [Z \leq q_\alpha] = \alpha$
- $\mathbb{P}_{Z \sim t(n-1)} [Z \geq q_{1-\alpha}] = \alpha$
- $\mathbb{P}_{Z \sim t(n-1)} [|Z| \geq q_{1-\alpha/2}] = \alpha$

Nous pouvons maintenant en déduire le test de Student.

Algorithm 18 Test de Student

```

1: Paramètre : Seuil  $1 - \alpha$ 
2: Entrée :  $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu, \sigma^2)$ 
3: Sortie : Décision sur  $H_0$ 
4: Calculer  $Z$  en fonction des observations
5: if  $|Z| \leq q_{1-\alpha/2}$  (où  $q_{1-\alpha/2}$  est le quantile de  $t(n-1)$ ) then
6:   Conserver  $H_0$ 
7: else
8:   Rejeter  $H_0$ 
9: end if

```

10.7 Tests pour échantillons indépendants

Test t de Student pour échantillons indépendants

Pour le test t de Student, nous allons faire les hypothèses suivantes.

Hypothèse. Nous supposons que nous avons deux échantillons $(\omega_1, \dots, \omega_m)$ et $(\omega'_1, \dots, \omega'_n)$ avec $\omega_i \sim \mathcal{N}(\mu_1, \sigma^2)$ et $\omega'_i \sim \mathcal{N}(\mu_2, \sigma^2)$. De plus, on suppose que l'on a

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2,$$

avec $\mu_0 \in \mathbb{R}$.

La statistique liée au test t de Student est

$$Z(\omega_1, \dots, \omega_m, \omega'_1, \dots, \omega'_n) = \frac{\bar{\omega}_m - \bar{\omega}'_n}{S \cdot \sqrt{\frac{1}{m} + \frac{1}{n}}} \quad \text{où} \quad s = \sqrt{\frac{(m-1)(S_m)^2 + (n-1)(S'_n)^2}{m+n-2}}$$

et suit une loi de Student $t(n+m-2)$.

Ainsi, nous pouvons en déduire le test t de Student pour échantillons indépendants.

Algorithm 19 Test t de Student pour échantillons indépendants

```
1: Paramètre : Seuil  $1 - \alpha$ 
2: Entrée :  $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu_1, \sigma^2)$  et  $\omega'_1, \dots, \omega'_n \sim \mathcal{N}(\mu_2, \sigma^2)$ 
3: Sortie : Décision sur  $H_0$ 
4: Calculer  $Z$  en fonction des observations
5: if  $|Z| \leq q_{1-\alpha/2}$  (où  $q_{1-\alpha/2}$  est le quantile de  $t(n+m-2)$ ) then
6:   Conserver  $H_0$ 
7: else
8:   Rejeter  $H_0$ 
9: end if
```

Test t de Welsh pour échantillons indépendants

Pour le test t de Welsh, nous allons faire les hypothèses suivantes.

Hypothèse. Nous supposons que nous avons deux échantillons $(\omega_1, \dots, \omega_m)$ et $(\omega'_1, \dots, \omega'_n)$ qui n'ont pas la même variance. Donc, nous allons avoir $\omega_i \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $\omega'_i \sim \mathcal{N}(\mu_2, \sigma_2^2)$. De plus, on suppose que l'on a

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2,$$

avec $\mu_0 \in \mathbb{R}$.

La statistique liée au test t de Welsh est

$$Z = \frac{\bar{\omega}_m - \bar{\omega}'_n}{\sqrt{\frac{(S_m)^2}{m} + \frac{(S'_n)^2}{n}}}$$

et suit une distribution de Student $t(d)$ où

$$d := \frac{\left(\frac{(S_m)^2}{m} + \frac{(S'_n)^2}{n}\right)^2}{\frac{((S_m)^2/m)^2}{m-1} + \frac{((S'_n)^2/n)^2}{n-1}}.$$

Ainsi, nous pouvons en déduire le test t de Welsh pour échantillons indépendants.

Algorithm 20 Test t de Welsh pour échantillons indépendants

```
1: Paramètre : Seuil  $1 - \alpha$ 
2: Entrée :  $\omega_1, \dots, \omega_m \sim \mathcal{N}(\mu_1, \sigma_1^2)$  et  $\omega'_1, \dots, \omega'_n \sim \mathcal{N}(\mu_2, \sigma_2^2)$ 
3: Sortie : Décision sur  $H_0$ 
4: Calculer  $Z$  en fonction des observations
5: if  $|Z| \leq q_{1-\alpha/2}$  (où  $q_{1-\alpha/2}$  est le quantile de  $t(d)$ ) then
6:   Conserver  $H_0$ 
7: else
8:   Rejeter  $H_0$ 
9: end if
```

10.8 Test de Kolmogorov-Smirnov

Ce test est souvent utilisé pour tester qu'un générateur aléatoire de nombres vérifie une certaine distribution μ représentée par une fonction de répartition continue $F_\mu : \mathbb{R} \rightarrow [0, 1]$.

Exemple 10.14. Est-ce que les données suivantes proviennent d'une loi normale centrée et réduite $\mathcal{N}(0, 1)$?

6.42, 5.23, -1.25, 0.12, -0.01, -1.02, 18.54, 0.06, -7.64, 2.85, -1.84, 0.74, -0.65, 0.24

Pour le test de Kolmogorov-Smirnov, nous allons faire les hypothèses suivantes.

Hypothèse. Soit des données $\omega_1, \dots, \omega_m \in \mathbb{R}$ générées par un générateur/phénomène. De plus, on suppose que l'on a

H_0 : Le générateur/phénomène suit une loi μ avec la fonction de répartition $F_\mu : \mathbb{R} \rightarrow [0, 1]$


H_1 : le générateur suit une autre loi.

Pour construire la statistique, nous devons construire une fonction de répartition empirique $F_{\omega_1, \dots, \omega_m}(\tau)$ à partir des données $\omega_1, \dots, \omega_m$ en attribuant une probabilité de $\frac{1}{m}$ à chacune des données. (Pour rappel, nous l'avons vu dans le théorème Glivenko-Cantelli.)

Définition. Étant donné des données $\omega_1, \dots, \omega_m \in \mathbb{R}$, on définit la *fonction de répartition empirique* :

$$F_{\omega_1, \dots, \omega_m}(\tau) = \frac{1}{m} \sum_{i=1}^m \mathbb{1}[\omega_i \leq \tau].$$

Le test consiste ensuite à comparer la fonction de répartition théorique F_μ (en rouge) avec la fonction de répartition empirique $F_{\omega_1, \dots, \omega_m}(\tau)$ (en bleu).



La fonction de répartition empirique (en bleu) $F_{\omega_1, \dots, \omega_m}$ est définie comme suit. Comme $F_{\omega_1, \dots, \omega_m}(\tau)$ est censé être la probabilité d'avoir une valeur plus petit que τ , on regarde la proportion de ω_i plus petit que τ , *i.e.*, le nombre de ω_i plus petit que τ divisé par m .

La statistique utilisée est la distance de convergence uniforme entre $F_{\omega_1, \dots, \omega_m}$ et F_μ .

Définition 10.15. La statistique est :

$$Z(\omega_1, \dots, \omega_m) = \sqrt{m} \|F_{\omega_1, \dots, \omega_m} - F_\mu\|_\infty,$$

où $\|F_{\omega_1, \dots, \omega_m} - F_\mu\|_\infty = \sup_{\tau \in \mathbb{R}} |F_{\omega_1, \dots, \omega_m}(\tau) - F_\mu(\tau)|$.

Définition 10.16. La *loi de Kolmogorov-Smirnov* KS est donnée par la fonction de répartition

$$F_{KS}(\tau) = 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} e^{-2k^2 \tau^2}.$$


Théorème 10.17. Si $\omega_1, \dots, \omega_m$ sont *i.i.d.* et de loi de fonction de répartition F_μ continue, alors

$$Z(\omega_1, \dots, \omega_m) \xrightarrow[m \rightarrow +\infty]{L} KS.$$

Nous pouvons donc en déduire le test de Kolmogorov-Smirnov.

Algorithm 21 Test de Kolmogorov-Smirnov

```
1: Paramètre : Seuil  $1 - \alpha$   
2: Entrée :  $\omega_1, \dots, \omega_m$   
3: Sortie : Décision sur  $H_0$   
4: Calculer  $Z$  en fonction des observations  
5: Soit  $q_{1-\alpha}$  le quantile d'ordre  $1 - \alpha$  de la loi de Kolmogorov  
6: if  $Z \leq q_{1-\alpha}$  then  
7:   Conserver  $H_0$   
8: else  
9:   Rejeter  $H_0$   
10: end if
```



Chapitre 11

Tests du χ^2

Dans le chapitre précédent . . .

Nous avons différents types de tests permettant de répondre à la question suivante :

Hypothèse. Soit $\omega_1, \dots, \omega_m \sim \mu_\theta$ où θ est inconnu. On suppose que l'on a

$$\begin{aligned} H_0 : & \theta = \theta_0 \\ H_1 : & \theta \neq \theta_0, \end{aligned}$$

avec θ_0 fixé.

Autrement dit, nous avons vu des tests permettant de vérifier si un paramètre $\theta = \theta_0$.

Motivation

Dans ce chapitre, on s'intéresse à d'autres tests. Voici, par exemple, ici un type de test auquel nous allons nous intéresser : le test d'adéquation à une distribution μ .

Hypothèse (Informelle). Soit $\omega_1, \dots, \omega_m$ des données. On suppose que l'on a

$$\begin{aligned} H_0 : & \omega_1, \dots, \omega_m \text{ suivent la loi } \mu, \\ H_1 : & \omega_1, \dots, \omega_m \text{ ne suivent pas la loi } \mu. \end{aligned}$$

Nous allons également étudier le test d'indépendance.

Hypothèse (Informelle). Soit $\omega_1, \dots, \omega_m$ des données. On suppose que l'on a

$$\begin{aligned} H_0 : & \omega_1, \dots, \omega_m \text{ sont indépendants,} \\ H_1 : & \omega_1, \dots, \omega_m \text{ ne sont pas indépendants.} \end{aligned}$$

Pour dériver ces tests du χ^2 , nous allons utiliser la même recette de cuisine que pour le chapitre précédent. En effet, nous allons d'abord :

1. Nous introduisons des statistiques qui ont la forme d'une distance au carrée :

$$Z_m = (\text{empirique}_1 - \text{théorique}_1)^2 + (\text{empirique}_2 - \text{théorique}_2)^2 + \dots,$$

2. Une telle statistique Z_m suit la loi dite du χ^2 avec un paramètre $k \in \mathbb{N}$,
3. Lorsque l'on fixe le seuil α , on peut ensuite considérer le quantile $q_{1-\alpha}$ de la loi du $\chi^2(k)$.

11.1 La loi du χ^2

Nous pouvons définir la loi du χ^2 de la manière suivante.

Définition 11.1. Soit k variables aléatoires $\omega_1, \dots, \omega_k \sim \mathcal{N}(0, 1)$. Alors la variable aléatoire

$$\omega = \sum_{i=1}^k \omega_i^2 \sim \chi^2(k),$$

où $\chi^2(k)$ est la loi du χ^2 à k degrés de liberté.

Nous pouvons également dériver la fonction de densité associée à la loi du χ^2 .

Définition 11.2. La loi du χ^2 à k degrés de liberté est de densité

$$\chi_k^2(x) = \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} x^{\frac{k}{2}-1} e^{-\frac{x}{2}},$$

avec $\Gamma(x) = \int_0^{+\infty} t^{x-1} e^{-t} dt$ la fonction ... Gamma.

11.2 Test d'adéquation à une loi donnée

On va tout d'abord considérer que les données suivent une loi μ qui est inconnue. Cependant, on pense très fortement que la loi suivie est donnée par μ_0 . C'est notre hypothèse nulle H_0 . Autrement dit, nous avons les hypothèses suivantes.

Hypothèse. Soit $\omega_1, \dots, \omega_m \sim \mu$ des données. On suppose que l'on a

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0.$$

où μ_0 est une distribution fixée.

Nous allons examiner le cas où la distribution est discrète.


Exemple (dé non pipé?). Soit $\omega_1, \dots, \omega_m \sim \mu$ des résultats de lancers d'un dé. On suppose que l'on a

$$H_0 : \mu = \mu_0, \quad \text{avec } \forall i \in \{1, \dots, 6\}, \mu_0(i) = \frac{1}{6}.$$

$$H_1 : \mu \neq \mu_0,$$

Nous pouvons réaliser plusieurs lancers afin de déterminer si le dé est pipé. Maintenant, avec $m = 600$ lancers, nous pouvons observer l'histogramme suivant.

Numéro tiré						
Effectif	88	109	107	94	105	97



Afin de dériver le test nous pouvons poser les notations suivantes :

- On considère $\omega_1, \dots, \omega_m$ des variables aléatoires à valeurs dans $\{1, \dots, k\}$, *i.i.d.* selon la distribution μ ,
- On note $N_i(m)$ la variable aléatoire qui vaut le nombre de fois où l'on obtient un élément dans la classe i sur les premiers m lancers aléatoires.

Nous pouvons instancier ces valeurs dans le cas des lancers d'un dé.

Exemple (lancers d'un dé). *Nous avons*

- Les variables aléatoires $\omega_t \sim \mu$ sont à valeurs dans $\{1, \dots, 6\}$,
- ω_t est la valeur du dé associé au t -ème lancer,
- $N_i(m)$ est le nombre de i obtenus sur les m lancers.

La définition qui suit donne la statistique utilisée pour faire le test. C'est cette statistique dont on va étudier la loi. Elle est définie comme une mesure d'erreurs par rapport à l'idéal. La quantité $N_i(m)$ est le nombre (empirique) de fois que l'on tombe dans la classe i , alors que $m\mu(i)$ est le nombre théorique où l'on tombe dans la classe i .

Définition 11.3. La statistique utilisée pour faire le test est :

$$\begin{aligned} Z_m &:= \sum_{i=1}^k \frac{(\text{nb d'éléments dans la classe } i - \text{nb d'éléments théorique dans la classe } i \text{ sous } H_0)^2}{\text{nb d'éléments théorique dans la classe } i \text{ sous } H_0} \\ &= \sum_{i=1}^k \frac{(N_i(m) - m\mu(i))^2}{m\mu(i)} \\ &= m \sum_{i=1}^k \frac{(\frac{N_i(m)}{m} - \mu(i))^2}{\mu(i)} \end{aligned}$$

Voici un exemple pour les lancers d'un dé.

Exemple 11.4 (m lancers d'un dé). *Pour m lancers de dé, on obtient :*

$$Z_m = m \left[\frac{(\frac{\# \text{ de } 1 \text{ obtenus}}{m} - \frac{1}{6})^2}{1/6} + \frac{(\frac{\# \text{ de } 2 \text{ obtenus}}{m} - \frac{1}{6})^2}{1/6} + \frac{(\frac{\# \text{ de } 3 \text{ obtenus}}{m} - \frac{1}{6})^2}{1/6} + \frac{(\frac{\# \text{ de } 4 \text{ obtenus}}{m} - \frac{1}{6})^2}{1/6} + \frac{(\frac{\# \text{ de } 5 \text{ obtenus}}{m} - \frac{1}{6})^2}{1/6} + \frac{(\frac{\# \text{ de } 6 \text{ obtenus}}{m} - \frac{1}{6})^2}{1/6} \right]$$

Nous pouvons étudier le comportement de la statistique quand H_0 est fausse.

Théorème 11.5 (quand H_0 est fausse). Supposons que H_0 fausse, c'est à dire que $(\omega_m)_{m \in \mathbb{N}}$ est une suite de variable aléatoire *i.i.d.* de loi μ_0 avec différent de μ . Alors, nous avons

$$Z_m \xrightarrow[m \rightarrow +\infty]{P.S.} +\infty.$$

Démonstration. En appliquant la loi des grands nombres, on obtient

$$\frac{N_i(m)}{m} \xrightarrow[m \rightarrow +\infty]{P.S.} \mu_0(i).$$

De plus, nous avons

$$\sum_{i=1}^k \frac{(\frac{N_i(m)}{m} - \mu(i))^2}{\mu(i)} \xrightarrow[m \rightarrow +\infty]{P.S.} \sum_{i=1}^k \frac{(\mu_0(i) - \mu(i))^2}{\mu(i)}.$$

Comme nous avons, $\mu \neq \mu_0$ sous l'hypothèse H_1 , on a

$$\sum_{i=1}^k \frac{(\mu_0(i) - \mu(i))^2}{\mu(i)} > 0.$$

Comme $Z_m = m \sum_{i=1}^k \frac{(\frac{N_i(m)}{m} - \mu(i))^2}{\mu(i)}$, on a $Z_m \xrightarrow[m \rightarrow +\infty]{P.S.} +\infty$. □

Remarquez que si l'hypothèse H_0 était vraie ($\mu = \mu_0$), on aurait

$$\sum_{i=1}^k \frac{\left(\frac{N_i(m)}{m} - \mu(i)\right)^2}{\mu(i)} \xrightarrow[m \rightarrow +\infty]{P.S.} 0.$$

Cependant, avec ce résultat, nous n'avons pas de garantie de convergence pour Z_m . Ainsi, nous pouvons étudier la convergence de Z_m en loi.

Théorème 11.6 (quand H_0 est vraie). Soit $(\omega_m)_{m \in \mathbb{N}}$ une suite de variables aléatoires *i.i.d.* de loi μ . Alors nous avons

$$Z_m \xrightarrow[m \rightarrow +\infty]{L} \chi^2(k-1).$$

Le test du χ^2 repose sur les deux théorèmes précédents. Autrement dit, il s'appuie sur des résultats asymptotiques, alors que l'on effectue qu'un nombre fini d'observations. En pratique, la recette magique est que le test est valide quand $m\mu(i) \geq 5$ pour tout $i \in 1, \dots, k$.

Algorithm 22 1er test du χ^2

- 1: **Paramètre** : Seuil $1 - \alpha$
 - 2: **Entrée** : $\omega_1, \dots, \omega_m \sim \mu$
 - 3: **Sortie** : Décision sur H_0
 - 4: Calculer Z_m en fonction des observations
 - 5: **if** $Z_m \leq q_{1-\alpha}$ (où $q_{1-\alpha}$ est le quantile de $\chi^2(k-1)$) **then**
 - 6: Conserver H_0
 - 7: **else**
 - 8: Rejeter H_0
 - 9: **end if**
-

Nous pouvons prendre un exemple !

Exemple 11.7 (dé pipé ou non ?). Sur $m = 600$ lancers, on observe :

Numéro tiré						
Effectif	88	109	107	94	105	97

On peut calculer la statistique

$$Z_m = \frac{(88 - 100)^2}{100} + \frac{(109 - 100)^2}{100} + \frac{(107 - 100)^2}{100} + \frac{(94 - 100)^2}{100} + \frac{(105 - 100)^2}{100} + \frac{(97 - 100)^2}{100} = 3.44,$$

et le quantile d'ordre 0.95 de la loi du $\chi^2(5)$:

$$q_{0.95} = 11.07.$$


Comme $Z_m < q_{0.95}$, on conserve H_0 .

Nous pouvons regarder un autre exemple (avec un autre dé).

Exemple 11.8 (dé pipé ou non ? Autre exemple).

Maintenant sur $n = 600$ lancers on observe :

Numéro tiré						
Effectif	89	131	93	92	104	91



Maintenant sur $n = 600$ lancers, nous avons observé :

Numéro tiré						
Effectif	89	131	93	92	104	91

On peut calculer Z_m et avoir

$$Z_m = \frac{(89 - 100)^2}{100} + \frac{(131 - 100)^2}{100} + \frac{(93 - 100)^2}{100} + \frac{(92 - 100)^2}{100} + \frac{(104 - 100)^2}{100} + \frac{(91 - 100)^2}{100} = 12.92$$

Ici, nous avons $Z_m \geq q_{0.95}$, nous rejetons donc H_0 .

11.3 Test d'adéquation à une famille de lois

Nous pouvons également nous intéresser à un test où l'on regarde si μ appartient à une famille de loi paramétrée par un paramètre θ .

Hypothèse. Soient une famille de paramètres $\Theta \subseteq \mathbb{R}^d$ et une famille de lois $(\mu_\theta)_{\theta \in \Theta}$. De plus, soit $\omega_1, \dots, \omega_m \sim \mu$ des données. On suppose que l'on a

$$H_0 : \mu = \mu_\theta \text{ avec } \theta \in \Theta$$

$$H_1 : \mu \neq \mu_\theta \text{ pour tout } \theta \in \Theta.$$

La statistique utilisée est quasiment la même que pour l'adéquation à une loi donnée, sauf que, au lieu d'utiliser μ_0 , on utilise μ_θ pour la valeur du paramètre $\theta \in \Theta$ la plus vraisemblable, autrement dit... pour l'estimateur du maximum de vraisemblance $\hat{\theta}_m$.

Définition 11.9. Soit $N_i(m)$ la variable aléatoire qui vaut le nombre de fois où l'on obtient un élément dans la classe i sur m lancers aléatoires. On pose

$$Z_m = \sum_{i=1}^k \frac{(N_i(m) - m\mu_{\hat{\theta}_m}(i))^2}{m\mu_{\hat{\theta}_m}(i)}$$

où $\hat{\theta}_m$ est l'estimateur du maximum de vraisemblance de θ .

Théorème 11.10. Soit $(\omega_m)_{m \in \mathbb{N}}$ une suite de variable aléatoires *i.i.d.* de loi μ_θ pour un certain $\theta \in \Theta$ (inconnu). Alors, nous avons

$$Z_m \xrightarrow[m \rightarrow +\infty]{L} \chi^2(k - d - 1),$$

où k est le nombre de classes, et d est le nombre de paramètres.

Grâce à ce théorème, nous pouvons ainsi étudier la convergence de Z_m lorsque l'hypothèse nulle est considérée comme vraie.

Théorème 11.11. Si l'hypothèse nulle H_0 est vraie, alors nous avons

$$Z_m \xrightarrow[m \rightarrow +\infty]{L} \chi^2(k-d-1).$$

De plus, lorsque l'hypothèse nulle H_0 est fausse, nous pouvons également étudier la convergence de Z_m .

Théorème 11.12. Si l'hypothèse nulle H_0 est fausse, alors nous avons

$$Z_m \xrightarrow[m \rightarrow +\infty]{P.S.} +\infty.$$

Nous pouvons donc déduire le test pour voir si une distribution μ appartient à une famille de loi $(\mu_\theta)_{\theta \in \Theta}$.

Algorithm 23 2ème test du χ^2

- 1: **Paramètre** : Seuil $1 - \alpha$
 - 2: **Entrée** : $\omega_1, \dots, \omega_m \sim \mu$
 - 3: **Sortie** : Décision sur H_0
 - 4: Calculer Z_m en fonction des observations
 - 5: **if** $Z_m \leq q_{1-\alpha}$ (où $q_{1-\alpha}$ est le quantile de $\chi^2(k-d-1)$) **then**
 - 6: Conserver H_0
 - 7: **else**
 - 8: Rejeter H_0
 - 9: **end if**
-

11.4 Test d'indépendance

Enfin, nous allons nous intéresser à tester si deux variables sont indépendantes.

Hypothèse. Soient $(\omega_m, \omega'_m)_{m \in \mathbb{N}}$ des variables aléatoires *i.i.d.* avec pour tout $m \in \mathbb{N}$, nous avons $\omega_m : \Omega \rightarrow \{1, \dots, k\}$ et $\omega'_m : \Omega \rightarrow \{1, \dots, l\}$. On suppose que l'on a

$$\begin{aligned} H_0 : & \quad \omega_1 \text{ et } \omega'_1 \text{ sont indépendantes} \\ H_1 : & \quad \omega_1 \text{ et } \omega'_1 \text{ ne sont pas indépendantes.} \end{aligned}$$

Pour toute classe $i \in \{1, \dots, k\}$, pour toute classe $j \in \{1, \dots, l\}$, on note $N_{i,j}(m)$ le nombre de fois où on a eu (i, j) , $N_{i,\cdot}(m)$ le nombre de fois où on a eu i , et $N_{\cdot,j}(m)$ le nombre de fois où on a eu j . Formellement, nous avons :

$$\begin{aligned} N_{i,j}(m) &= \sum_{n=1}^m \mathbf{1}[(Y_n, Z_n) = (i, j)], \\ N_{i,\cdot}(m) &= \sum_{j=1}^l N_{i,j}(m), \\ \text{et } N_{\cdot,j}(m) &= \sum_{i=1}^k N_{i,j}(m). \end{aligned}$$

Nous sommes maintenant en mesure de définir la statistique associée à ce test.

Définition 11.13. La statistique du test est donnée par

$$Z_m = \sum_{i=1}^k \sum_{j=1}^l \frac{\left(N_{i,j}(m) - \frac{N_{i,\cdot}(m)N_{\cdot,j}(m)}{m} \right)^2}{\frac{N_{i,\cdot}(m)N_{\cdot,j}(m)}{m}} = m \left(\sum_{i=1}^k \sum_{j=1}^l \frac{N_{i,j}(m)^2}{N_{i,\cdot}(m)N_{\cdot,j}(m)} - 1 \right).$$

Comme pour les statistiques précédentes, nous pouvons étudier la convergence de Z_m lorsque H_0 est vraie ou H_0 est fausse.

Théorème 11.14. Si l'hypothèse nulle H_0 est vraie, alors nous avons

$$Z_m \xrightarrow[m \rightarrow +\infty]{L} \chi^2((k-1)(l-1)).$$

Théorème 11.15. Si l'hypothèse nulle H_0 est fausse, alors nous avons

$$Z_m \xrightarrow[m \rightarrow +\infty]{P.S.} +\infty.$$

Nous pouvons maintenant en déduire le test.

Algorithm 24 3ème test du χ^2

- 1: **Paramètre** : Seuil $1 - \alpha$
 - 2: **Entrée** : $\omega_1, \dots, \omega_m$ et $\omega'_1, \dots, \omega'_m$
 - 3: **Sortie** : Décision sur H_0
 - 4: Calculer Z_m en fonction des observations
 - 5: **if** $Z_m \leq q_{1-\alpha}$ (où $q_{1-\alpha}$ est le quantile de $\chi^2((k-1)(l-1))$) **then**
 - 6: Conserver H_0
 - 7: **else**
 - 8: Rejeter H_0
 - 9: **end if**
-

Voici un exemple où nous voulons tester l'efficacité d'un médicament.

Exemple (efficacité de deux médicaments semblables mais de prix différents).

	<i>Médicament cher</i>	<i>Médicament bon marché</i>	
<i>Guérisons</i>	$N_{g,c}(m) = 156$	$N_{g,b}(m) = 44$	$N_{g,\cdot} = 200$
<i>Non-guérisons</i>	$N_{n,c}(m) = 44$	$N_{n,b}(m) = 6$	$N_{n,\cdot}(m) = 50$
	$N_{\cdot,c}(m) = 200$	$N_{\cdot,b}(m) = 50$	$m = 250$

Y-a-t-il indépendance entre guérison et médicament cher ou pas ?

Exemple. Nous pouvons calculer la statistiques Z_m . Nous avons

$$Z_m = 250 \left(\frac{156^2}{200 \cdot 200} + \frac{44^2}{50 \cdot 200} + \frac{44^2}{50 \cdot 200} + \frac{6^2}{50 \cdot 50} - 1 \right) = 2.5.$$

De plus, le quantile de $\chi_2(1)$ d'ordre 0.95 vaut

$$q_{0.95} = 3.84.$$

Comme $2.5 < 3.84$, on conserve H_0 .

Références

- Luc DEVROYE. Random variate generation in one line of code. *Conference on Winter simulation*. (1996).
- Christopher M. BISHOP et Nasser M. NASRABADI. Pattern recognition and machine learning. *Springer*. (2006).
- Trevor HASTIE, Robert TIBSHIRANI, Jerome H FRIEDMAN et Jerome H FRIEDMAN. The elements of statistical learning : data mining, inference, and prediction. *Springer*. (2009).
- Mehryar MOHRI, Afshin ROSTAMIZADEH et Ameet TALWALKAR. Foundations of Machine Learning. *MIT Press*. (2012).
- Peter WHITTLE. Probability via expectation. *Springer Science & Business Media*. (2012).
- Vladimir VAPNIK. The nature of statistical learning theory. *Springer science & business media*. (2013).
- Olivier GARET et Aline KURTZMANN. De l'intégration aux probabilités-2e édition augmentée. *Editions Ellipses*. (2019).
- Glenn SHAFER et Vladimir VOVK. Game-theoretic foundations for probability and finance. *John Wiley & Sons*. (2019).
- Philippe BARBE et Michel LEDOUX. Probabilité. *Probabilité. EDP Sciences*. (2021).
- Kevin P. MURPHY. Probabilistic machine learning : an introduction. *MIT press*. (2022).
- Francis BACH. Learning theory from first principles. *MIT press*. (2024).